


Python
for DA

Исследование данных с помощью визуализации в Matplotlib



Преподаватель

Портрет

Имя Фамилия

Текущая должность

Количество лет опыта

Какой у Вас опыт - ключевые кейсы

Самые яркие проекты

Дополнительная информация по вашему усмотрению

Корпоративный e-mail

Социальные сети (по желанию)

Важно

- 

Камера должна быть включена на протяжении всего занятия
- 

В течение занятия вопросы задавать в чате или когда преподаватель спрашивает, есть ли у Вас вопросы
- 

Вести себя уважительно и этично по отношению к остальным участникам занятия
- 

Организационные вопросы по обучению решаются с кураторами, а не на тематических занятиях
- 

Во время занятия будут интерактивные задания, будьте готовы включить камеру или демонстрацию экрана по просьбе преподавателя

Повторение



Масштабирование числовых характеристик



Выявление выбросов с помощью визуализации и статистических методов



Обработка выбросов



Работа с категориальными данными. Кодирование меток

План занятия

- Набор данных Wine Recognition
- Установка необходимых библиотек и загрузка данных
- Описание данных
- Распределение классов
- Boxplot
- Корреляция и тепловая карта
- Гистограммы
- Диаграмма рассеяния



ОСНОВНОЙ БЛОК





Набор данных Wine Recognition



Набор данных Wine Recognition

Это набор данных для распознавания вин, доступный в библиотеке `scikit-learn`, является классическим эталонным набором данных, обычно используемым для задач классификации.

Набор данных Wine Recognition



Этот набор данных включает результаты химического анализа вин, выращенных в одном и том же регионе Италии, но полученных из трех разных сортов (классов)

Набор данных Wine Recognition



Этот набор данных включает результаты химического анализа вин, выращенных в одном и том же регионе Италии, но полученных из трех разных сортов (классов)

В нем содержится 13 числовых признаков, представляющих различные химические свойства, обнаруженные в винах



Классы

Это целевая переменная. Существует три класса сортов вина, представленных целыми числами.

Классы сортов вина

Класс 0

Класс 1

Класс 2

Вино сорта 1

Вино сорта 2

Сорт вина 3



Характеристики

Это 13 признаков (атрибутов), представляющих различные химические свойства, обнаруженные в винах.

Характеристики



Алкоголь



Яблочная кислота



Зола



Щелочность золы



Магний



Общие фенолы



Флаваноиды



Нефлаваноидные фенолы



Проантоцианы



Интенсивность цвета



Оттенок



OD280/OD315 разбавленных вин



Пролин



Размер данных

Это 178 экземпляров (строк), каждый из которых представляет собой отдельный образец вина.



Источник данных

Это репозиторий машинного обучения
Калифорнийского университета в Ирвине (UCI).



Использование

Для задач классификации, в частности для обучения и оценки моделей машинного обучения.



ВОПРОСЫ





Установка библиотек и загрузка данных

Установка необходимых библиотек

```
import numpy as np
import pandas as pd
from sklearn.datasets import load_wine
import matplotlib.pyplot as plt
import seaborn as sns
```

Загрузка данных

```
X, y = load_wine(return_X_y=True, as_frame=True)
X['class'] = y
X.head()
```



ВОПРОСЫ





Описание **данных**

Повторный вызов функции load_wine()

```
print(load_wine()['DESCR'])
```




.describe()

Это метод, который вычисляет и отображает описательную статистику для каждого числового столбца в DataFrame X.

Метод .describe()

```
X.describe()
```



ВОПРОСЫ






Распределение классов

Распределение классов

```
X['class'].plot.hist()
```





`.plot.hist()`

Это метод, который строит гистограмму для данных в выбранном столбце (`X['class']`).



Гистограмма

Это графическое представление, которое отображает распределение числовых данных путем разделения данных на бины или интервалы и подсчета количества наблюдений, попавших в каждую бину.




`.hist()`

Это функция, которая используется для создания графика гистограммы в pandas.

Создание гистограммы

```
X['class'].plot.hist(orientation="horizontal", cumulative=True)
```



Вспомним Python Fundamentals

```
from collections import Counter  
  
print(Counter(y))
```



ВОПРОСЫ






Boxplot



Горизонтальный бокс-график

`X.plot.box(vert=False)`






`.plot.box()`

Это метод, который генерирует квадратный график для данных в DataFrame X.

Выбросы

```
with_outliners = ['hue', 'color_intensity', 'proanthocyanins',
                  'alcalinity_of_ash', 'ash', 'malic_acid'] # , 'magnesium'
X[with_outliners].plot.box(vert=False)
```

Выбросы



Экспресс-опрос

?

Что бы Вы сделали с выбросами?



ВОПРОСЫ






Корреляция и тепловая карта

Корреляция и тепловая карта

```
plt.figure(figsize=(10,10))
cmap=X.corr()
sns.heatmap(cmap, annot=True)
```





`plt.figure()`

Это функция, которая создает новую фигуру с заданным размером в Matplotlib. Она задает размер фигуры, чтобы визуализация тепловой карты имела достаточно места для четкого отображения.



Корреляционная матрица

Это квадратная матрица, каждый элемент которой представляет собой коэффициент корреляции между двумя признаками. Она дает представление о связях и зависимостях между различными признаками в наборе данных.



heatmap()

Это функция, которая генерирует тепловую карту. Она визуализирует корреляционную матрицу (сmap) в виде тепловой карты, где цвет каждой ячейки представляет собой коэффициент корреляции между двумя признаками.



ВОПРОСЫ






Гистограммы

Корреляция и тепловая карта

```
X['total_phenols'].hist(by=X['class'])
```





ВОПРОСЫ






Диаграмма рассеяния



Корреляция и тепловая карта

```
X.plot.scatter(x="total_phenols",
, y="flavanoids", c="class",
s=50, colormap='viridis')
```



Графики рассеяния для атрибутов с лучшей корреляцией

```
good_corr = ['total_phenols', 'flavanoids', 'od280/od315_of_diluted_wines', 'hue', 'proline',
'nonflavanoid_phenols', 'alcalinity_of_ash']

pairs = [(good_corr[i], good_corr[j]) for i in range(len(good_corr)) for j in range(i+1,
len(good_corr))]

non_repeated_pairs = []
seen_pairs = set()
for pair in pairs:
    reversed_pair = (pair[1], pair[0]) # Check both (a, b) and (b, a)
    if pair not in seen_pairs and reversed_pair not in seen_pairs:
        non_repeated_pairs.append(pair)
        seen_pairs.add(pair)

print(len(non_repeated_pairs))
```

Графики рассеяния для атрибутов с лучшей корреляцией

```
num_plots = len(non_repeated_pairs)

num_rows = num_plots // 3
num_cols = 3
fig, axs = plt.subplots(num_rows, num_cols, figsize=(24, 24))

if num_rows == 1 or num_cols == 1:
    axs = axs.flatten()


axe = axs.ravel()

for i, pair in enumerate(non_repeated_pairs):
    X.plot.scatter(x=pair[0], y=pair[1], c="class", s=50, colormap='viridis', ax=axe[i])
    axe[i].set_title(f'{pair[0]}'+ '/' +f'{pair[1]}')

plt.tight_layout()

plt.show()
```

Графики рассеяния для атрибутов с лучшей корреляцией





ВОПРОСЫ





ПРАКТИЧЕСКАЯ РАБОТА



Задание

1. Постройте круговую диаграмму распределения классов.
2. Какие графики Вы бы ещё построили?
3. Как можно было бы исправить графики распределения переменных по классам, чтобы сделать их более наглядными?





ВОПРОСЫ



Заключение

