


Python
for DA

Основы статистики



Преподаватель

Портрет

Имя Фамилия

Текущая должность

Количество лет опыта

Какой у Вас опыт - ключевые кейсы

Самые яркие проекты

Дополнительная информация по вашему усмотрению

Корпоративный e-mail

Социальные сети (по желанию)

Важно

- 

Камера должна быть включена на протяжении всего занятия
- 

В течение занятия вопросы задавать в чате или когда преподаватель спрашивает, есть ли у Вас вопросы
- 

Вести себя уважительно и этично по отношению к остальным участникам занятия
- 

Организационные вопросы по обучению решаются с кураторами, а не на тематических занятиях
- 

Во время занятия будут интерактивные задания, будьте готовы включить камеру или демонстрацию экрана по просьбе преподавателя

Повторение



Обзор Dash и его экосистемы



Установка необходимых пакетов для разработки Dash



Настройка базового окружения Dash и структура приложения Dash в VS Code



Создание HTML-контура приборной панели с помощью `dash_html_components`



Включение интерактивных визуализаций данных с помощью `dash_core_components`



Пример приложения

План занятия

- Обзор статистики и ее виды
- Генеральная совокупность и выборка
- Качественные и количественные переменные
- Описательная статистика



ОСНОВНОЙ БЛОК





Обзор статистики и ее виды



Статистика

Это раздел математики, который занимается сбором, анализом, интерпретацией, представлением и организацией числовых данных.

Важность статистики в анализе данных

-  Обобщение данных
-  Принятие решений
-  Понимание взаимосвязей
-  Работа с неопределенностью
-  Визуализация данных
-  Применение в реальном мире

Типы статистики

Описательная статистика

Обобщение и описание характеристик
набора данных

Индуктивная статистика

Составление прогнозов или выводов о
совокупности на основе выборки
данных



Описательная статистика


Это раздел статистики, который включает в себя организацию, визуализацию и представление данных таким образом, чтобы обеспечить четкое и краткое обобщение собранной информации.

Описательная статистика



Направлена на описание характеристик изучаемого набора данных, не делая выводов или предсказаний за пределами анализируемых данных

Компоненты описательной статистики



Меры
центральной
тенденции

Меры дисперсии

Графические
представления



Индуктивная статистика

Это раздел статистики, который включает в себя прогнозы, выводы или обобщения о более широкой совокупности на основе данных, собранных на основе выборки этой совокупности.

Индуктивная статистика



Распространяет выводы, сделанные на основе выборки, на всю генеральную совокупность, из которой была взята выборка, позволяя исследователям делать выводы, проверять гипотезы и делать прогнозы

Компоненты индуктивной статистики



Проверка гипотез

Регрессионный
анализ

Доверительные
интервалы



ВОПРОСЫ





Генеральная совокупность и выборка



Генеральная совокупность

Это вся совокупность точек данных, представляющих интерес в конкретном исследовании. Включает в себя все возможные наблюдения, которые могут быть сделаны в рамках определенной группы.

Характеристика генеральной совокупности



Включает каждый элемент изучаемой группы



Параметр

Это измеряемая характеристика генеральной совокупности, такая как среднее значение или стандартное отклонение.

Примеры генеральной совокупности



Все жители страны
Все студенты университета
Все продукты, производимые компанией

Типы генеральных совокупностей

Конечная
совокупность

Бесконечная
совокупность

Существующая
генеральная
совокупность

Гипотетическая
генеральная
совокупность



Выборка

Это подмножество генеральной совокупности, отобранное для анализа. Представляет собой меньшую, управляемую часть генеральной совокупности, отобранную для того, чтобы сделать выводы обо всей группе.

Характеристика выборки



Включает только часть генеральной совокупности



Статистика

Это измеряемая характеристика выборки, такая как среднее значение выборки или стандартное отклонение выборки.

Примеры выборки



Случайная выборка 1000 жителей страны
Группа из 200 студентов университета
Выборка продукции из производственной партии

Типы генеральных совокупностей

Случайная выборка

Стратифицированная
выборка

Удобная выборка

Различия между генеральной совокупностью и выборкой



Генеральная совокупность

- Вся исследуемая группа людей, предметов или наблюдений
- Все элементы, представляющие интерес
- Цель обобщения в исследовании
- Различные методы сбора данных
- Цель - понять характеристики, тенденции и закономерности всей группы

Выборка

- Подмножество людей, предметов или наблюдений, отобранных из генеральной совокупности
- Часть генеральной совокупности
- Используется, чтобы сделать выводы о более широкой генеральной совокупности
- Данные собираются с помощью методов выборки
- Цель - сделать выводы о совокупности на основе характеристик выборки

Важность статистического анализа



Эффективность



Целесообразность



Выводы



ВОПРОСЫ





Качественные и количественные переменные



Переменные

Это фундаментальные элементы, представляющие собой характеристики или свойства, которые мы измеряем или наблюдаем в ходе исследования. Необходимы для сбора, анализа и интерпретации данных



Качественные переменные

Это нечисловые данные, описывающие качества или характеристики. Делят данные на отдельные группы или категории на основе атрибутов или свойств, которые нельзя измерить численно.

Типы качественных переменных

Номинальные
переменные

Ординарные
переменные

Бинарные переменные

Качественные переменные

- Качественные переменные выражаются не числами, а описательными терминами.
- Классифицируют данные по категориям или группам.



Примеры:

- Цвет глаз
- Семейное положение
- Тип автомобиля
- Отзывы покупателей



Количественные переменные

Это данные, которые можно измерить и выразить численно. Выражают количественные характеристики и позволяют выполнять широкий спектр математических операций и статистических анализов.

Типы количественных переменных

Дискретные переменные

Непрерывные переменные

Количественные переменные

- Количественные переменные выражаются в числах.
- Они измеряют количества или суммы.



Примеры:

- Возраст
- Доход
- Расстояние
- Результаты тестов

Важность статистического анализа



Сбор данных



Статистические методы



Интерпретация



ВОПРОСЫ





Меры центральной тенденции



Описательная статистика

Это статистика, которая используется для обобщения и описания основных характеристик набора данных.



Мера центральной тенденции

Это ключевой аспект описательной статистики, который определяет центральную точку или типичное значение в наборе данных.



Среднее значение

Это сумма всех значений в наборе данных, деленная на количество значений.

Среднее значение



$$\bar{x} = \frac{\sum x_i}{n}$$

$\sum x_i$ - сумма всех значений, а n - количество значений в наборе данных

Среднее значение



Пример расчета

Рассмотрим набор данных: 5, 4, 2, 3, 2, 1, 5, 4, 5

$$\bar{x} = \frac{5+4+2+3+2+1+5+4+5}{9} = \frac{31}{9} \approx 3.44$$

Команда Python

```
import numpy as np
data = [5, 4, 2, 3, 2, 1, 5, 4, 5]
mean = np.mean(data)
print(mean) # Выходные данные: 3.44
```



Медиана

Это среднее значение в наборе данных, когда значения расположены в порядке возрастания или убывания.

Шаги для расчета медианы

1. Расположите данные в порядке возрастания.
2. Если количество наблюдений (n) нечетное, медиана - это среднее значение.
3. Если количество наблюдений (n) четное, медиана - это среднее значение двух средних значений.

Медиана



Пример расчета

Рассмотрим набор данных:

5, 4, 2, 3, 2, 1, 5, 4, 5

Упорядоченный набор данных:

1, 2, 2, 3, 4, 4, 5, 5, 5

Медиана: 4 (среднее значение)

Команда Python

```
median = np.median(data)
print(median) # Вывод: 4
```



Мода

Это значение, которое чаще всего встречается в наборе данных. Единственная мера центральной тенденции, которую можно использовать с номинальными данными (категориальными данными).

Мода



Набор данных может не иметь моды, иметь один моду или несколько мод

Мода



Пример расчета

Рассмотрим набор данных:

5, 4, 2, 3, 2, 1, 5, 4, 5

Мода: 5 (встречается наиболее часто)

Команда Python

```
from scipy import stats
mode = stats.mode(data)
print(mode.mode) # Вывод: 5
```

Выбор подходящей меры

Среднее значение

Подходит для
симметричных
распределений без
выбросов

Медиана

Подходит для
перекошенных
распределений или при
наличии выбросов

Мода

Подходит для
категориальных данных
или определения
наиболее часто
встречающегося значения
в наборе данных



ВОПРОСЫ





Меры дисперсии



Меры дисперсии

Это статистические инструменты, используемые для описания разброса или изменчивости в наборе данных. Дают представление о том, насколько сильно точки данных отличаются от центрального значения, помогая понять распределение и согласованность данных.



Диапазон

Это простейшая мера дисперсии, которая рассчитывается как разница между максимальным и минимальным значениями в наборе данных.

Диапазон



Диапазон = Максимальное значение - Минимальное значение

Диапазон



Пример расчета

Набор данных:

5, 4, 2, 3, 2, 1, 5, 4, 5

Диапазон: $5 - 1 = 4$

Команда Python

```
data = [5, 4, 2, 3, 2, 1, 5, 4, 5]
range_value = max(data) - min(data)
print(range_value) # Вывод: 4
```



Дисперсия

Измеряет среднее квадратичное отклонение каждой точки данных от среднего значения. Дает представление о том, насколько разбросаны точки данных.

Дисперсия



$$\sigma^2 = \frac{\sum (x_i - \bar{x})^2}{N}$$

Дисперсия



Пример расчета

Набор данных:

5, 4, 2, 3, 2, 1, 5, 4, 5

Среднее ($\bar{x}$) : ≈ 3.44

Дисперсия:

$$\frac{(5-3.44)^2 + (4-3.44)^2 + (2-3.44)^2 + \dots + (5-3.44)^2}{9} \approx 2.02$$

Команда Python

```
import numpy as np
variance = np.var(data)
print(variance) # Выходные данные: 2.02
```



Стандартное отклонение

Это квадратный корень из дисперсии, обеспечивающий меру дисперсии в тех же единицах, что и данные.

Стандартное отклонение



$$\sigma = \sqrt{\frac{\sum (x_i - \bar{x})^2}{N}}$$

Стандартное отклонение



Пример расчета

$$\sqrt{2.02} \approx 1.42$$

Команда Python

```
std_dev = np.std(data)
print(std_dev) # Выходные данные: 1.42
```



Межквартильный интервал (IQR)

Измеряет разброс средних 50% данных, рассчитывается как разница между третьим квартилем (Q3) и первым квартилем (Q1).

Межквартильный интервал (IQR)



$$IQR = Q_3 - Q_1$$

Межквартильный интервал (IQR)



Пример расчета

Упорядоченный набор данных:

1, 2, 2, 3, 4, 4, 5, 5, 5

Q1: 2, Q3: 5

IQR: $5 - 2 = 3$.

Команда Python

```
Q1 = np.percentile(data, 25)
Q3 = np.percentile(data, 75)
IQR = Q3 - Q1
print(IQR) # Выходные данные: 3
```



ВОПРОСЫ





ПРАКТИЧЕСКАЯ РАБОТА



Задание



Рассчитайте дисперсию без использования встроенных функций numpy.



ВОПРОСЫ



Заключение

