


Python
for DA

Исследовательский анализ данных (EDA). Первый взгляд на данные



Преподаватель

Портрет

Имя Фамилия

Текущая должность

Количество лет опыта

Какой у Вас опыт - ключевые кейсы

Самые яркие проекты

Дополнительная информация по вашему усмотрению

Корпоративный e-mail

Социальные сети (по желанию)

Важно

- 

Камера должна быть включена на протяжении всего занятия
- 

В течение занятия вопросы задавать в чате или когда преподаватель спрашивает, есть ли у Вас вопросы
- 

Вести себя уважительно и этично по отношению к остальным участникам занятия
- 

Организационные вопросы по обучению решаются с кураторами, а не на тематических занятиях
- 

Во время занятия будут интерактивные задания, будьте готовы включить камеру или демонстрацию экрана по просьбе преподавателя

Повторение



Тест Хи-квадрат



Основы корреляции



Коэффициент корреляции Пирсона (r)



Коэффициент ранговой корреляции Спирмена (ρ)



Визуализация корреляции. Графики рассеяния



Тепловые карты в корреляционном анализе

План занятия

- Цели исследовательского анализа данных
- Инструменты EDA
- Основные этапы EDA
- Подключение модулей
- Загрузка и первоначальная проверка данных
- Преобразование данных



ОСНОВНОЙ БЛОК





Цели исследовательского анализа данных





Исследовательский анализ данных (EDA)

это метод анализа наборов данных для понимания их основных характеристик. Он включает в себя обобщение характеристик данных, выявление закономерностей и взаимосвязей с помощью визуальных и статистических методов.

Этапы проведения EDA



Понимание структуры и характеристик набора данных

На этом этапе EDA мы пристально изучаем структуру и характеристики данных, чтобы полностью понять, с чем имеем дело. Изучаем размер набора данных, типы переменных, выявляем пропущенные значения, дубликаты и другие важные аспекты.

Выявление аномалий и выбросов

Иногда данные могут хранить в себе сюрпризы, которые могут существенно повлиять на наши выводы. Используя методы EDA мы обнаруживаем аномалии и выбросы в наших данных.

Этапы проведения EDA



Идентификация связей и корреляций между переменными

С помощью статистических характеристик EDA позволяет выявить взаимосвязи между переменными, понять, как одни факторы влияют на другие.

Подготовка данных для дальнейших этапов анализа

На этом этапе EDA мы обрабатываем данные для того, чтобы подготовить их к более сложным аналитическим методам. Мы чистим данные от шума, заполняем пропущенные значения, проводим масштабирование или преобразования переменных, чтобы обеспечить их качественную и интерпретируемую структуру.



ВОПРОСЫ





Инструменты EDA и этапы EDA

Основные этапы EDA

-  Загрузка и первоначальная проверка данных
-  Очистка и преобразование данных
-  Одномерный анализ
-  Двумерный анализ
-  Визуализация



ВОПРОСЫ





**Загрузка и 
первоначальная
проверка данных**

Этапы EDA на примере



Рассмотрим основные этапы, возьмем [набор данных](#) с информацией о поддержанных автомобилях. Цель – на основе этих данных построить модель для прогнозирования цен поддержанных автомобилей. Само по себе создание модели – отдельный сложный процесс определения вклада каждого фактора в финальную цену. Но прежде чем приступить к этому процессу, нужно понять, какие факторы имеют влияние на цену, а какие вообще не нужно, нельзя или невозможно включить в модель. Собственно, это и есть основной результат, который мы хотели бы получить в результате исследовательского анализа данных.

Описание датасета



Name: Марка и модель автомобиля

Location: Город, в котором автомобиль продается

Year: Год выпуска

Kilometers_Driven: Пробег (в км)

Fuel_Type: Тип топлива, используемого автомобилем

Transmission: Тип коробки передач

Owner_Type: Количество предыдущих владельцев

Mileage: Расход топлива (в км/л или км/кг)

Engine: Объем двигателя (в см³)

Power: Максимальная мощность двигателя (в л.с.)

Seats: Количество мест в автомобиле

New_Price: Стоимость нового автомобиля той же марки

Price: Цена подержанного автомобиля (в лакхах)

1 Lakh (лакх) = 100000 индийских рупий, 1 Cr (крор) = 100 лакх

Подключение модулей

```
import pandas as pd  
import numpy as np  
import matplotlib.pyplot as plt  
import seaborn as sns
```

Загрузка данных

[Данные](#) для загрузки

```
data = pd.read_csv("used_cars_data.csv")
```

Получение общего представления о данных

```
data.head()
```

```
data.tail()
```

```
data.info()
```

Результат

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 7253 entries, 0 to 7252
Data columns (total 14 columns):
#   Column                Non-Null Count  Dtype
---  -
0   S.No.                  7253 non-null   int64
1   Name                   7253 non-null   object
2   Location               7253 non-null   object
3   Year                   7253 non-null   int64
4   Kilometers_Driven      7253 non-null   int64
5   Fuel_Type              7253 non-null   object
6   Transmission           7253 non-null   object
7   Owner_Type             7253 non-null   object
8   Mileage                7251 non-null   object
9   Engine                 7207 non-null   object
10  Power                  7207 non-null   object
11  Seats                  7200 non-null   float64
12  New_Price              1006 non-null   object
13  Price                  6019 non-null   float64
dtypes: float64(2), int64(3), object(9)
memory usage: 793.4+ KB
```

Количество отсутствующих значений

```
data.isnull().sum()
```

Количество уникальных и дублированных значений

```
data.nunique()
```

```
data[data.duplicated()]
```

Задание



Что известно про столбец New_Price? Это категориальная переменная или нет, и почему?

Что вычисляет этот код?

```
(data.isnull().sum()/(len(data)))*100
```




ВОПРОСЫ





Преобразование данных



Преобразование данных

включает в себя их сокращение, корректировку и дополнение на основе имеющихся.

Исключение данных

```
data = data.drop(['S.No.'], axis = 1)  
data.info()
```

Преобразование необработанных данных

```
from datetime import date  
date.today().year  
data['Car_Age']=date.today().year-data['Year']  
data.head()
```

Преобразование необработанных данных

```
data['Brand'] = data.Name.str.split().str.get(0)
data['Model'] = data.Name.str.split().str.get(1) +
data.Name.str.split().str.get(2)
data.sample(10)
```

Анализ соответствия данных типам столбцов

```
print(data.Brand.unique())
```

```
['Maruti' 'Hyundai' 'Honda' 'Audi' 'Nissan' 'Toyota' 'Volkswagen' 'Tata'
 'Land' 'Mitsubishi' 'Renault' 'Mercedes-Benz' 'BMW' 'Mahindra' 'Ford'
 'Porsche' 'Datsun' 'Jaguar' 'Volvo' 'Chevrolet' 'Skoda' 'Mini' 'Fiat'
 'Jeep' 'Smart' 'Ambassador' 'Isuzu' 'ISUZU' 'Force' 'Bentley'
 'Lamborghini' 'Hindustan' 'OpelCorsa']
```

Исправление ошибок

```
data["Brand"] = data["Brand"].replace({"ISUZU": "Isuzu", "Mini": "Mini  
Cooper", "Land": "Land Rover"})
```

```
del data['Name']
```


Анализ ошибок с Mileage, Engine, Power, New_Price

```
data['Mileage_num'] = data.Mileage.str.split().str.get(0)
data['Mileage_units'] = data.Mileage.str.split().str.get(1)
data['Mileage_num'] = data['Mileage_num'].astype(float)
```

Просмотр результата

```
print(data.isnull().sum())  
print(data.Mileage_units.unique())  
print(data.info())
```

Унификация единиц

```
data['Mileage'] = data['Mileage_num']*(1+0.333*(data['Mileage_units']=='km/kg'))  
del data['Mileage_num']  
del data['Mileage_units']  
print(data.info())
```



ВОПРОСЫ





ЗАДАНИЕ



Задание

Как проверить, что в категориальных столбцах Fuel_Type, Transmission, Owner_Type нет опечаток? Сделайте это.

Столбец "Seats" – количество мест в автомобиле – имеет тип float64. Корректно ли это? Нужно ли его преобразовать к целочисленному типу? Возможно ли это?



ПРАКТИЧЕСКАЯ РАБОТА



Задание



Приведите столбцы Engine, Power, New_Price к числовым типам. Проверьте, требуется ли унификация единиц измерения.



ВОПРОСЫ



Заключение

