


Python
for DA

Анализ временных рядов



Преподаватель

Портрет

Имя Фамилия

Текущая должность

Количество лет опыта

Какой у Вас опыт - ключевые кейсы

Самые яркие проекты

Дополнительная информация по вашему усмотрению

Корпоративный e-mail

Социальные сети (по желанию)

Важно

- 

Камера должна быть включена на протяжении всего занятия
- 

В течение занятия вопросы задавать в чате или когда преподаватель спрашивает, есть ли у Вас вопросы
- 

Вести себя уважительно и этично по отношению к остальным участникам занятия
- 

Организационные вопросы по обучению решаются с кураторами, а не на тематических занятиях
- 

Во время занятия будут интерактивные задания, будьте готовы включить камеру или демонстрацию экрана по просьбе преподавателя

Повторение



Цели основного этапа EDA



Одномерный анализ



Двумерный анализ



Многомерный анализ



Заполнение пропущенных значений

План занятия

- Временные ряды
- Компоненты временных рядов
- Стационарность
- Автокорреляционные и частичные автокорреляционные функции
- Повторная выборка



ОСНОВНОЙ БЛОК





Временные ряды



Временной ряд

Это последовательность точек данных, собранных или записанных в последовательные моменты времени, как правило, через равномерные интервалы. Характеризуется временной упорядоченностью, что означает, что порядок наблюдения точек данных имеет решающее значение для анализа.

Отличия данных временных рядов



Данные временных рядов отличаются от других типов данных, так как они фиксируют изменение переменной во времени, что позволяет выявить тенденции, закономерности и сезонные колебания

Важность временных рядов

Финансы

Прогнозирование
погоды

Анализ продаж

- Отслеживания движения цен
- Прогнозирования
- Анализ волатильности

Важность временных рядов

Финансы

Прогнозирование
погоды

Анализ продаж

- Прогнозирование погодных условий
- Изучение климата
- Управление энергопотреблением

Важность временных рядов

Финансы

Прогнозирование
погоды

Анализ продаж

- Прогнозировать будущие продажи
- Выявлять сезонные тенденции
- Оптимизировать операции



Тренд

Это долгосрочное движение в данных, указывающее на общее увеличение или уменьшение с течением времени.



Сезонность

Это регулярные, предсказуемые изменения, повторяющиеся в течение определенных периодов, таких как ежедневные, ежемесячные или ежегодные циклы.



Шум

Это случайные колебания данных, которые не следуют определенным закономерностям.



Стационарность

Это свойство временного ряда, при котором его статистические характеристики, такие как среднее значение и дисперсия, постоянны во времени.

Применение в различных областях

Эконометрика

Здравоохранение

Инженерия



ВОПРОСЫ





Компоненты временных рядов



Тренд

Это долгосрочная динамика ряда.
Показывает общее направление, в котором
движутся данные с течением времени:
увеличивается, уменьшается или остается
неизменным.



Сезонность

Это регулярные колебания, которые происходят через определенные промежутки времени, например, ежедневно, ежемесячно или ежегодно. Сезонность часто обусловлена внешними факторами, такими как праздники, погодные условия или бизнес-циклы.



Шум

Это случайная вариация ряда, которую нельзя отнести к тренду или сезонности. Это непредсказуемая часть данных, часто вызванная непредвиденными событиями или ошибками измерений.



Декомпозиция временного ряда

Это процесс разделения временного ряда на составляющие его компоненты. Можно реализовать с помощью аддитивных или мультипликативных моделей.

Методы декомпозиции

Аддитивная модель

Мультипликативная
модель

Аддитивная модель



Подходит, когда величина сезонности не зависит от уровня ряда.
Компоненты складываются вместе:

$$y(t) = \text{Уровень} + \text{Тренд} + \text{Сезонность} + \text{Шум}$$

Мультипликативная модель



Подходит, когда величина сезонности масштабируется с уровнем ряда.
Компоненты перемножаются между собой:

$$y(t) = \text{Уровень} \times \text{Тренд} \times \text{Сезонность} \times \text{Шум}$$

Пример с использованием предустановленных данных

Для демонстрации компонентов воспользуемся набором данных AirPassengers, который предустановлен в библиотеке statsmodels в Python.

Импорт библиотек и загрузка данных

```
import pandas as pd
import matplotlib.pyplot as plt
from statsmodels.tsa.seasonal import seasonal_decompose
from statsmodels.datasets import get_rdataset

data = get_rdataset('AirPassengers', 'datasets').data
data.index = pd.date_range(start = "1949-01", periods = len(data.index), freq =
"ME").to_period()
data.index = data.index.to_timestamp()
data.head()
```

Разложение временного ряда

```
# Декомпозиция временного ряда
decomposition = seasonal_decompose(data['value'], model='multiplicative')

trend = decomposition.trend
seasonal = decomposition.seasonal
residual = decomposition.resid
```

Построение графика компонентов

```
plt.figure(figsize=(12, 8))

plt.subplot(411)
plt.plot(data['value'], label='Original')
plt.legend(loc='best')

plt.subplot(412)
plt.plot(trend, label='Trend')
plt.legend(loc='best')

plt.subplot(413)
plt.plot(seasonal, label='Seasonality')
plt.legend(loc='best')

plt.subplot(414)
plt.plot(residual, label='Residuals')
plt.legend(loc='best')

plt.tight_layout()
plt.show()
```

Полезно знать

Исходная серия

Исходные данные, показывающие количество авиапассажиров с течением времени.

Тренд

Долгосрочный рост числа пассажиров.



Сезонность

Повторяющаяся закономерность в течение каждого года, показывающая увеличение числа пассажиров в определенные месяцы.

Остатки

Оставшийся шум после удаления тренда и сезонности, представляющий собой случайные колебания.



ВОПРОСЫ





ЗАДАНИЕ



Задание



Компания Adidas решила проанализировать продажи худи за последние 10 лет. Опишите возможные результаты:

- Каким будет тренд?
- Будет ли выраженная сезонность?
- Будут ли шумы?



ВОПРОСЫ





Стационарность



Стационарность

Это свойство, при котором статистические характеристики ряда, такие как среднее значение, дисперсия и автокорреляция, остаются неизменными с течением времени. Процесс, порождающий временной ряд, не меняется с течением времени, что делает ряд предсказуемым и более простым для моделирования.

Типы стационарности

Строгая
стационарность

Слабая
стационарность

Важность стационарности


-  Предположения модели
-  Упрощенный анализ
-  Прогнозирование
-  Диагностические проверки
-  Улучшенная производительность моделей




Дополненный тест Дикки-Фуллера (ADF)

Это распространенный статистический тест, используемый для определения стационарности временного ряда. Разновидность теста на единичный корень, который проверяет нулевую гипотезу о наличии единичного корня во временном ряду, что подразумевает нестационарность.

Шаги выполнения теста ADF



Шаги выполнения теста ADF



Пример с использованием предустановленных наборов данных

Для демонстрации теста ADF воспользуемся набором данных AirPassengers, который предустановлен в библиотеке statsmodels в Python.

Выполнение ADF-теста

```
from statsmodels.tsa.stattools import adfuller
result = adfuller(data['value'])
print('ADF Statistic:', result[0])
print('p-value:', result[1])
print('Критические значения:', result[4])
```

Интерпретация результатов

```
if result[1] < 0.05:  
    print("Временной ряд стационарен")  
else:  
    print("Временной ряд нестационарный")
```



ВОПРОСЫ





ЗАДАНИЕ



Задание

Вы исследуете данные о среднесуточной температуре воздуха в Берлине за некоторый длинный период времени. Какой вывод можно будет сделать, если вы обнаружите, что этот ряд не стационарен, и какой – если стационарен?



ВОПРОСЫ





Автокорреляционные и частичные автокорреляционные функции



Автокорреляция

Измеряет линейную связь между наблюдениями во временном ряду и наблюдениями на предыдущих временных шагах (лагах). Помогает выявить закономерности и зависимости в данных, указывая на то, как прошлые значения влияют на текущие.



Автокорреляционная функция (АКФ)

Оценивает корреляцию между
наблюдениями для набора лагов.

Автокорреляция



$$ACF(k) = \text{Corr}(y_t, y_{t-k}),$$

где Corr обозначает корреляционную функцию,
 k - лаг.

Интерпретация

Положительная АКФ

Указывает на положительную корреляцию между текущим наблюдением и наблюдением с лагом k

Отрицательная АКФ

Указывает на отрицательную корреляцию между текущим наблюдением и наблюдением с лагом k

Затухание АКФ

Постепенное затухание автокорреляции с увеличением лага часто указывает на наличие тренда или сезонности во временном ряду



Частичная автокорреляционная функция (PACF)

Помогает определить прямую связь между наблюдениями на определенных лагах, исключая вклад других лагов.

Пример с использованием предустановленных наборов данных

Воспользуемся набором данных AirPassengers, который предустановлен в библиотеке statsmodels в Python, чтобы продемонстрировать автокорреляцию и частичную автокорреляцию.

График автокорреляционной функции

```
from statsmodels.graphics.tsaplots import plot_acf, plot_pacf
plot_acf(data['value'], lags=50)
plt.title('Автокорреляционная функция (АКФ)')
plt.show()
```

График частичной автокорреляционной функции

```
plot_pacf(data['value'], lags=50)  
plt.title('Частичная автокорреляционная функция (PACF)')  
plt.show()
```



ВОПРОСЫ





ЗАДАНИЕ



Задание

Вы исследуете данные о среднесуточной температуре воздуха в Берлине за некоторый длинный период времени. Автокорреляция с каким лагом будет наиболее существенной?



ВОПРОСЫ





Повторная выборка



Повторная выборка

Это важная техника анализа временных рядов, которая заключается в изменении частоты данных временного ряда. Это может быть сделано либо путем апсемплинга, либо путем даунсемплинга. Позволяет обобщать или агрегировать данные по различным временным периодам.



Апсемплинг

Это увеличение частоты данных временного ряда, например, преобразование ежедневных данных в часовые. При этом часто приходится заполнять недостающие значения с помощью таких методов, как интерполяция.



Даунсемплинг

Это уменьшение частоты данных временного ряда, например, преобразование часовых данных в ежедневные. Обычно это связано с агрегированием точек данных с помощью таких функций, как `sum`, `mean` или `max`.

Пример демонстрации повторной выборки

Воспользуемся [набором данных](#). Этот набор данных содержит данные о продажах с временными метками, которые мы можем агрегировать до различных временных частот.

Импорт библиотек и загрузка данных

```
import pandas as pd
import matplotlib.pyplot as plt

data = pd.read_excel(r'Superstore.xlsx', sheet_name='Orders')
data['Order Date'] = pd.to_datetime(data['Order Date'])
data.set_index('Order Date', inplace=True)
```

Агрегация продаж по месяцам

```
# Агрегируем продажи по месяцам
monthly_sales = data['Sales'].resample('ME').sum()

# Постройте график продаж за месяц
plt.figure(figsize=(10, 6))
plt.plot(monthly_sales, label='Monthly Sales')
plt.title('Ежемесячные продажи магазина')
plt.xlabel('Дата')
plt.ylabel('Продажи')
plt.legend()
plt.show()
```

Агрегация продаж по неделям

```
# Агрегирование продаж по неделям
weekly_sales = data['Sales'].resample('W').sum()

# Постройте график недельных продаж
plt.figure(figsize=(10, 6))
plt.plot(weekly_sales, label='Weekly Sales')
plt.title('Еженедельные продажи в магазина')
plt.xlabel('Дата')
plt.ylabel('Продажи')
plt.legend()
plt.show()
```

Агрегация продаж по дням

```
# Агрегирование продаж по дням
daily_sales = data['Sales'].resample('D').sum()

# Постройте график ежедневных продаж
plt.figure(figsize=(10, 6))
plt.plot(daily_sales, label='Ежедневные продажи')
plt.title('Ежедневные продажи супермаркета')
plt.xlabel('Дата')
plt.ylabel('Продажи')
plt.legend()
plt.show()
```

Настройка агрегирования

```
# Агрегируем продажи по дням и вычисляем среднее значение
daily_sales_mean = data['Sales'].resample('D').mean()

# Постройте график среднедневных продаж
plt.figure(figsize=(10, 6))
plt.plot(daily_sales_mean, label='Среднедневные продажи')
plt.title('Среднедневные продажи в супермаркете')
plt.xlabel('Дата')
plt.ylabel('Средние продажи')
plt.legend()
plt.show()
```




ВОПРОСЫ





ПРАКТИЧЕСКАЯ РАБОТА



Задание 1



Откройте [файл](#). Разложите временной ряд, агрегированный по месяцам, на составляющие: тренд, сезонность и шум.

Задание 2



Проверьте стационарность временного ряда, агрегированного по месяцам.



ВОПРОСЫ



Заключение

