


Python
for DA

Анализ временных рядов. Продолжение



Преподаватель

Портрет

Имя Фамилия

Текущая должность

Количество лет опыта

Какой у Вас опыт - ключевые кейсы

Самые яркие проекты

Дополнительная информация по вашему усмотрению

Корпоративный e-mail

Социальные сети (по желанию)

Важно

- 

Камера должна быть включена на протяжении всего занятия
- 

В течение занятия вопросы задавать в чате или когда преподаватель спрашивает, есть ли у Вас вопросы
- 

Вести себя уважительно и этично по отношению к остальным участникам занятия
- 

Организационные вопросы по обучению решаются с кураторами, а не на тематических занятиях
- 

Во время занятия будут интерактивные задания, будьте готовы включить камеру или демонстрацию экрана по просьбе преподавателя

Повторение



Временные ряды



Компоненты временных рядов



Стационарность



Автокорреляционные и частичные автокорреляционные функции



Повторная выборка

План занятия

- Прогнозирование
- Модель ARIMA
- Подбор моделей
- Оценка модели ARIMA
- SARIMA
- Введение в Facebook Prophet



ОСНОВНОЙ БЛОК





Прогнозирование



Прогнозирование

Это инструмент, используемый в различных областях для принятия обоснованных решений, планирования будущего и управления рисками.

Цель прогнозирования



Выявить закономерности и тенденции в исторических данных и использовать эту информацию для предсказания будущих результатов

Важность прогнозирования

-  Принятие обоснованных решений
-  Управление ресурсами
-  Финансовое планирование
-  Управление рисками
-  Операционная эффективность
-  Стратегическое планирование

Области применения

Финансы

Бизнес

Здравоохранение

Наука об
окружающей
среде

Энергетика

Анализ фондового
рынка

Курсы валют

Процентные ставки

Области применения

Финансы

Бизнес

Здравоохранение

Наука об
окружающей
среде

Энергетика

Прогнозирование
продаж

Управление
цепочками поставок

Маркетинг

Области применения

Финансы

Бизнес

Здравоохранение

Наука об
окружающей
среде

Энергетика

Вспышки заболеваний

Прием пациентов в
больницах

Распределение
ресурсов

Области применения

Финансы

Бизнес

Здравоохранение

Наука об
окружающей
среде

Энергетика

Прогнозирование
погоды

Климатическое
моделирование

Качество воздуха

Области применения

Финансы

Бизнес

Здравоохранение

Наука об
окружающей
среде

Энергетика

Прогнозирование
нагрузки на
электросети

Возобновляемые
источники энергии



ВОПРОСЫ






Модель ARIMA



Модель ARIMA

Или AutoRegressive Integrated Moving Average - это мощный и универсальный инструмент для прогнозирования временных рядов.

Модель ARIMA



Компонент авторегрессии (AR)



Определение

Авторегрессионный компонент модели ARIMA отражает связь между наблюдением и рядом запаздывающих наблюдений.

Параметр (p)

Количество запаздывающих наблюдений, включенных в модель. Показывает, сколько прошлых значений используется для прогнозирования текущего значения.

Компонент авторегрессии (AR)



Обозначения

AR(p) обозначает модель авторегрессии порядка p .

Пример

В модели AR(1) текущее значение y_t основывается на непосредственно предшествующем значении y_{t-1} . В модели AR(2) текущее значение y_t основывается на двух предыдущих значениях y_{t-1} и y_{t-2} .



Стационарность

Означает, что статистические свойства ряда, такие как среднее значение и дисперсия, постоянны во времени.



Дифференцирование

Это процесс вычитания предыдущего наблюдения из текущего.

Интегральная (I) компонента



Определение

Интегральная компонента предполагает дифференцирование временного ряда, чтобы сделать его стационарным.

Параметр (d)

Количество раз, которое необходимо продифференцировать данные для достижения стационарности.

Интегральная (I) компонента



Обозначения

$I(d)$ обозначает степень дифференцирования.

Пример

Если $d=1$, ряд дифференцируется один раз.
Если $d=2$, то ряд дифференцируется дважды.

Компонент скользящего среднего (МА)



Определение

Компонент скользящего среднего отражает связь между наблюдениями и остаточной ошибкой модели скользящего среднего, примененной к запаздывающим наблюдениям.

Параметр (p)

Количество запаздывающих ошибок прогноза в уравнении прогнозирования. Указывает на то, сколько прошлых членов ошибки используется для прогнозирования текущего значения.

Компонент скользящего среднего (МА)



Обозначения

МА(q) обозначает модель скользящего среднего порядка q .

Пример

В модели МА(1) текущее значение y_{t-1} основывается на члене ошибки, полученном на предыдущем временном шаге e_{t-1} . В модели МА(2) текущее значение y_t основывается на условиях ошибки двух предыдущих временных шагов e_{t-1} и e_{t-2} .

ARIMA(p, d, q)

p

Количество наблюдений с лагом (часть авторегрессии)

d

Количество дифференцированных данных (интегральная часть)

q

Количество запаздывающих ошибок прогноза (часть скользящего среднего)

Пример

Модель ARIMA(2, 1, 1) может быть выражена как:

$$y_t = \alpha + \beta_1 y_{t-1} + \beta_2 y_{t-2} + \theta_1 e_{t-1} + e_t,$$

где y_t - это текущее значение;

α - постоянная величина;

β_1 и β_2 - коэффициенты для наблюдений с запаздыванием;

θ_1 - коэффициент для запаздывающего термина ошибки;

e_t - ошибка в момент времени t .



ВОПРОСЫ





Подбор моделей



statsmodels

Это библиотека, которая предоставляет обширный набор инструментов для подгонки моделей ARIMA.

Шаги для подгонки модели ARIMA



Импорт библиотек и загрузка данных



Подгоните модель ARIMA



Проверить результаты

Подгонка модели ARIMA

```
from statsmodels.tsa.arima.model import ARIMA

# Загрузка данных
data = get_rdataset('AirPassengers', 'datasets').data
data.index = pd.date_range(start = "1949-01", periods = len(data.index), freq =
"ME").to_period()
data.index = data.index.to_timestamp()

# Определите модель ARIMA
model = ARIMA(data['value'], order=(5, 1, 0))

# Подгонка модели
model_fit = model.fit()

# Выведите итоговое значение модели
print(model_fit.summary())
```

Результаты

```

=====
                        SARIMAX Results
=====
Dep. Variable:          value    No. Observations:          144
Model:                  ARIMA(5, 1, 0)    Log Likelihood          -689.067
Date:                   Mon, 03 Jun 2024    AIC                    1390.135
Time:                   18:07:34    BIC                    1407.912
Sample:                 01-01-1949    HQIC                   1397.358
                        - 12-01-1960
Covariance Type:        opg
=====
              coef    std err          z      P>|z|      [0.025    0.975]
-----
ar.L1          0.3223     0.097     3.334     0.001     0.133     0.512
ar.L2         -0.2170     0.078    -2.776     0.006    -0.370    -0.064
ar.L3         -0.0646     0.071    -0.915     0.360    -0.203     0.074
ar.L4         -0.2641     0.075    -3.519     0.000    -0.411    -0.117
ar.L5          0.0250     0.094     0.267     0.790    -0.159     0.209
sigma2        893.7229   113.383     7.882     0.000   671.497   1115.949
=====
Ljung-Box (L1) (Q):          0.00    Jarque-Bera (JB):          0.45
Prob(Q):                    0.97    Prob(JB):                0.80
Heteroskedasticity (H):      8.15    Skew:                    0.12
Prob(H) (two-sided):         0.00    Kurtosis:                3.14
=====

```

Warnings:

[1] Covariance matrix calculated using the outer product of gradients (complex-step).



ВОПРОСЫ





Оценка модели

ARIMA

Оценка модели ARIMA

Метрики

Средняя квадратичная
ошибка (MSE)

Корневая средняя
квадратичная ошибка
(RMSE)



Средняя квадратичная ошибка (MSE)

Измеряет среднее значение квадратичной разницы между предсказанными и фактическими значениями.

Средняя квадратичная ошибка (MSE)



$$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2,$$

где y_i - это фактическое значение в момент времени i ,
 $\hat{y}_i$ - это прогнозируемое значение в момент времени i ,
 n - общее количество наблюдений.

Средняя квадратичная ошибка (MSE)



Преимущества

- Штрафует большие ошибки
- Простота

Недостатки

- Зависимость от масштаба
- Интерпретируемость



Корень средней квадратичной ошибки (RMSE)

Это квадратный корень из MSE. Он позволяет оценить среднюю величину ошибок в тех же единицах, что и исходные данные.

Корень средней квадратичной ошибки (RMSE)



$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$

Корень средней квадратичной ошибки (RMSE)



Преимущества

- Интерпретируемость
- Штрафует большие ошибки

Недостатки

- Зависимость от масштаба
- Чувствительность к выбросам

Пример: оценка модели ARIMA с помощью MSE и RMSE

На примере набора данных AirPassengers продемонстрируем, как построить модель ARIMA и оценить ее эффективность с помощью MSE и RMSE.

Разделение данных

```
# Удаляем невоstreбованный столбец и делим данные на обучающий и тестовый наборы
del data['time']
train_size = int(len(data) * 0.8)
train, test = data[0:train_size], data[train_size:]
```

Подгонка модели ARIMA

```
# Подбор модели ARIMA  
model = ARIMA(train, order=(5, 1, 0))  
model_fit = model.fit()
```

Создание предсказаний

```
# Сделать прогнозы  
predictions = model_fit.forecast(steps=len(test))
```


Расчет MSE и RMSE

```
from sklearn.metrics import mean_squared_error
from math import sqrt
# Вычислить MSE
mse = mean_squared_error(test, predictions)
print('Среднеквадратичная ошибка:', mse)

# Вычислить RMSE
rmse = sqrt(mse)
print('Root Mean Squared Error:', rmse)
```

Построение графика результатов

```
# Постройте график сравнения фактических и прогнозируемых значений
plt.figure(figsize=(10, 6))
plt.plot(test.index, test, label='Actual')
plt.plot(test.index, predictions, label='Predicted', color='red')
plt.title('Фактические и прогнозируемые значения')
plt.xlabel('Дата')
plt.ylabel('Количество пассажиров')
plt.legend()
plt.show()
```



ВОПРОСЫ





SARIMA





SARIMA

Это расширение модели ARIMA, которая явно моделирует сезонный компонент в одномерных данных временных рядов.

SARIMA(p, d, q)(P, D, Q, s)

- p: порядок несезонной авторегрессии
- d: порядок несезонного дифференциала
- q: порядок несезонного скользящего среднего
- P: Порядок сезонной авторегрессии
- D: Порядок сезонного дифференцирования
- Q: Порядок сезонного скользящего среднего
- s: Длина сезонного цикла

Области использования SARIMA

-  Экономика
-  Финансы
-  Розничная торговля
-  Прогнозирование погоды
-  Энергетика
-  Здравоохранение

Пример с использованием предустановленного набора данных

Воспользуемся набором данных `AirPassengers`, который предустановлен в библиотеке `statsmodels`, чтобы продемонстрировать, как построить модель SARIMA.

Подгонка модели SARIMA

```
from statsmodels.tsa.statespace.sarimax import SARIMAX
# Определяем модель SARIMA
model = SARIMAX(data, order=(1, 1, 1), seasonal_order=(1, 1, 1, 12))

# Подгонка модели
model_fit = model.fit(dispatch=False)

# Выведите итоговое значение модели
print(model_fit.summary())
```

Создание предсказаний

```
# Сделать прогнозы
forecast = model_fit.forecast(steps=12)

# Постройте график результатов
plt.figure(figsize=(10, 6))
plt.plot(data, label='Actual')
plt.plot(forecast, label='Forecast', color='red')
plt.title('Прогноз количества авиапассажиров')
plt.xlabel('Дата')
plt.ylabel('Количество пассажиров')
plt.legend()
plt.show()
```



ВОПРОСЫ





Введение в Facebook Prophet



Facebook Prophet

Это библиотека с открытым исходным кодом, предназначенная для прогнозирования временных рядов данных.

Области Prophet

-  Аддитивная модель
-  Автоматическое прогнозирование
-  Настраиваемые прогнозы
-  Надежность

Модель Prophet



$$y(t)=g(t)+s(t)+h(t)+\varepsilon_t,$$

где $g(t)$ представляет собой компонент тренда

$s(t)$ представляет сезонный компонент

$h(t)$ представляет собой эффект праздников

ε_t - ошибка

Пример с использованием предустановленного набора данных

Воспользуемся набором данных `AirPassengers`, который предустановлен в библиотеке `statsmodels`, чтобы продемонстрировать, как подгонять модель `Prophet` и строить прогнозы.

Подгонка модели Prophet

```
from prophet import Prophet

data.reset_index(inplace=True)
data.columns = ['ds', 'y'] # Prophet требует, чтобы столбцы были названы 'ds' (дата) и
'y' (значение).

# Создаем экземпляр Prophet
model = Prophet()

# Подгонка модели к данным
model.fit(data)
```

Создание будущих предсказаний

```
# Создаем фрейм данных для хранения прогнозов
future = model.make_future_dataframe(periods=12, freq='M') # Прогнозирование на 12
месяцев вперед

# Делаем прогнозы
forecast = model.predict(future)
```

Визуализация прогноза

```
# Построить график прогноза
fig1 = model.plot(forecast)
plt.title('Прогноз количества авиапассажиров')
plt.xlabel('Дата')
plt.ylabel('Количество пассажиров')
plt.show()
```

```
# Построить график компонентов прогноза
fig2 = model.plot_components(forecast)
plt.show()
```



ВОПРОСЫ





ПРАКТИЧЕСКАЯ РАБОТА



Задание 1



Используя [данные о продажах машин](#) по месяцам, сделайте прогноз с использованием модели ARIMA.

Задание 2



Используя те же данные о продажах машин по месяцам , сделайте прогноз с использованием модели SARIMA.



ВОПРОСЫ



Домашнее задание

Используйте датасет PRSA_Data_Dingling_20130301-20170228.csv по [ссылке](#).

Объедините прогнозы, полученные с помощью моделей ARIMA, SARIMA и Prophet, чтобы повысить точность предсказаний.

Инструкции:

1. Загрузите набор данных и выберите данные о концентрации PM2.5.
2. Агрегируйте данные по месяцам.
3. Сделайте прогноз на год с помощью моделей ARIMA, SARIMA и Prophet.
4. Объедините прогнозы всех трех моделей (возьмите их среднее арифметическое) и постройте график комбинированного прогноза.

Заключение

