


Python
for DA

Введение в машинное обучение



Преподаватель

Портрет

Имя Фамилия

Текущая должность

Количество лет опыта

Какой у Вас опыт - ключевые кейсы

Самые яркие проекты

Дополнительная информация по вашему усмотрению

Корпоративный e-mail

Социальные сети (по желанию)

Важно

-  Камера должна быть включена на протяжении всего занятия
-  В течение занятия вопросы задавать в чате или когда преподаватель спрашивает, есть ли у Вас вопросы
-  Вести себя уважительно и этично по отношению к остальным участникам занятия
-  Организационные вопросы по обучению решаются с кураторами, а не на тематических занятиях
-  Во время занятия будут интерактивные задания, будьте готовы включить камеру или демонстрацию экрана по просьбе преподавателя

Повторение



Прогнозирование



Модель ARIMA



Подбор моделей



Оценка модели ARIMA



SARIMA



Введение в Facebook Prophet

План занятия

- Что такое машинное обучение? Определение и основные понятия
- Типы машинного обучения: обучение с учителем, обучение без учителя и обучение с подкреплением
- Разделение данных на обучающие и тестовые наборы
- Реализация с помощью функции `train_test_split` из Scikit-Learn



ОСНОВНОЙ БЛОК





Что такое машинное
обучение?



Машинное обучение

область искусственного интеллекта (ИИ), которая занимается разработкой алгоритмов, позволяющих компьютерам обучаться и принимать решения на основе данных. В отличие от традиционного программирования, где компьютеру даются явные инструкции, машинное обучение позволяет системе изучать закономерности и делать прогнозы

Основные определения



Алгоритмы

Это математические модели, которые обрабатывают данные, чтобы найти закономерности и сделать предсказания. К распространенным алгоритмам относятся линейная регрессия, деревья решений и нейронные сети.

Обучающие данные

Это набор данных, используемый для обучения модели машинного обучения. Он включает в себя входные данные и соответствующие выходные метки.

Основные определения



Модель

Модель - это результат работы алгоритма машинного обучения после его обучения на данных. Она может делать прогнозы или принимать решения на основе новых входных данных.

Характеристики

Это отдельные измеряемые свойства или характеристики данных, используемые в модели.

Основные определения



Метки

В обучении с учителем метки - это выходные данные, которые модель обучается предсказывать.

Обучение

Процесс подачи данных в алгоритм машинного обучения, чтобы помочь ему изучить закономерности и взаимосвязи.

Основные определения



Оценка

Оценка эффективности модели с помощью таких показателей, как точность, precision, recall и F1-score.

Оверфиттинг и андерфиттинг

Оверфиттинг происходит, когда модель слишком хорошо усваивает обучающие данные, включая шум и провалы, что делает ее менее эффективной на новых данных. Андерфиттинг происходит, когда модель слишком проста, чтобы уловить основные закономерности в данных.

Различие машинного обучения и программирования

Машинное обучение


- Управляемое данными
- Вероятностное
- Автоматизированное обучение
- Неструктурированные данные

Традиционное программирование

- Основанное на правилах
- Детерминированное
- Ручное обновление
- Структурированные данные


Пример

TRADITIONAL PROGRAMMING



Rule1. Claim time - Submit time < 1 h
Rule2. Agreement review time > 5 m
Rule3. ...

MACHINE LEARNING





ВОПРОСЫ





Типы машинного обучения



Обучение с учителем

Обучение с учителем предполагает обучение модели на наборе данных с метками, где каждая точка данных имеет соответствующую метку или выходное значение. Алгоритм учится сопоставлять входные данные с желаемым выходом, что позволяет ему делать прогнозы для новых, еще невидимых данных.

Ключевые понятия



Маркированные данные



Процесс обучения



Области применения: классификация и регрессия

Распространенные алгоритмы

Классификация

Машины опорных векторов (SVM), логистическая регрессия, деревья решений, Naive Bayes.

Регрессия

Линейная регрессия, полиномиальная регрессия, гребневая регрессия.

Пример



Предсказание того, является ли письмо спамом или нет, на основе таких характеристик, как адрес отправителя, содержание письма и тема письма. Модель обучается на наборе данных писем, помеченных как "спам" или "не спам".



Обучение без учителя

Обучение без учителя предполагает обучение модели на наборе данных без помеченных ответов. Алгоритм пытается найти скрытые закономерности или внутренние структуры в исходных данных.

Ключевые понятия



Немаркированные данные



Обнаружение закономерностей



Области применения: кластеризация и ассоциация

Распространенные алгоритмы

Кластеризация

K-Means Clustering, Hierarchical Clustering, DBSCAN.

Снижение размерности

Анализ главных компонент (PCA), автокодировщики.

Пример



Сегментирование клиентов на различные группы на основе покупательского поведения. Модель анализирует данные, чтобы найти естественные группы клиентов с похожими моделями покупок.



Обучение с подкреплением

Обучение с подкреплением подразумевает обучение агента принимать последовательность решений, взаимодействуя с окружающей средой. Агент учится достигать цели, получая вознаграждения или штрафы в зависимости от своих действий.

Ключевые понятия

-  Агент и среда
-  Вознаграждения и наказания
-  Пробы и ошибки
-  Области применения

Распространенные алгоритмы

Q-Learning

Метод, основанный на ценности, в котором агент узнает ценность действий в состояниях.

SARSA (State-Action-Reward- State-Action)

Аналогичен Q-Learning, но обновляет функцию "действие-ценность" в зависимости от выполненного действия.

Глубокие Q-сети (DQN)

Сочетает Q-Learning с глубокими нейронными сетями для работы с высокоразмерными пространствами состояний.

Пример



Обучение робота перемещению по лабиринту. Робот получает вознаграждение за достижение конца лабиринта и штрафы за столкновение со стенами. Со временем он учится оптимальному пути к цели.



ВОПРОСЫ





Важность разделения данных



Разделение данных на обучающие и тестовые наборы

Фундаментальная практика машинного обучения, которая обеспечивает разработку надежных и достоверных моделей

Основные причины для разделения

-  Оценка модели и оценка производительности
-  Предотвращение оверфиттинга
-  Обеспечение беспристрастной оценки
-  Настройка гиперпараметров и выбор модели
-  Моделирование сценариев реального мира
-  Перекрестная валидация для повышения надежности



ВОПРОСЫ





Реализация с
помощью функции



Scikit-learn

популярная библиотека Python для машинного обучения, предоставляет удобную функцию `train_test_split` для выполнения такого разделения данных.

Шаг 1: Импорт необходимых библиотек

```
from sklearn.model_selection import train_test_split  
from sklearn.datasets import load_iris  
import matplotlib.pyplot as plt
```

Шаг 2: Загрузка набора данных

```
# Загрузить набор данных Iris
iris = load_iris()
X = iris.data # Характеристики
y = iris.target # Метки
```

Шаг 3: Выполните разбиение

```
# Разделить данные на обучающий и тестовый наборы  
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_state=42)
```

Шаг 4: Проверка разбиения

```
print(f"Размер обучающих данных (X_train): {X_train.shape}")  
print(f"Размер тестовых данных (X_test): {X_test.shape}")  
print(f"Размер обучающих меток (y_train): {y_train.shape}")  
print(f"Размер тестовых меток (y_test): {y_test.shape}")
```

Пример вывода

Размер обучающих данных (X_train): (120, 4)

Размер тестовых данных (X_test): (30, 4)

Размер обучающих меток (y_train): (120,)

Размер тестовых меток (y_test): (30,)

Шаг 5. Изображение выборки

```
fig, axs = plt.subplots(nrows= 1 , ncols= 3 )

axs[0].boxplot(X)
axs[0].title.set_text("Все данные")
axs[1].boxplot(X_train)
axs[1].title.set_text("Тренировочные")
axs[2].boxplot(X_test)
axs[2].title.set_text("Тестовые")
plt.show()
```



Стратифицированное разделение обучения и тестирования

Для задач классификации часто важно сохранить одинаковое распределение классов в обучающем и тестовом наборах. Этого можно добиться с помощью параметра `stratify`.

Применение параметра stratify

```
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2,  
random_state=42, stratify=y)
```

Визуализация

```
fig, axs = plt.subplots(nrows= 1 , ncols= 3 )

axs[0].boxplot(X)
axs[0].title.set_text("Все данные")
axs[1].boxplot(X_train)
axs[1].title.set_text("Тренировочные")
axs[2].boxplot(X_test)
axs[2].title.set_text("Тестовые")
plt.show()
```



Разделение на обучение-валидацию-тестирование

В некоторых случаях для настройки гиперпараметров полезно иметь отдельный валидационный набор. Это можно сделать, сначала разделив данные на обучающий и временный наборы, а затем разделив временный набор на валидационный и тестовый наборы.

Реализация

```
# Первоначальное разбиение на обучающий и временный наборы
X_train, X_temp, y_train, y_temp = train_test_split(X, y, test_size=0.4,
random_state=42)

# Дальнейшее разбиение временного набора на валидационный и тестовый наборы
X_val, X_test, y_val, y_test = train_test_split(X_temp, y_temp, test_size=0.5,
random_state=42)
```

Визуализация

```
fig, axs = plt.subplots(nrows= 1 , ncols= 4 )

axs[0].boxplot(X)
axs[0].title.set_text("Все данные")
axs[1].boxplot(X_train)
axs[1].title.set_text("Тренировочные")
axs[2].boxplot(X_test)
axs[2].title.set_text("Тестовые")
axs[3].boxplot(X_val)
axs[3].title.set_text("Валидационные")
plt.show()
```



ВОПРОСЫ





ПРАКТИЧЕСКАЯ РАБОТА



Задание 1



Набор данных Digits состоит из изображений 8x8 рукописных цифр. Каждое изображение представлено в виде плоского массива из 64 пикселей, а целевой вектор состоит из цифр, которые представляет каждое изображение (от 0 до 9). Задача состоит в том, чтобы разделить этот набор данных на обучающий и тестовый наборы.

Решение

```
from sklearn.datasets import load_digits
from sklearn.model_selection import train_test_split

digits = load_digits()
X, y = digits.data, digits.target

X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2,
random_state=42, stratify=y)
print(f"Размер обучающих данных (X_train): {X_train.shape}")
print(f"Размер тестовых данных (X_test): {X_test.shape}")
print(f"Размер обучающих меток (y_train): {y_train.shape}")
print(f"Размер тестовых меток (y_test): {y_test.shape}")
```

Задание 2



Набор данных Wine содержит результаты химического анализа вин, выращенных в одном и том же регионе Италии, но полученных из трех разных сортов. Задача состоит в том, чтобы разделить этот набор данных на обучающий и тестовый наборы.

Решение

```
from sklearn.datasets import load_wine
from sklearn.model_selection import train_test_split

wine = load_wine()
X, y = wine.data, wine.target

X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2,
                                                    random_state=42, stratify=y)
print(f"Размер обучающих данных (X_train): {X_train.shape}")
print(f"Размер тестовых данных (X_test): {X_test.shape}")
print(f"Размер обучающих меток (y_train): {y_train.shape}")
print(f"Размер тестовых меток (y_test): {y_test.shape}")
```

Задание 3



Набор данных Breast Cancer содержит признаки, вычисленные по оцифрованным изображениям ядер клеток рака молочной железы. Задача состоит в том, чтобы разделить этот набор данных на обучающий и тестовый наборы.

Решение

```
from sklearn.datasets import load_breast_cancer
from sklearn.model_selection import train_test_split

breast_cancer = load_breast_cancer()
X, y = breast_cancer.data, breast_cancer.target

X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2,
random_state=42, stratify=y)
print(f"Размер обучающих данных (X_train): {X_train.shape}")
print(f"Размер тестовых данных (X_test): {X_test.shape}")
print(f"Размер обучающих меток (y_train): {y_train.shape}")
print(f"Размер тестовых меток (y_test): {y_test.shape}")
```



ВОПРОСЫ



Заключение

