

Python
for DA

Revision. Статистика



Преподаватель

Портрет

Имя Фамилия

Текущая должность

Количество лет опыта

Какой у Вас опыт - ключевые кейсы

Самые яркие проекты

Дополнительная информация по вашему усмотрению

Корпоративный e-mail

Социальные сети (по желанию)

Важно

- 

Камера должна быть включена на протяжении всего занятия
- 

В течение занятия вопросы задавать в чате или когда преподаватель спрашивает, есть ли у Вас вопросы
- 

Вести себя уважительно и этично по отношению к остальным участникам занятия
- 

Организационные вопросы по обучению решаются с кураторами, а не на тематических занятиях
- 

Во время занятия будут интерактивные задания, будьте готовы включить камеру или демонстрацию экрана по просьбе преподавателя

Повторение



Основы построения графиков с помощью Matplotlib



Настройка графиков



Подграфики



Основы построения графиков с Seaborn



Парные графики и тепловые карты в Seaborn

План занятия

- Виды статистик
- Меры центральной тенденции
- Меры дисперсии
- Проверка гипотез
- Доверительные интервалы



ОСНОВНОЙ БЛОК





Виды статистик



Статистика

Это отрасль математики, которая занимается сбором, анализом, интерпретацией, представлением и организацией данных.



Описательная статистика

Обобщает и описывает основные характеристики набора данных. Они предоставляют простые сводки о выборке и показателях.

Основные компоненты описательной статистики

Меры центральной
тенденции

Среднее значение

Медиана

Мода

Меры
изменчивости
(дисперсии)

Диапазон

Дисперсия

Стандартное
отклонение

Частотное
распределение

Гистограммы

Столбчатые
диаграммы

Круговые
диаграммы

Форма
распределения

Перекос

Экссесс

Примеры описательной статистики



Вычисление среднего тестового балла студентов в классе.



Использование гистограммы для отображения распределения возрастов в генеральной совокупности.



Обобщение результатов опроса с помощью среднего значения, медианы и моды.



Инференциальная статистика

Используется для того, чтобы делать выводы или обобщения о генеральной совокупности на основе выборки данных.

Основные компоненты инференциальной статистики



Примеры инференциальной статистики



Использование выборочного обследования для оценки среднего дохода населения.



Проведение t-теста, чтобы определить, существует ли значительная разница между средними показателями двух групп.



Проведение регрессионного анализа для прогнозирования будущих продаж на основе прошлых данных.



ВОПРОСЫ





Меры центральной тенденции



Меры центральной тенденции

Это статистические показатели, которые описывают центральную точку или типичное значение набора данных.

Среднее



Определение

Это сумма всех значений в наборе данных, деленную на количество значений.

Пример

```
import numpy as np

data = [1, 2, 3, 4, 5]
mean = np.mean(data)
print("Среднее:", mean)
```

Медиана



Определение

Это среднее значение набора данных, упорядоченное от наименьшего к наибольшему.

Пример

```
import numpy as np

data = [1, 2, 3, 4, 5]
median = np.median(data)
print("Медиана:", median)
```

Мода



Определение

Это значение, которое чаще всего встречается в наборе данных.

Пример

```
from scipy import stats

data = [1, 1, 2, 3, 4, 6, 18]
mode_result = stats.mode(data)
mode = mode_result.mode
print("Мода:", mode)
```

Пример



Вычисление среднего, медианы и моды с помощью Python SciPy.

Набор данных

```
data = [99, 86, 87, 88, 111, 86, 103, 87, 94, 78, 77, 85, 86]
```

Вычисление среднего значения

```
import numpy as np

mean = np.mean(data)
print("Среднее:", mean)
```

Вычисление медианы

```
median = np.median(data)  
print("Медиана:", median)
```


Вычисление моды

```
from scipy import stats

mode_result = stats.mode(data)
mode = mode_result.mode
print("Мода:", mode)
```



ВОПРОСЫ





Меры дисперсии



Меры дисперсии

Это статистические инструменты, используемые для описания разброса или изменчивости в наборе данных.

Диапазон



Определение

Это самая простая мера дисперсии.

Пример

```
data = [4, 8, 6, 5, 3, 2, 8, 9, 2, 5]
range_value = max(data) - min(data)
print("Диапазон:", range_value)
```

Вариация



Определение

Это среднее квадратичное отклонение каждой точки данных от среднего значения.

Пример

```
import numpy as np

data = [4, 8, 6, 5, 3, 2, 8, 9, 2, 5]
variance = np.var(data)
print("Вариация:", variance)
```

Стандартное отклонение



Определение

Это квадратный корень из дисперсии.

Пример

```
import numpy as np

data = [4, 8, 6, 5, 3, 2, 8, 9, 2, 5]
std_deviation = np.std(data)
print("Стандартное отклонение:",
      std_deviation)
```

Пример



Вычисление диапазона, дисперсии и стандартного отклонения с помощью Python

Набор данных

```
data = [99, 86, 87, 88, 111, 86, 103, 87, 94, 78, 77, 85, 86]
```

Вычисление диапазона

```
range_value = max(data) - min(data)  
print("Диапазон:", range_value)
```

Вычисление дисперсии

```
variance = np.var(data)  
print("Вариация:", variance)
```

Вычисление стандартного отклонения

```
std_deviation = np.std(data)  
print("Стандартное отклонение:", std_deviation)
```



ВОПРОСЫ





Проверка гипотез



Проверка гипотез

Это статистический метод, используемый для того, чтобы сделать выводы о совокупности на основе выборочных данных.

Нулевая гипотеза



Определение

Это утверждение об отсутствии эффекта или различий, представляющее собой статус-кво или базовое предположение.

Пример

Если мы проверяем, является ли монета честной, нулевая гипотеза может состоять в том, что вероятность выпадения решек равна 0,5.

Альтернативная гипотеза



Определение

Это утверждение, противоречащее нулевой гипотезе. Она представляет собой эффект или разницу, которую исследователь стремится обнаружить.

Пример

Для теста на честность монеты альтернативная гипотеза может заключаться в том, что вероятность выпадения решек не равна 0,5.

Шаги при проверке гипотез

1. Сформулируйте нулевую и альтернативную гипотезы.
2. Выберите уровень значимости (α), - это вероятность отвергнуть нулевую гипотезу, если она верна. Обычно выбирают 0,05, 0,01 и 0,10.
3. Выберите статистический тест в зависимости от типа данных и гипотезы. К распространенным тестам относятся t-тесты, тесты хи-квадрат, ANOVA и регрессионный анализ.
4. Соберите данные, которые будут анализироваться в тесте.
5. На основе собранных данных и выбранного теста рассчитайте тестовую статистику, которая отражает, насколько наблюдаемые данные отклоняются от нулевой гипотезы.
6. Определите р-значение - это вероятность того, что результаты теста будут не менее экстремальными, чем наблюдаемые результаты, при условии, что нулевая гипотеза верна.
7. Сравните р-значение с выбранным уровнем значимости:
 - Если $p\text{-значение} \leq \alpha$: Отклоните нулевую гипотезу.
 - Если $p\text{-значение} > \alpha$: Не отвергайте нулевую гипотезу.
8. Представьте результаты проверки гипотез, включая тестовую статистику, р-значение и вывод о гипотезах.



t-тест

Используется для сравнения средних значений двух групп.

Пример t-теста

```
from scipy import stats

# Данные выборки
data1 = [1, 2, 3, 4, 5]
data2 = [6, 7, 8, 9, 10]

# Выполните t-тест
t_statistic, p_value = stats.ttest_ind(data1, data2)

print('t-статистика:', t_statistic)
print('p-value:', p_value)
```



Тест хи-квадрат

Используется для определения наличия значимой связи между двумя категориальными переменными.

Пример теста хи-квадрат

```
from scipy.stats import chi2_contingency
import numpy as np

# Таблица контингентности
data = np.array([[207, 282, 241], [234, 242, 232]])

# Выполните тест хи-квадрат
chi2, p, dof, expected = chi2_contingency(data)

print('Статистика хи-квадрат:', chi2)
print('p-значение:', p)
print('Степени свободы:', dof)
print('Ожидаемые частоты:', expected)
```



ВОПРОСЫ





Доверительные интервалы



Доверительный интервал

Это диапазон значений, полученный на основе выборочных данных, который, скорее всего, содержит истинное значение неизвестного параметра генеральной совокупности.

Ключевые понятия



Уровень доверия



Предел погрешности

Пример



Вычисление доверительных интервалов с помощью Python

Импорт библиотек

```
import numpy as np  
from scipy import stats
```

Определение выборочных данных

```
data = [99, 86, 87, 88, 111, 86, 103, 87, 94, 78, 77, 85, 86]
```

Вычисление выборочного среднего и стандартного отклонения

```
sample_mean = np.mean(data)
sample_std = np.std(data, ddof=1) # ddof=1 для выборочного стандартного отклонения
n = len(data)
```

Определение Z-значения для 95-процентного уровня доверия

```
confidence_level = 0.95  
alpha = 1 - confidence_level  
z_value = stats.norm.ppf(1 - alpha/2)
```

Вычисление предела ошибки

```
margin_of_error = z_value * (sample_std / np.sqrt(n))
```


Расчет доверительного интервала

```
confidence_interval = (sample_mean - margin_of_error, sample_mean + margin_of_error)
print("95% доверительный интервал:", confidence_interval)
```



ВОПРОСЫ





ПРАКТИЧЕСКАЯ РАБОТА



Задание

1. Определите, значительно ли отличается средний рост выборки студентов от известного среднего роста генеральной совокупности. Известно, что средний рост студентов в определенной генеральной совокупности составляет 170 см. У вас есть выборка из 10 студентов со следующим ростом (в см): [172, 168, 171, 169, 170, 173, 167, 174, 175, 169].
2. Сравните средние тестовые баллы двух разных классов, чтобы увидеть, есть ли значительная разница. У вас есть результаты тестов двух классов:
 - Класс А: [85, 88, 90, 92, 87, 85, 89, 91, 90, 86]
 - Класс В: [78, 82, 84, 79, 81, 80, 83, 85, 84, 82]
3. Определите, существует ли значимая связь между полом и предпочтением нового продукта. Был проведен опрос с целью выяснить, существует ли связь между полом и предпочтениями в отношении нового продукта. Результаты оказались следующими:
 - Мужчины, которым нравится продукт: 30
 - Мужчины, которым продукт не нравится: 20
 - Женщины, которым нравится продукт: 25
 - Женщины, которым не нравится продукт: 25



ВОПРОСЫ



Домашнее задание

1. Создайте многопанельный график, используя набор данных Iris. График должен включать:
 - Диаграмма рассеяния длины чашелистика по сравнению с шириной чашелистика на первой панели.
 - График разброса длины лепестка по ширине лепестка на второй панели.
 Обе панели должны иметь одинаковые границы по оси x и оси y.
2. Создайте тепловую карту корреляционной матрицы набора данных Tips. Аннотируйте тепловую карту значениями корреляции и используйте пользовательскую палитру расходящихся цветов.
3. Проверьте, значительно ли отличается средняя длина лепестка у видов Iris setosa от 1,5 см.

Заключение

