

Стать IT-шником может каждый



Python DA Summary 4



Преподаватель



Ваше фото

ИМЯ ФАМИЛИЯ

Текущая должность

Количество лет опыта

Какой у Вас опыт - ключевые кейсы

Самые яркие проекты

Дополнительная информация по вашему усмотрению

Корпоративный e-mail

Социальные сети (по желанию)



ВАЖНО!

- Камера должна быть включена на протяжении всего занятия.
- Если у Вас возник вопрос в процессе занятия, пожалуйста, поднимите руку и дождитесь, пока преподаватель закончит мысль и спросит Вас, также можно задать вопрос в чате или когда преподаватель скажет, что начался блок вопросов.
- Организационные вопросы по обучению решаются с кураторами, а не на тематических занятиях.
- Вести себя уважительно и этично по отношению к остальным участникам занятия.
- Во время занятия будут интерактивные задания, будьте готовы включить микрофон или демонстрацию экрана по просьбе преподавателя.

ПЛАН ЗАНЯТИЯ

Повторение изученного за неделю
Вопросы по повторению
Разбор домашних заданий
Вопросы по разбору заданий
Задание для закрепления
Оставшиеся вопросы



Стать IT-шником может каждый



ПОВТОРЕНИЕ ИЗУЧЕННОГО



Временные ряды и графики дат

```
dates = pd.date_range('20240101', periods=6)  
values = [1, 3, 2, 5, 0, 4]
```

```
plt.plot(dates, values)  
plt.show()
```

Экспресс-опрос




Что такое colormaps?





Цветовые карты (colormaps) —

это мощный инструмент для визуализации данных, позволяющий отображать трехмерные данные в двухмерном формате с использованием цвета. Интенсивность цвета отображает количество значений в интервале.



Цветовые карты

```
x = np.random.randn(1000)
y = np.random.randn(1000)
plt.hexbin(x, y, gridsize=30, cmap='Blues')
cb = plt.colorbar()
cb.set_label('intensity')
plt.show()
```

Экспресс-опрос




Какие возможности предоставляет Matplotlib для создания и настройки тепловых карт?





Тепловые карты —

это инструмент для визуализации данных, полезный для визуализации матрицы данных, где цвета представляют значения. Это может быть полезно для отображения корреляции или интенсивности.



Тепловые карты

```
data = np.random.rand(10, 10)
plt.imshow(data, cmap='hot', interpolation='nearest')
plt.colorbar()
plt.show()
```

Экспресс-опрос



Что такое plt.figure()?




Полезно знать



plt.figure() —


это функция, которая используется для создания новой фигуры.





`plt.subplot()` —

это функция, которая используется для добавления подграфиков в фигуру.



Параметры subplot

Количество строк

Количество столбцов

**Порядковый номер текущего
рисунка**

Пример

```
# Линейная зависимость
x = np.linspace(0, 10, 50)
y1 = x
# Квадратичная зависимость
y2 = [i**2 for i in x]
# Построение графиков
plt.figure(figsize=(9, 9))
plt.subplot(2, 1, 1)
plt.plot(x, y1)          # построение графика
plt.title(r"Зависимость $y_1 = x$") # заголовок
plt.ylabel(r"$y_1$", fontsize=14) # ось ординат
plt.grid(True)          # включение отображение сетки
plt.subplot(2, 1, 2)
plt.plot(x, y2)          # построение графика
plt.title(r"Зависимость $y_2 = x^2$") # заголовок
plt.xlabel("x", fontsize=14) # ось абсцисс
plt.ylabel(r"$y_2$", fontsize=14) # ось ординат
plt.grid(True)          # включение отображение сетки
plt.show()
```

Экспресс-опрос




Что такое `twinx()`?





`twinx()` —

это метод, который используется для создания второго подграфика, если два подграфика одного рисунка имеют общую ось X, но разные оси Y.



Пример

```
month = ['янв','фев','март','апр','май','июнь','июль','авг','сен','окт','ноя','дек']  
temp = [1.8, 1.8, 4.8, 9.0, 14.0, 18.8, 19.8, 19.6, 15.0, 10.0, 5.0, 2.0]  
prec = [56, 41, 53, 42, 60, 67, 81, 62, 56, 49, 48, 54]
```

```
plt.figure()  
ax1 = plt.subplot()
```

```
ax1.set_xlabel('Month')  
ax1.set_ylabel(r'Temperature, $\degree$C', color='red')  
ax1.plot(month, temp, color='red')  
ax1.tick_params(axis='y', labelcolor='red')
```

```
ax2 = ax1.twinx()  
ax2.set_ylabel('Precipitation, mm', color='blue')  
ax2.plot(month, prec, color='blue')  
ax2.tick_params(axis='y', labelcolor='blue')
```

```
plt.show()
```

Экспресс-опрос




Что такое axes()?





axes() —

это функция, которая создает оси в заданном прямоугольнике. Вся площадь рисунка описывается прямоугольником $[0, 0, 1, 1]$. Добавление новых функций axes() с другими параметрами создает подфигуру с собственным графиком.



Пример

```
# Основной график  
plt.axes([0, 0, 1, 1])  
plt.plot(range(10), color='red')  
plt.title('Основной график')  
  
# Вложенный график  
plt.axes([0.2, 0.6, 0.25, 0.25])  
plt.plot(range(10), color='blue')  
plt.title('Вложенный график')  
plt.show()
```

Экспресс-опрос



Какие типы 3D графиков можно создать с помощью Matplotlib и какие модули для этого необходимы?




Полезно знать



matplotlib —

это модуль, который позволяет создавать трехмерных графиков: 3D-поверхности, 3D-линии и 3D-точечные графики.



Пример

```
from mpl_toolkits.mplot3d import Axes3D

fig = plt.figure()
ax = fig.add_subplot(111, projection='3d')
X = np.arange(-5, 5, 0.25)
Y = np.arange(-5, 5, 0.25)
X, Y = np.meshgrid(X, Y) #создаем матрицу из всех возможных комбинаций X и Y
Z = np.sin(np.sqrt(X**2 + Y**2))

surf = ax.plot_surface(X, Y, Z, cmap='viridis')
fig.colorbar(surf)
ax.can_zoom()
plt.show()
```

Стать IT-шником может каждый



Экспресс-опрос




Что такое контурные графики?





Контурные графики —

это графики, которые полезны для визуализации трехмерных данных в двух измерениях. Они могут помочь выявить потенциальные уровни или границы в наборе данных.



Пример


```
X = np.arange(-5, 5, 0.25)
Y = np.arange(-5, 5, 0.25)
X, Y = np.meshgrid(X, Y)
Z = np.sin(np.sqrt(X**2 + Y**2))

plt.contourf(X, Y, Z, cmap='viridis')
plt.colorbar()
plt.show()
```



Basemap или Cartopy —

[это библиотеки](#), которые используются в сочетании с Matplotlib, для визуализации географических данных на картах.



Пример

```
%matplotlib widget
import cartopy.crs as ccrs
import cartopy.feature as cfeature

plt.figure(figsize=(10, 5))
ax = plt.axes([0, 0, 1, 1], projection=ccrs.PlateCarree())
ax.add_feature(cfeature.LAND) # отображение суши
ax.add_feature(cfeature.OCEAN) # отображение океанов
ax.add_feature(cfeature.COASTLINE) # отображение береговой линии
ax.add_feature(cfeature.BORDERS) # отображение границ стран
ax.add_feature(cfeature.LAKES, alpha=0.5) # отображение озер
ax.add_feature(cfeature.RIVERS) # отображение рек
ax.add_feature(cfeature.STATES) # отображение границ штатов США
plt.show()
```

Стать IT-шником может каждый




ВОПРОСЫ





Визуализация данных в pandas —

это простой и удобный способ создавать базовые графики непосредственно из объектов DataFrame и Series. Основана на библиотеке Matplotlib и позволяет быстро получать графическое представление данных без необходимости переходить к более специализированным инструментам визуализации.



Создание датафрейма

```
df = pd.DataFrame(np.random.randn(10, 4), columns=['A', 'B', 'C', 'D'])
```

Экспресс-опрос



Что такое `.plot()`?




Полезно знать



`.plot()` —

это метод, который поддерживает различные типы графиков через аргумент `kind`.



Типы графиков, поддерживаемых через аргумент kind

Типы	Пояснение
'line' (линии)	По умолчанию для индексированных данных
'bar' и 'barh' (вертикальные и горизонтальные столбцы)	Для сравнения значений нескольких групп
'hist' (гистограмма)	Для визуализации распределения данных
'box' (ящик с усами)	Для отображения распределения по квартилям
'scatter' (точечная диаграмма)	Для визуализации взаимосвязей между двумя числовыми переменными
'area' (площадь)	Для стековых диаграмм, показывающих суммированное значение по времени или другим переменным
'pie' (круговая диаграмма)	Для отображения долевого соотношения категорий

Метод .plot()

```
df['A'].plot(kind='hist')  
plt.show()
```

Настройка внешнего вида графиков

```
df.plot(kind='scatter', x='A', y='B', color='red', label='Group 1')  
plt.title('Scatter Plot')  
plt.xlabel('X axis')  
plt.ylabel('Y axis')  
plt.legend()  
plt.show()
```

Экспресс-опрос




Что такое `.groupby()`?





.groupby() —

это метод, который позволяет группировать данные по одной или нескольким переменным и визуализировать агрегированные результаты.




Визуализация с использованием группировки

```
df = pd.DataFrame({'A': np.random.randint(1, 5, 10),  
                  'B': np.random.rand(10)})  
df.groupby('A').sum().plot(kind='bar')  
plt.show()
```



Создание сложных макетов —

это создание макетов с несколькими графиками, pandas может быть использован в сочетании с Matplotlib, предоставляя возможность точной настройки расположения графиков.



Визуализация с использованием группировки

```
fig, axes = plt.subplots(figsize=(9, 9), nrows=2, ncols=1) # эта функция объединяет plt.figure() и  
plt.subplot()  
df['A'].plot(ax=axes[0], kind='line', title='Line Plot')  
df['B'].plot(ax=axes[1], kind='bar', title='Bar Plot')  
plt.show()
```

Стать IT-шником может каждый



Экспресс-опрос




Что такое стековые графики?





Стековые графики —

это **графики**, которые позволяют визуализировать части целого, распределяя значения по категориям в форме стека. Полезны для сравнения пропорций во времени.



Стековые графики

```
df.plot(kind='area')  
plt.title('Stacked Area Plot')  
plt.show()
```

Стать IT-шником может каждый



Экспресс-опрос




Что такое by?





by —

это параметр, который используется в методе `.plot()` и позволяет создавать графики с разбивкой по определенной категории, что позволяет сравнивать подгруппы данных.



Параметр by

```
df['C'] = np.random.choice(['Category 1', 'Category 2'], size=10)
df.plot(kind="hist", figsize=(9, 9), column='B', by='C')
plt.show()
```

Экспресс-опрос




Что такое scatter_matrix?





scatter_matrix —

это функция, которая используется для визуализации попарных отношений между несколькими переменными в DataFrame. Создает матрицу из графиков рассеяния для каждой пары переменных.



Парные графики и матрицы рассеяния

```
from pandas.plotting import scatter_matrix
df_new = pd.DataFrame({'A': np.random.normal(size=2000),
                       'B': np.random.uniform(size=2000)})
scatter_matrix(df_new, figsize=(10, 10))
plt.show()
```

Набор данных


[Датасет Титаник](#)

Загрузить датасет

```
df = pd.read_csv('titanic.csv')  
df.head()
```


Распределение выживших и невыживших пассажиров среди тех, билет которых стоил менее 50 единиц

```
%matplotlib inline  
df[df.Fare < 50].plot.scatter(x='Fare', y='Survived')
```



Распределение выживших и неживших в зависимости от цены билета


```
df.groupby('Survived').Fare.plot(kind="hist", alpha=0.5)  
plt.xlim(0, 150)  
plt.legend()  
plt.show()
```





Ядерная оценка плотности (kde) —

это способ представления распределения данных,
основанный на идее сглаживания гистограммы.



Ядерная оценка плотности (kde)

```
df.groupby('Survived').Fare.plot(kind="kde")  
plt.xlim(0, 150)  
plt.legend()  
plt.show()
```

Распределение цены

```
ax = df.Fare.plot.hist()  
ax.set_title('Visualization')  
plt.show()
```

Стать IT-шником может каждый



ВОПРОСЫ



Импорт библиотеки

```
import seaborn as sns
```

Экспресс-опрос




Что такое seaborn?





Seaborn —

это мощная библиотека для визуализации данных в Python, построенная на основе Matplotlib. Она предоставляет высокоуровневый интерфейс для создания привлекательных и информативных статистических графиков.



Экспресс-опрос




Какие функции seaborn позволяют визуализировать распределение одной переменной?





distplot (displot и histplot) —

это функция, которая позволяет визуализировать распределение переменной, включая гистограмму и KDE (ядерная оценка плотности).



Функция distplot

```
x = np.random.randn(100)  
sns.histplot(x, kde=True)
```

Экспресс-опрос




Что такое jointplot?





jointplot —

это функция, которая создает многопанельный график, показывающий распределения двух переменных и их взаимосвязь.



Функция jointplot

```
data = pd.DataFrame({'x': np.random.randn(100), 'y': np.random.randn(100)})  
sns.jointplot(x='x', y='y', data=data, kind='scatter')
```

Экспресс-опрос



Что такое kdeplot?




Полезно знать



kdeplot —

это функция, которая позволяет визуализировать распределение данных с помощью ядерной оценки плотности, включая многомерные распределения.



Функция kdeplot

```
sns.kdeplot(data=tips, x="total_bill", y="tip", hue="time")
```

Экспресс-опрос



Что такое barplot?





barplot —

это график, который показывает среднее значение по категориям с помощью столбцов и дает понимание о дисперсии данных через ошибки.




График barplot

```
tips = sns.load_dataset("tips")  
sns.barplot(x="day", y="total_bill", data=tips)
```



boxplot —

это график, который визуализирует распределение категориальных данных и выделяет выбросы.




График barplot

```
sns.boxplot(x="day", y="total_bill", data=tips)
```

Экспресс-опрос




Как с помощью seaborn создать график, показывающий взаимосвязь между двумя переменными?





scatterplot —

это функция, которая позволяет реализовать классический способ для визуализации взаимосвязи между двумя непрерывными переменными.



Функция scatterplot

```
sns.scatterplot(x="total_bill", y="tip", data=tips)
```

Экспресс-опрос



Что такое lineplot?




Полезно знать



lineplot —

это функция, которая полезна для визуализации временных рядов или зависимостей между двумя непрерывными переменными.



Функция lineplot

```
sns.lineplot(x="total_bill", y="tip", data=tips)
```

Экспресс-опрос




Что такое pairplot?





pairplot —

это функция, которая отображает попарные отношения в наборе данных и распределение каждой переменной на диагонали.



Функция pairplot

```
sns.pairplot(tips)
```

Экспресс-опрос



Что такое heatmap?




Полезно знать



heatmap —

это функция, которая позволяет визуализировать матрицы корреляции или других двумерных данных.



Функция heatmap

```
corr = tips.corr()  
sns.heatmap(corr, annot=True)
```

Экспресс-опрос




Что такое regplot и lmpplot?





regplot и Implot —

это функции, которые позволяют визуализировать линейную зависимость между двумя переменными и оценить регрессионную модель.



Функции regplot и lmpplot

```
sns.regplot(x="total_bill", y="tip", data=tips)
```

Стать IT-шником может каждый



Экспресс-опрос




Что такое FacetGrid?





FacetGrid —

это функция, которая позволяет построить решетку графиков, основанную на распределении категориальной переменной. Это полезно для сравнения подгрупп данных.



Функции FacetGrid

```
g = sns.FacetGrid(tips, col="time", row="smoker")  
g.map(sns.scatterplot, "total_bill", "tip")
```

Экспресс-опрос



Что такое catplot?




Полезно знать



catplot —

это функция, которая используется для построения различных типов категориальных графиков, включая точечные, столбчатые и скрипичные диаграммы.



Функции catplot

```
sns.catplot(x="day", y="total_bill", hue="smoker", kind="violin", data=tips)
```

Настройка стилей

```
sns.set_style("whitegrid")  
sns.set_context("talk")
```

Экспресс-опрос



Что такое set_theme?




Полезно знать



set_theme —

[это функция](#), которая используется для настройки глобального внешнего вида всех графиков.



Функции set_theme

```
sns.set_theme(style="darkgrid")
```

Стать IT-шником может каждый



Экспресс-опрос



Что такое palette?




Полезно знать



palette —

это функция-параметр в функциях визуализации для выбора схемы цветов.



Функции palette

```
sns.set_palette("pastel")
```


Экспресс-опрос



Что такое sns.palplot?




Полезно знать



sns.palplot —

это функция, которая позволяет визуализировать используемую палитру.



Стать IT-шником может каждый



Типы палитр

Последовательные (sequential)

```
sns.palplot(sns.color_palette('viridis', n_colors=10))  
sns.palplot(sns.color_palette('magma', n_colors=10))  
sns.palplot(sns.color_palette('inferno', n_colors=10))
```

Расходящиеся (diverging)

```
sns.palplot(sns.color_palette('coolwarm', n_colors=10))  
sns.palplot(sns.color_palette('rainbow', n_colors=10))
```

Категориальные (qualitative)

```
sns.palplot(sns.color_palette('muted', n_colors=10))  
sns.palplot(sns.color_palette('Set2', n_colors=10))
```

Установка эстетических параметров графиков

```
sns.set(context='notebook', style='darkgrid', palette='deep', font='sans-serif', font_scale=1,  
color_codes=False, rc=None)
```

Установка эстетических параметров графиков

Параметр	Пояснение
context	Параметр контекста, влияет на размер меток, линий и других элементов, но не на общий стиль. Контекст: notebook, paper, talk, poster
style	Стиль осей: darkgrid (серый фон с сеткой), whitegrid (белый фон с сеткой), dark (серый фон без сетки), white (белый фон без сетки), ticks
palette	Цветовая палитра: deep, muted, bright, pastel, dark, colorblind, а так же палитры из matplotlib
font	Шрифт текста
font_scale	Масштабирование размера текста

Вид графиков для разных контекстов

```
plt.figure(figsize=(15, 9))
for i, context in enumerate(['notebook', 'paper', 'talk', 'poster']):
    sns.set(context=context) # Устанавливаем стиль
    plt.subplot(2, 2, i+1)
    sinplot()
    plt.title(context)
```

Убрать рамку вокруг картинки

```
sns.despine(fig=None, ax=None, top=True, right=True, left=False, bottom=False, offset=None, trim=False)
```

Убрать рамку вокруг картинки

Параметр	Пояснение
fig	Фигура matplotlib. Если None, то текущая
top, right, left, bottom	Указатели границ. Левую и нижнюю оставляют, т.к. вдоль них расположены метки на координатных осях.

Убрать рамку вокруг картинки

```
sns.set(style='white')  
sinplot()  
sns.despine()
```

Использование Seaborn с Matplotlib

```
fig, ax = plt.subplots()
sns.scatterplot(x="total_bill", y="tip", ax=ax, data=tips)
ax.set_title("Scatterplot in Matplotlib Figure")
```

Стать IT-шником может каждый



ВОПРОСЫ



Экспресс-опрос




Что показывает Box Plot и в чем его преимущество при сравнении групп?





Box plot —

это график, использующийся в описательной статистике, компактно изображающий одномерное распределение вероятностей.



Box plot

```
sns.boxplot(x=None, y=None, hue=None, data=None, order=None, hue_order=None, orient=None,  
color=None, palette=None, saturation=0.75, width=0.8, dodge=True, fliersize=5, linewidth=None,  
whis=1.5, notch=False, ax=None, **kwargs)
```

Box plot


- `x, y, hue` — одномерные данные или имена переменных из `data`.
- `hue` отвечает за категории данных
- `data` — данные
- `orient: "v" | "h"` — ориентация (вертикальная или горизонтальная)
- `color` и `palette` — задают цвет



Пример

```
data = sps.norm.rvs(size=(1000, 6)) + np.arange(6) / 2
```

```
plt.figure(figsize=(8, 7))  
sns.boxplot(data=data, palette='Set2');
```



Датасет tips

- total_bill — общая сумма счета
- tip — сумма чаевых
- sex — пол клиента
- smoker — курящий ли клиент
- day — день недели (официант работал не все дни)
- time — время дня
- size — количество людей в компании клиента



Загрузка датасета

```
tips = sns.load_dataset('tips')  
tips.head()
```


Зависимость общей суммы счета от дня недели

```
plt.figure(figsize=(15, 6))

plt.subplot(121)
sns.boxplot(x='day', y='total_bill', data=tips, palette='Set3')
plt.ylabel('Сумма счета')

plt.subplot(122)
sns.boxplot(x='day', y='tip', data=tips, palette='Set3')
plt.ylabel('Размер чаевых');
```

Зависимость общей суммы счета от дня недели




Зависимость общей суммы счета от smoker

```
plt.figure(figsize=(15, 6))

plt.subplot(121)
ax = sns.boxplot(x='day', y='total_bill', hue='smoker',
                 data=tips, palette='Set3')
ax.legend().get_frame().set_facecolor("white")
plt.ylabel('Сумма счета')

plt.subplot(122)
ax = sns.boxplot(x='day', y='tip', hue='smoker',
                 data=tips, palette='Set3')
ax.legend().get_frame().set_facecolor("white")
plt.ylabel('Размер чаевых');
```

Зависимость общей суммы счета от smoker




Зависимость общей суммы счета от пола

```
plt.figure(figsize=(15, 6))

plt.subplot(121)
ax = sns.boxplot(x='day', y='total_bill', hue='sex',
                 data=tips, palette='Set3')
ax.legend().get_frame().set_facecolor("white")
plt.ylabel('Сумма счета')

plt.subplot(122)
ax = sns.boxplot(x='day', y='tip', hue='sex',
                 data=tips, palette='Set3')
ax.legend().get_frame().set_facecolor("white")
plt.ylabel('Размер чаевых');
```

Зависимость общей суммы счета от пола



Экспресс-опрос



Как Violin Plot сочетает в себе характеристики распределения данных и кривую плотности вероятности?






Violin plot —

это комбинация **boxplot** и ядерной оценки плотности.

Внутри облака изображен обычный ящик с усами, только в сжатом виде и без выбросов. Форма облака соответствует ядерной оценке плотности.



Violin plot

```
sns.violinplot(x=None, y=None, hue=None, data=None, order=None, hue_order=None, bw='scott',  
cut=2, scale='area', scale_hue=True, gridsize=100, width=0.8, inner='box', split=False, dodge=True,  
orient=None, linewidth=None, color=None, palette=None, saturation=0.75, ax=None, **kwargs)
```

Violin plot




- `x, y, hue` — одномерные данные или имена переменных из `data`
- `data` — данные
- `bw` — ширина ядра
- `gridsize` — размер сетки для отрисовки ядерной оценки плотности
- `orient: "v" | "h"` — ориентация (вертикальная или горизонтальная)
- `color` и `palette` — задают цвет

Пример

```
data = sps.norm.rvs(size=(20, 6)) + np.arange(6) / 2  
plt.figure(figsize=(8, 7))  
sns.violinplot(data=data, palette='Set2', bw=.2, cut=1, linewidth=1);
```

Пример

```
with sns.plotting_context("notebook", font_scale=1.5):  
    plt.figure(figsize=(8, 7))  
    sns.violinplot(x="day", y="tip", hue="smoker",  
                   data=tips, palette="Set2", split=True);  
    plt.ylabel('Размер чаевых');  
    plt.xlabel('День недели');
```




Экспресс-опрос



Как интерпретировать данные на Heatmap и какие особенности корреляции между переменными можно выявить?




Полезно знать



Heatmap —

это инструмент, который визуализирует двумерную таблицу в виде тепловой карты.



Heatmap

```
sns.heatmap(data, vmin=None, vmax=None, cmap=None, center=None, robust=False, annot=None,
fmt='.2g', annot_kws=None, linewidths=0, linecolor='white', cbar=True, cbar_kws=None,
cbar_ax=None, square=False, xticklabels='auto', yticklabels='auto', mask=None, ax=None, **kwargs)
```

Heatmap



- data — 2D-данные
- vmin и vmax — минимальное и максимальное значения цветов
- cmap — цветовая схема
- robust — если не указаны vmin и vmax, то не используются выбросы при определении минимума и максимума
- annot — в какие ячейки записывать данные
- fmt — формат записи данных
- linewidths — ширина линий между ячейками
- linecolor — цвет линий между ячейками
- cbar — рисовать ли colorbar

Данные о количестве пассажиров самолетов за каждый месяц с 1949 по 1960


```
flights_long = sns.load_dataset('flights')  
flights_long.head()
```

Создание двумерной таблицы

[illegible]

Визуализация с помощью heatmap

```
sns.set(font_scale=1.3)  
f, ax = plt.subplots(figsize=(12, 7))  
sns.heatmap(flights, annot=True, fmt='d', ax=ax, cmap="viridis")  
plt.ylim((0, 12));
```



sns.heatmap

```
sns.heatmap(np.array([1., np.nan], [3., 4.]))  
# TypeError: data type not understood
```

Экспресс-опрос




В чем ценность использования Pair Plot для исследования датасета и какие выводы можно сделать из этой визуализации?





Clustermap —


это аналог `sns.heatmap`, который автоматически группирует похожие строки и/или столбцы таблицы.



Загрузка датасета brain_networks

```
data = sns.load_dataset("brain_networks", header=[0, 1, 2], index_col=0)
# выберем подмножество отделов мозга
used_networks = [1, 5, 6, 7, 8, 12, 13, 17]
used_columns = (data.columns.get_level_values("network")
                .astype(int)
                .isin(used_networks))
data = data.loc[:, used_columns]
# создадим для них категориальную палитру
network_pal = sns.husl_palette(len(used_networks), s=.45)
network_lut = dict(zip(map(str, used_networks), network_pal))
# окрасим строки и столбцы в соответствии с отделом
networks = data.columns.get_level_values("network")
network_colors = pd.Series(networks, index=data.columns).map(network_lut)
# нарисуем график корреляции паттернов активности участков мозга
# и убедимся, что участки из одного отдела попадают в одну группу
# после иерархической кластеризации
sns.clustermap(data.corr(), center=0, cmap="vlag",
               row_colors=network_colors, col_colors=network_colors,
               linewidths=.75, figsize=(13, 13));
```

Загрузка датасета brain_networks



Стать IT-шником может каждый



ВОПРОСЫ



Стать IT-шником может каждый




ЗАДАНИЕ ДЛЯ ЗАКРЕПЛЕНИЯ



Задание

Завершить работу над задачами с практикумов 7 и 8.





Задание

1. В [файле](#) содержится информация о фильмах: название, рейтинг, год выпуска, режиссер, жанр. На основе этих данных создайте датафрейм и постройте цветовую карту для демонстрации распределения рейтингов по годам.
2. Для предыдущего файла постройте столбчатую диаграмму, показывающую количество фильмов каждого жанра. Добавьте на этот рисунок два вложенных графика – гистограммы распределения фильмов по годам и по рейтингам.



Задание

3. Прочитайте из [файла](#) данные о продажах фруктов в нескольких магазинах компании. Постройте столбчатую диаграмму количества всех продаж каждый день. Рядом разместите вторую столбчатую диаграмму, демонстрирующую выручку от всех продаж каждый день.
4. Разместите обе столбчатые диаграммы из предыдущей задачи на одном графике, с общей осью X и двумя отдельными осями Y.



Задание

1. Скачайте [файл](#) с данными о результатах экзаменов по нескольким предметам.
2. Используя библиотеку `seaborn`, постройте гистограмму распределения оценок по математике.
3. Создайте `heatmap`, чтобы визуализировать корреляцию между оценками по различным предметам.





Задание

4. Используя ящики с усами, визуализируйте распределение оценок по литературе и истории. ☐
5. Постройте точечную диаграмму (scatterplot), чтобы визуализировать зависимость оценок по биологии от оценок по физике.
6. (*) Вычислите средние оценки для каждого студента и постройте гистограмму распределения этих средних оценок.

Стать IT-шником может каждый



ВОПРОСЫ



Стать IT-шником может каждый



РАЗБОР ДОМАШНЕГО ЗАДАНИЯ





Домашнее задание

1. Изобразите на одной системе координат графики функций $y=\sin(x)$ и $y=\log(x+1)$. Используйте две оси Y: одну для первого графика, и вторую для другого.





Решение 1

```
x = np.arange(0, 10, 0.1)
y1 = np.sin(x)
y2 = np.log(x + 1)

plt.figure()
ax1 = plt.subplot()

ax1.set_xlabel('Variable X')
ax1.set_ylabel('Sin', color='red')
ax1.plot(x, y1, color='red')
ax1.tick_params(axis='y', labelcolor='red')

ax2 = ax1.twinx()
ax2.set_ylabel('Log', color='blue')
ax2.plot(x, y2, color='blue')
ax2.tick_params(axis='y', labelcolor='blue')

plt.show()
```



Домашнее задание

2. В датафрейме ниже представлены результаты соревнований: для каждого игрока указано набранное количество очков в нескольких попытках.

```
data = {  
    'Name': ['Анна', 'Антон', 'Мария', 'Макс', 'Макс', 'Алекс', 'Антон',  
            'Мария', 'Макс', 'Алекс', 'Антон', 'Анна'],  
    'Points': [145, 2524, 343, 4212, 5212, 6421, 745, 842, 524, 3224, 212,  
              1214]  
}
```

Создайте из этих данных датафрейм. Сгруппируйте данные по имени игроков. Методом `plot()` для датафреймов постройте график минимальных, максимальных и средних очков каждого игрока на одной системе координат.



Решение 2

```
data = pd.DataFrame({
    'Name': ['Анна', 'Антон', 'Мария', 'Макс', 'Макс', 'Алекс', 'Антон', 'Мария', 'Макс', 'Алекс',
            'Антон', 'Анна'],
    'Points': [145, 2524, 343, 4212, 5212, 6421, 745, 842, 524, 3224, 212, 1214]})

fig, axes = plt.subplots(figsize=(7, 7), nrows=1, ncols=1)
data.groupby('Name').mean().plot(ax=axes, kind='line')
data.groupby('Name').min().plot(ax=axes, kind='line')
data.groupby('Name').max().plot(ax=axes, kind='line')
plt.show()
```



Домашнее задание

1. Импортируйте `seaborn` и скачайте датасет `fmri`. Этот набор данных содержит данные функциональной магнитно-резонансной томографии (fMRI) из эксперимента, в котором испытуемые выполняли задания на восприятие языка. Отобразите первые 5 строчек датафрейма. Визуализируйте эффект типа события. Для этого постройте `barplot`, отображающий среднее значение `display` для каждого события в момент времени `timepoint=5`. Не забудьте назвать график.





Решение 1

```
import seaborn as sns
fmri = sns.load_dataset('fmri')
fmri.head(5)

sns.barplot(data=fmri.query("timepoint == 5"), x='event', y='signal')
plt.show()
```



Домашнее задание

2. Изучите влияние области на результаты томографии. Отобразите с помощью `pointplot` средний сигнал в каждый момент времени в зависимости от области снятия показателей. Не забудьте назвать график.
3. Интерактивная визуализация с помощью `FacetGrid`. Используя `FacetGrid`, постройте отдельные `lineplot` для каждого субъекта, каждый график должен показывать связь между временем и сигналом. *Задача со звёздочкой:* подписать каждый график.



Решение 2


```
sns.pointplot(data=fmri, x='timepoint', y='signal', hue='region')  
plt.show()
```



Решение 3

```
g = sns.FacetGrid(fmri, col='subject', col_wrap=5, height=2, sharey=False)
g.map(sns.lineplot, 'timepoint', 'signal')
g.set_titles('Субъект {col_name}')
plt.show()
```

Стать IT-шником может каждый



ОСТАВШИЕСЯ ВОПРОСЫ



Стать IT-шником может каждый



ЗАКЛЮЧЕНИЕ

