


Python  
for DA

# Основы статистики. Распределения



# Преподаватель

Портрет

**Имя Фамилия**

Текущая должность

Количество лет опыта

Какой у Вас опыт - ключевые кейсы

Самые яркие проекты

Дополнительная информация по вашему усмотрению

Корпоративный e-mail

Социальные сети (по желанию)

# Важно

- 

Камера должна быть включена на протяжении всего занятия
- 

В течение занятия вопросы задавать в чате или когда преподаватель спрашивает, есть ли у Вас вопросы
- 

Вести себя уважительно и этично по отношению к остальным участникам занятия
- 

Организационные вопросы по обучению решаются с кураторами, а не на тематических занятиях
- 

Во время занятия будут интерактивные задания, будьте готовы включить камеру или демонстрацию экрана по просьбе преподавателя

# Повторение



Обзор статистики и ее виды



Генеральная совокупность и выборка



Качественные и количественные переменные



Описательная статистика

# План занятия

- Боксплоты
- Биномиальное распределение и распределение Пуассона
- Непрерывные распределения
- Распределение данных: асимметрия и эксцесс



# ОСНОВНОЙ БЛОК





# Боксплоты





## Графическая диаграмма или "ящик с усами"

Это графическое представление, используемое в описательной статистике для отображения распределения набора данных. Дает наглядное представление о центральной тенденции, изменчивости и асимметрии данных через их квартили.



# Построение графической диаграммы

Минимум

Первый  
квартиль (Q1)

Медиана (Q2)

Третий  
квартиль (Q3)

Максимум  
(Maximum)

Наименьшая  
точка данных,  
исключающая  
провалы

# Построение графической диаграммы

Минимум

Первый  
квартиль (Q1)

Медиана (Q2)

Третий  
квартиль (Q3)

Максимум  
(Maximum)

Медиана нижней  
половины набора  
данных (25-й  
процентиль)

# Построение графической диаграммы

Минимум

Первый  
квартиль (Q1)

Медиана (Q2)

Третий  
квартиль (Q3)

Максимум  
(Maximum)

Среднее  
значение набора  
данных (50-й  
процентиль)

# Построение графической диаграммы

Минимум

Первый  
квартиль (Q1)

Медиана (Q2)

Третий  
квартиль (Q3)

Максимум  
(Maximum)

Медиана верхней  
половины набора  
данных (75-й  
процентиль)

# Построение графической диаграммы

Минимум

Первый  
квартиль (Q1)

Медиана (Q2)

Третий  
квартиль (Q3)

Максимум  
(Maximum)

Наибольшая  
точка данных без  
учета выбросов.

# Графическая диаграмма



Для определения разброса средних 50% данных используется интерквартильный размах (IQR), который представляет собой расстояние между  $Q1$  и  $Q3$



## Выбросы

Определяются как точки данных, которые находятся ниже  $Q1 - 1,5IQR$  или выше  $Q3 + 1,5IQR$ .

# Графическая диаграмма в Matplotlib

```
import matplotlib.pyplot as plt
import numpy as np

np.random.seed(42)
data = np.random.normal(100, 20, 200)

plt.boxplot(data)
plt.title("Box Plot using Matplotlib")
plt.show()
```



# Графическая диаграмма в Seaborn

```
import seaborn as sns
import matplotlib.pyplot as plt

tips = sns.load_dataset("tips")

sns.boxplot(x=tips["total_bill"])
plt.title("Box Plot using Seaborn")
plt.show()
```

# Графическая диаграмма в Plotly

```
import plotly.graph_objects as go
import numpy as np

np.random.seed(42)
y0 = np.random.randn(50) - 1

fig = go.Figure()
fig.add_trace(go.Box(y=y0))
fig.show()
```

# Интерпретация диаграммы "ящик с усами"

Описательная  
статистика

Индуктивная  
статистика

Описательная  
статистика

Индуктивная  
статистика

Граница представляет собой межквартильный интервал (IQR), который содержит средние 50% данных

# Интерпретация диаграммы "ящик с усами"

Описательная  
статистика

Индуктивная  
статистика

Описательная  
статистика

Индуктивная  
статистика

Линия внутри коробки  
указывает на медиану  
(Q2) набора данных

# Интерпретация диаграммы "ящик с усами"

Описательная  
статистика

Индуктивная  
статистика

Описательная  
статистика

Индуктивная  
статистика

Линии, идущие от рамки к  
минимальному и  
максимальному  
значениям в пределах  
 $1,5 \cdot IQR$  от  $Q1$  и  $Q3$ ,  
соответственно

# Интерпретация диаграммы "ящик с усами"

Описательная  
статистика

Индуктивная  
статистика

Описательная  
статистика

Индуктивная  
статистика

Точки за пределами усов  
считаются выбросами и  
наносятся на график  
отдельно

# Польза диаграммы "ящик с усами"



Определения центрального значения и разброса данных



Выявления перекоса и симметрии в распределении данных



Сравнения распределений по различным группам



Выделения провалов и понимания их влияния на набор данных



# ВОПРОСЫ







# Биномиальное распределение и распределение Пуассона



## Биномиальное распределение

Моделирует количество успехов в фиксированном числе независимых испытаний бинарного эксперимента. Каждое испытание имеет два возможных исхода: успех или неудача. Вероятность успеха одинакова для каждого испытания.

# Биномиальное распределение



## Параметры

- $n$ : Количество испытаний
- $p$ : Вероятность успеха в каждом испытании

## Функция вероятности

$$P(X = k) = C_n^k p^k (1 - p)^{n-k}$$

$C_n^k$  - биномиальный коэффициент, представляющий собой количество способов выбора  $k$  успехов из  $n$  испытаний.

# Пример



Рассмотрим сценарий, в котором вы подбрасываете монету 10 раз и хотите найти вероятность получения ровно 6 голов (успехов), если вероятность получения головы при каждом подбрасывании равна 0,5

# Реализация примера

```
from scipy.stats import binom
import seaborn as sns
import matplotlib.pyplot as plt

# Параметры
n = 10 # количество испытаний
p = 0.5 # вероятность успеха

# Генерируем случайные величины с биномиальным распределением
data_binom = binom.rvs(n=n, p=p, size=10000)

# Построение графика распределения
ax = sns.histplot(data_binom, kde=False, color='skyblue', bins=30)
ax.set(xlabel='Биномиальное распределение', ylabel='Частота')
plt.title('Биномиальное распределение (n=10, p=0.5)')
plt.show()
```



## Распределение Пуассона

Моделирует количество событий, происходящих в фиксированном интервале времени или пространства, с учетом среднего числа повторений события за этот интервал. Оно используется для событий, которые происходят независимо и с постоянной скоростью.

# Биномиальное распределение



## Параметры

$\lambda$  : Среднее количество событий в интервале

## Функция вероятности

$$P(X = k) = \frac{e^{-\lambda} \lambda^k}{k!}$$

где  $e$  - основание натурального логарифма,  
 $k$  - количество вхождений

# Пример



Рассмотрим сценарий, в котором колл-центр получает в среднем 3 звонка в минуту.  
Вы хотите найти вероятность получения ровно 5 звонков за минуту



# Реализация примера

```
from scipy.stats import poisson
import seaborn as sns
import matplotlib.pyplot as plt

# Параметр
mu = 3 # среднее число вхождений (лямбда)

# Генерируем случайные переменные с пуассоновским распределением
data_poisson = poisson.rvs(mu=mu, size=10000)

# Построение графика распределения
ax = sns.histplot(data_poisson, kde=False, color='skyblue', bins=30)
ax.set(xlabel='Распределение Пуассона', ylabel='Частота')
plt.title('Распределение Пуассона (лямбда=3)')
plt.show()
```

- Используется для фиксированного числа независимых испытаний с двумя возможными исходами.
- Используется в сценариях, где есть два возможных исхода (успех или неудача) для фиксированного числа независимых испытаний, с постоянной вероятностью успеха.

Биномиальное распределение

- Используется для моделирования количества событий в фиксированном интервале.
- Используется для моделирования количества раз, когда событие происходит в фиксированном интервале времени или пространства, когда эти события происходят с известной средней скоростью и независимо от времени, прошедшего с момента последнего события.

Распределение Пуассона



# ВОПРОСЫ





# Непрерывные распределения




## Непрерывные распределения

Описывают вероятности возможных значений  
непрерывной случайной величины.


# Непрерывные распределения



Нормальное  
распределение



Равномерное  
распределение



Экспоненциальное  
распределение



## Нормальное распределение

Или распределение Гаусса, - это непрерывное распределение вероятностей, характеризующееся колоколообразной кривой. Симметрично относительно среднего значения, причем данные вблизи среднего значения встречаются чаще, чем данные вдали от среднего значения.

# Нормальное распределение



## Параметры

- $\mu$ : Среднее значение распределения
- $\sigma$ : Стандартное отклонение распределения

## Функция вероятности

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$



# Пример



Рассмотрим сценарий, в котором рост взрослых мужчин распределен нормально со средним значением 70 дюймов и стандартным отклонением 3 дюйма

# Реализация примера

```
import numpy as np
import matplotlib.pyplot as plt
from scipy.stats import norm

# Параметры
mu = 70 # среднее значение
sigma = 3 # стандартное отклонение

# Генерируем нормально распределенные случайные величины
data_normal = np.random.normal(mu, sigma, 1000)

# Построение графика распределения
plt.hist(data_normal, bins=30, density=True, alpha=0.6, color='g')

# Построение графика PDF
xmin, xmax = plt.xlim()
x = np.linspace(xmin, xmax, 100)
p = norm.pdf(x, mu, sigma)
plt.plot(x, p, 'k', linewidth=2)
plt.title("Нормальное распределение (mu=70, sigma=3)")
plt.show()
```

# Примеры использования нормального распределения

Рост отдельных  
людей

Результаты тестов

Артериальное  
давление

Вес  
новорожденных  
при рождении



## Равномерное распределение

Это непрерывное распределение вероятностей, в котором все интервалы одинаковой длины в пределах диапазона распределения одинаково вероятны.

# Равномерное распределение



## Параметры

- $a$ : Нижняя граница
- $b$ : Верхняя граница

## Функция вероятности

$$f(x) = \frac{1}{b-a} \text{ для } a \leq x \leq b$$

# Пример



Рассмотрим сценарий, в котором случайная величина равномерно распределена между 0 и 10

# Реализация примера

```
from scipy.stats import uniform
import matplotlib.pyplot as plt
import numpy as np

# Параметры
a = 0 # нижняя граница
b = 10 # верхняя граница

# Генерируем равномерно распределенные случайные величины
data_uniform = uniform.rvs(loc=a, scale=b-a, size=1000)

# Построение графика распределения
plt.hist(data_uniform, bins=30, density=True, alpha=0.6, color='b')

# Построение графика PDF
x = np.linspace(a, b, 100)
p = uniform.pdf(x, loc=a, scale=b-a)
plt.plot(x, p, 'k', linewidth=2)
plt.title("Равномерное распределение (a=0, b=10)")
plt.show()
```

# Примеры использования равномерного распределения

Время ожидания  
лифта

Генерация  
случайных чисел

Бросок игральной  
кости





## Экспоненциальное распределение

Это непрерывное распределение вероятностей, которое описывает время между событиями в пуассоновском процессе. Используется для моделирования времени до наступления события.

# Экспоненциальное распределение



## Параметры

$\lambda$ : Параметр скорости (обратный среднему значению)

## Функция вероятности

$$f(x) = \lambda e^{-\lambda x} \text{ для } x \geq 0$$

# Пример



Рассмотрим сценарий, в котором среднее время между прибытиями в пункт обслуживания составляет 5 минут. Параметр скорости  $\lambda$  равен  $1/5$

# Реализация примера

```
from scipy.stats import expon
import matplotlib.pyplot as plt
import numpy as np

# параметр
lambda_ = 1/5 # Параметр скорости

# Генерируем экспоненциально распределенные случайные величины
data_exponential = expon.rvs(scale=1/lambda_, size=1000)

# Построение графика распределения
plt.hist(data_exponential, bins=30, density=True, alpha=0.6, color='r')

# Построение графика PDF
x = np.linspace(0, np.max(data_exponential), 100)
p = expon.pdf(x, scale=1/lambda_)
plt.plot(x, p, 'k', linewidth=2)
plt.title("Экспоненциальное распределение (лямбда=1/5)")
plt.show()
```

# Примеры использования экспоненциального распределения

Время между  
прибытиями  
клиентов

Время между  
отказами

Время между  
землетрясениями



**ВОПРОСЫ**





# Распределение данных: асимметрия и эксцесс



## Асимметрия

Это мера положения распределения вероятностей вещественной случайной величины относительно ее среднего значения. Показывает, насколько точки данных перекошены влево (отрицательная асимметрия) или вправо (положительная асимметрия) от среднего значения.



# Асимметрия

Положительная асимметрия  
(правая ассиметрия)

Отрицательная асимметрия  
(ассиметрия влево)

Нулевая асимметрия  
(Zero Skewness)

Правый хвост (более высокие значения) длиннее или толще левого хвоста. Среднее значение больше медианы.

# Асимметрия

Положительная асимметрия  
(правая ассиметрия)

Отрицательная асимметрия  
(ассиметрия влево)

Нулевая асимметрия  
(Zero Skewness)

Левый хвост (меньшие значения)  
длиннее или толще правого хвоста.  
Среднее значение меньше  
медианы.

# Асимметрия

Положительная асимметрия  
(правая ассиметрия)

Отрицательная асимметрия  
(ассиметрия влево)

Нулевая асимметрия  
(Zero Skewness)

Данные симметрично  
распределены вокруг среднего  
значения, что свидетельствует о  
нормальном распределении.

# Формула для перекоса

$$\text{Skewness} = \frac{n}{(n-1)(n-2)} \sum \left( \frac{x_i - \bar{x}}{s} \right)^3,$$

где:

- $n$  - количество точек данных
- $x_i$  - это каждая отдельная точка данных
- $\bar{x}$  - среднее значение данных
- $s$  - стандартное отклонение данных

# Пример

```
import pandas as pd
import numpy as np
from scipy.stats import skew

# Пример набора данных
data = np.random.normal(0, 1, 1000)

# Рассчёт асимметрии с помощью pandas
skewness_pandas = pd.Series(data).skew()
print(f "Skewness (pandas): {skewness_pandas}")

# Рассчёт асимметрии с помощью scipy
skewness_scipy = skew(data)
print(f "Skewness (scipy): {skewness_scipy}")
```



## Эксцесс

Это мера "хвостатости" распределения вероятностей. Показывает, сколько данных находится в хвостах и пиках распределения по сравнению с нормальным распределением.

# Эксцесс

Положительный эксцесс

Отрицательный эксцесс

Нулевой эксцесс

Распределение имеет более тяжелые хвосты и более острый пик, чем нормальное распределение. Указывает на большую вероятность экстремальных значений.

# Эксцесс

Положительный эксцесс

Отрицательный эксцесс

Нулевой эксцесс

Распределение имеет более светлые хвосты и более плоский пик, чем нормальное распределение.



# Эксцесс

Положительный эксцесс

Отрицательный эксцесс

Нулевой эксцесс

Распределение имеет хвосты,  
похожие на нормальное  
распределение.

# Формула для перекоса

$$\text{Kurtosis} = \frac{n(n+1)}{(n-1)(n-2)(n-3)} \sum \left( \frac{x_i - \bar{x}}{s} \right)^4 - \frac{3(n-1)^2}{(n-2)(n-3)},$$

где:

- $n$  - количество точек данных
- $x_i$  - это каждая отдельная точка данных
- $\bar{x}$  - среднее значение данных
- $s$  - стандартное отклонение данных

# Пример

```
from scipy.stats import kurtosis

# Вычисление эксцесса с помощью pandas
kurtosis_pandas = pd.Series(data).kurt()
print(f "Kurtosis (pandas): {kurtosis_pandas}")

# Вычисление эксцесса с помощью scipy
kurtosis_scipy = kurtosis(data)
print(f "Kurtosis (scipy): {kurtosis_scipy}")
```



**ВОПРОСЫ**





# ПРАКТИЧЕСКАЯ РАБОТА



# Задание



Создайте набор данных из 10 000 значений с нормальным распределением со средним значением 50 и стандартным отклонением 10. Вычислите среднее значение, стандартное отклонение и постройте гистограмму с функцией плотности вероятности (PDF).



**ВОПРОСЫ**



# Домашнее задание

1. Сгенерируйте 10 000 пар значений из равномерного распределения от 0 до 1. Вычислите сумму каждой пары и постройте гистограмму сумм.
2. При определенных условиях распределение Пуассона можно использовать в качестве приближения к биномиальному распределению:
  - Число испытаний  $n$  велико.
  - Вероятность успеха  $p$  мала.
  - Произведение  $np$  (среднее значение биномиального распределения) конечное и равно  $\lambda$ .

Пример: если у вас есть биномиальное распределение с  $n=1000$  и  $p=0.003$ , вы можете аппроксимировать его, используя распределение Пуассона с  $\lambda=np=3$ .

Задача: сгенерировать случайные величины с биномиальным распределением, сгенерировать пуассоновские распределенные случайные величины с  $\lambda = np$ , построить графики распределений рядом друг с другом.



## Заключение

