


Python
for DA

ОСНОВЫ СТАТИСТИКИ. Z-score



Преподаватель

Портрет

Имя Фамилия

Текущая должность

Количество лет опыта

Какой у Вас опыт - ключевые кейсы

Самые яркие проекты

Дополнительная информация по вашему усмотрению

Корпоративный e-mail

Социальные сети (по желанию)

Важно

- 

Камера должна быть включена на протяжении всего занятия
- 

В течение занятия вопросы задавать в чате или когда преподаватель спрашивает, есть ли у Вас вопросы
- 

Вести себя уважительно и этично по отношению к остальным участникам занятия
- 

Организационные вопросы по обучению решаются с кураторами, а не на тематических занятиях
- 

Во время занятия будут интерактивные задания, будьте готовы включить камеру или демонстрацию экрана по просьбе преподавателя

Повторение



Функция распределения, функция процентной точки и функция выживания



Визуализация сравнения PDF и CDF



Условная вероятность



Закон полной вероятности



Теорема Байеса

План занятия

- Z-score: Определение и расчет
- Применение Z-score в анализе данных
- Стандартное нормальное распределение: Свойства и значение
- Поиск вероятностей с помощью Z-score



ОСНОВНОЙ БЛОК





Z-score:



**Определение и
расчет**



Z-score

Это статистическое измерение, описывающее отношение значения к среднему значению группы значений. Показывает, на сколько стандартных отклонений точка данных отличается от среднего значения набора данных.

Z-score

Положительный
Z-score

Указывает на то, что точка
данных находится выше
среднего значения

Отрицательный
Z-score

Указывает на то, что точка
данных находится ниже
среднего значения

Z-score, равный 0

Означает, что точка
данных находится точно
на среднем уровне

Важность Z-score



Сравнение



Выявление выбросов



Вероятность

Формула для расчета Z-score



$$Z = \frac{x - \mu}{\sigma},$$

где z - Z-score. x - стандартизируемая величина, μ - среднее значение генеральной совокупности, σ - стандартное отклонение.

Z-score



Пример

Предположим, у нас есть набор данных тестовых оценок со средним значением (μ), равным 70, и стандартным отклонением (σ), равным 10. Мы хотим найти Z-score для тестового балла (x), равного 85.

Решение

1. Вычтите среднее значение из индивидуального балла:

$$85 - 70 = 15$$

2. Разделите разницу на стандартное отклонение:

$$15 / 10 = 1.5$$

Реализация на языке Python

```
import numpy as np

# Определите данные
data = [55, 60, 65, 70, 75, 80, 85]

# Вычислите среднее значение и стандартное отклонение
mean = np.mean(data)
std_dev = np.std(data)

# Вычислите Z-скор для конкретного значения
x = 85
z_score = (x - mean) / std_dev

print(f"Среднее значение: {mean}")
print(f"Стандартное отклонение: {std_dev}")
print(f"Z-score для {x}: {z_score}")
```



ВОПРОСЫ





Применение Z-score в анализе данных

Стандартизация данных



Стандартизация преобразует данные в общую шкалу со средним значением 0 и стандартным отклонением 1. Это важно при сравнении точек данных из разных распределений или наборов данных с разными единицами измерения или шкалами.

Стандартизация данных



Пример

Предположим, у вас есть результаты двух разных экзаменов с разными средними и стандартными отклонениями. Преобразовав их в Z-score, вы сможете сравнить успеваемость студентов на обоих экзаменах по единой шкале.

Реализация на языке Python

```
import numpy as np

exam1_scores = [85, 90, 78, 92, 88]
exam2_scores = [75, 80, 70, 85, 78]

mean_exam1 = np.mean(exam1_scores)
std_exam1 = np.std(exam1_scores)
mean_exam2 = np.mean(exam2_scores)
std_exam2 = np.std(exam2_scores)

z_scores_exam1 = [(x - mean_exam1) / std_exam1 for x in exam1_scores]
z_scores_exam2 = [(x - mean_exam2) / std_exam2 for x in exam2_scores]

print("Z-баллы для экзамена 1:", z_scores_exam1)
print("Z-баллы для экзамена 2:", z_scores_exam2)
```



Выброс

Это точка данных, которая значительно отклоняется от других наблюдений. Как правило, точки данных с Z-score больше 3 или меньше -3 считаются выброшенными.

Определение выбросов



Пример

В наборе данных о росте студентов вы можете использовать Z-score, чтобы определить всех студентов, чей рост значительно отклоняется от среднего.

Реализация на языке Python

```
heights = [160, 162, 165, 170, 175, 180, 185, 190, 195, 200, 320]

mean_height = np.mean(heights)
std_height = np.std(heights)

z_scores_heights = [(x - mean_height) / std_height for x in heights]

outliers = [x for x, z in zip(heights, z_scores_heights) if abs(z) > 3]

print("Выбросы:", outliers)
```

Сравнение различных наборов данных



Z-score позволяют сравнивать точки данных из разных наборов данных, стандартизируя их значения. Важно, когда наборы данных имеют разные шкалы или единицы измерения.

Сравнение различных наборов данных



Пример

Сравнение высоты учеников двух разных школ с разным средним ростом и стандартным отклонением.

Реализация на языке Python

```
school1_heights = [160, 162, 165, 170, 175]
school2_heights = [150, 155, 160, 165, 170]

# Рассчитайте среднее значение и стандартное отклонение для каждой школы
mean_school1 = np.mean(school1_heights)
std_school1 = np.std(school1_heights)
mean_school2 = np.mean(school2_heights)
std_school2 = np.std(school2_heights)

# Стандартизация высот
z_scores_school1 = [(x - mean_school1) / std_school1 for x in school1_heights]
z_scores_school2 = [(x - mean_school2) / std_school2 for x in school2_heights]

print("Z-баллы для школы 1:", z_scores_school1)
print("Z-баллы для школы 2:", z_scores_school2)
```

Оценка вероятности



Z-score используются для оценки вероятности того, что определенная точка данных находится в пределах нормального распределения. Переведя Z-score в процент или используя стандартную таблицу нормального распределения, можно определить вероятность того, что значение будет выше или ниже определенного порога.

Применение Z-score

-  Стандартизация данных
-  Выявление выбросов
-  Проверка гипотез
-  Сравнение различных наборов данных
-  Оценка вероятности



ВОПРОСЫ





Стандартное нормальное распределение: Свойства и значение



Стандартное нормальное распределение

Это частный случай нормального (или гауссовского) распределения. Оно характеризуется средним значением (μ), равным 0, и стандартным отклонением (σ), равным 1.

Экспресс-опрос

?

Какие свойства стандартного нормального распределения вы знаете?

Свойства стандартного нормального распределения



Симметрия



Среднее значение, медиана и мода



Колоколообразная кривая



Площадь под кривой



Стандартное отклонение и дисперсия



Эмпирическое правило

Значимость стандартного нормального распределения

Стандартизация

Проверка гипотез

Доверительные
интервалы

Центральная
предельная
теорема



ВОПРОСЫ






Поиск вероятностей с помощью Z-score



Z-таблица

Это кумулятивная вероятность для данного Z-score, которая представляет собой площадь под стандартной нормальной кривой слева от этого Z-score.

Шаги по нахождению вероятностей с помощью Z-score



Пример 1: Вероятность того, что меньше определенного Z-score



Задача

Найти вероятность того, что значение в заданном распределении имеет Z-score меньше, чем $z=0.25$.

Решение

Z-таблица показывает, что кумулятивная вероятность для $z=0.25$ равна примерно 0,5987.

Вероятность того, что значение имеет Z-score меньше 0,25, равна 0,5987 или 59,87 %.

Пример 2: Вероятность того, что значение больше определенного Z-score



Задача

Найти вероятность того, что значение в данном распределении имеет Z-score больше, чем $z = -0.5$.

Решение

Найдите -0,5 в Z-таблице. Кумулятивная вероятность равна 0,3085.

Мы хотим, чтобы вероятность была больше, чем $z = -0.5$, мы вычитаем кумулятивную вероятность из 1.

$$P(z > -0.5) = 1 - P(z < -0.5) = 1 - 0.3085 \approx 0.6915.$$

Вероятность того, что значение имеет Z-score больше, чем -0,5, равна 0,6915 или 69,15%.

Пример 3: Вероятность между двумя Z-score



Задача

Найти вероятность того, что значение в данном распределении имеет Z-score между $z=0.4$ и $z=1$.

Решение

Для $z=0.4$, кумулятивная вероятность равна 0,6554. Для $z=1$, суммарная вероятность равна 0,8413.

Вычтите меньшую кумулятивную вероятность из большей.

$$\begin{aligned} P(0.4 < z < 1) &= P(z < 1) - P(z < 0.4) = \\ &= 0.8413 - 0.6554 \approx 0.1859 \end{aligned}$$

Вероятность того, что значение имеет Z-score между 0,4 и 1, равна 0,1859 или 18,59%.

Пример на языке Python

```
from scipy.stats import norm
```

```
# Пример 1: Вероятность меньше определенного Z-score
```

```
z1 = 0.25
```

```
prob_less_than_z1 = norm.cdf(z1)
```

```
print(f"Вероятность меньше {z1}: {prob_less_than_z1}")
```

```
# Пример 2: Вероятность больше определенного Z-score
```

```
z2 = -0.5
```

```
prob_greater_than_z2 = 1 - norm.cdf(z2)
```

```
print(f"Вероятность больше {z2}: {prob_greater_than_z2}")
```

```
# Пример 3: Вероятность между двумя Z-score
```

```
z3 = 0.4
```

```
z4 = 1
```

```
prob_between_z3_z4 = norm.cdf(z4) - norm.cdf(z3)
```

```
print(f"Вероятность между {z3} и {z4}: {prob_between_z3_z4}")
```



ВОПРОСЫ





ПРАКТИЧЕСКАЯ РАБОТА



Задание



Постройте график стандартного нормального распределения и постройте зоны эмпирического правила 68-95-99.7.



ВОПРОСЫ



Домашнее задание

1. Компания оценивает своих сотрудников по трем показателям: продажи, удовлетворенность клиентов и пунктуальность. Среднее значение и стандартное отклонение для каждого показателя следующие:

- Продажи: Среднее = 500, Стандартное отклонение = 50
- Удовлетворенность клиентов: Среднее = 80, Стандартное отклонение = 10
- Пунктуальность: Среднее = 95, Стандартное отклонение = 5

У сотрудника следующие показатели:

- Продажи: 550
- Удовлетворенность клиентов: 85
- Пунктуальность: 90

Рассчитайте Z-баллы для каждой метрики и определите, в какой метрике сотрудник показал лучшие результаты по сравнению со средним показателем по компании.

Домашнее задание

2. Среднее время выполнения задания на фабрике составляет 30 минут со стандартным отклонением 5 минут. Рассчитайте вероятность того, что выполнение случайно выбранной задачи займет от 25 до 35 минут. Используйте коэффициент Z и таблицу стандартного нормального распределения.

3. Определенное заболевание поражает 1% населения. Тест на это заболевание имеет 99 % чувствительности (истинно положительный результат) и 2 % ложноположительных результатов. Если у человека положительный тест, какова вероятность того, что у него действительно есть болезнь?

Заключение

