


Python
for DA

Основы статистики. Корреляционный анализ



Преподаватель

Портрет

Имя Фамилия

Текущая должность

Количество лет опыта

Какой у Вас опыт - ключевые кейсы

Самые яркие проекты

Дополнительная информация по вашему усмотрению

Корпоративный e-mail

Социальные сети (по желанию)

Важно

- 

Камера должна быть включена на протяжении всего занятия
- 

В течение занятия вопросы задавать в чате или когда преподаватель спрашивает, есть ли у Вас вопросы
- 

Вести себя уважительно и этично по отношению к остальным участникам занятия
- 

Организационные вопросы по обучению решаются с кураторами, а не на тематических занятиях
- 

Во время занятия будут интерактивные задания, будьте готовы включить камеру или демонстрацию экрана по просьбе преподавателя

Повторение



P-значения



T-тест



Z-тест

План занятия

- Тест Хи-квадрат
- Основы корреляции
- Коэффициент корреляции Пирсона (r)
- Коэффициент ранговой корреляции Спирмена (ρ)
- Визуализация корреляции. Графики рассеяния
- Тепловые карты в корреляционном анализе
- "Корреляция не подразумевает причинно-следственной связи"



ОСНОВНОЙ БЛОК





Тест Хи-квадрат



Тест Хи-квадрат

Это статистический метод, широко используемый при проверке гипотез, в частности при анализе категориальных данных. Предназначен для определения наличия значимой связи между двумя категориальными переменными.

Типы тестов Хи-квадрат

Тест Хи-квадрат на добросовестность соответствия

Используется, когда есть одна категориальная переменная с двумя или более уровнями. Проверяет, соответствуют ли наблюдаемые частоты для одной категориальной переменной ожидаемым частотам для этих уровней.

Тест независимости (или ассоциации) Хи-квадрат

Применяется, когда есть две категориальные переменные, и нужно оценить, есть ли между ними связь. Сравнивает наблюдаемые частоты в категориях одной переменной с категориями второй переменной с ожидаемыми частотами, рассчитанными в предположении, что переменные независимы.

Ключевые понятия и допущения

-  Наблюдаемые и ожидаемые частоты
-  Степени свободы
-  Р-значение
-  Допущения



scipy.stats

Это модуль, который предоставляет удобную функцию `chi2_contingency` для проведения теста Хи-квадрат в Python.



`chi2_contingency`

Это функция, которая используется для выполнения теста независимости Хи-квадрат на таблице случайностей.

Импорт необходимых библиотек

```
import pandas as pd  
from scipy.stats import chi2_contingency
```



Таблица случайностей

Это матрица, которая отображает распределение частот переменных.

Создание или загрузка таблицы КОНТИНГЕНТНОСТИ

```
# Пример таблицы случайностей
data = {'Preference': ['Like', 'Dislike', 'Neutral'],
        'Product_A': [20, 15, 25],
        'Product_B': [30, 10, 20]}

df = pd.DataFrame(data)
df.set_index('Preference', inplace=True)
print(df)
```

Выполнение теста хи-квадрат

```
# Выполнить тест Хи-квадрат
chi2, p, dof, expected = chi2_contingency(df)

print(f"Статистика хи-квадрат: {chi2}")
print(f"P-value: {p}")
print(f"Степени свободы: {dof}")
print("Ожидаемые частоты:")
print(expected)
```

Интерпретация результатов

Статистика хи-
квадрат

Измеряет
расхождение
между
наблюдаемыми и
ожидаемыми
частотами

P-значение

Указывает на
вероятность
наблюдения
данных, если
нулевая гипотеза
верна

Степени свободы
(Dof)

Рассчитывается как
(количество строк -
1) * (количество
столбцов - 1)

Ожидаемые
частоты (Expected
Frequencies)

Числа, ожидаемые
при отсутствии
связи между
переменными
(нулевая гипотеза)

Пример с реальным набором данных

```
import seaborn as sns

# Загружаем набор данных "Титаник"
titanic = sns.load_dataset('titanic')

# Создайте таблицу случайностей
contingency_table = pd.crosstab(titanic['class'], titanic['survived'])
print(contingency_table)

# Выполните тест Хи-квадрат
chi2, p, dof, expected = chi2_contingency(contingency_table)

print(f"Статистика хи-квадрат: {chi2}")
print(f"P-value: {p}")
print(f"Степени свободы: {dof}")
print("Ожидаемые частоты:")
print(expected)
```



ВОПРОСЫ





Основы корреляции



Корреляция

Это статистическая мера, которая выражает степень линейной зависимости двух переменных, то есть их совместное изменение с постоянной скоростью. Количественно определяет силу и направление связи между двумя переменными с помощью коэффициента корреляции, который обычно обозначается как r .

Важность изучения взаимосвязей между переменными с помощью корреляционного анализа

- Измерение взаимосвязи
- Экономические и поведенческие выводы
- Прогнозирование и принятие решений
- Основа для дальнейших исследований

Типы переменных в корреляционном анализе



Интервальные переменные

Это переменные, в которых разница между значениями значима, но нет истинной нулевой точки.

Коэффициентные переменные

Эти переменные обладают всеми свойствами интервальных переменных, но также имеют значимую нулевую точку, которая указывает на отсутствие измеряемой величины.

Коэффициент корреляции

$$r=+1$$

Означает идеальную
положительную
корреляцию, то есть обе
переменные растут
вместе

$$r=-1$$

Означает идеальную
отрицательную
корреляцию, то есть одна
переменная
увеличивается при
уменьшении другой

$$r=0$$

Указывает на отсутствие
корреляции, то есть
между переменными нет
предсказуемой связи



ВОПРОСЫ





Коэффициент корреляции Пирсона (r)



Коэффициент корреляции Пирсона (r)

Измеряет линейную связь между двумя
непрерывными переменными.

Формула расчета коэффициента корреляции Пирсона



$$r = \frac{n\sum xy - (\sum x)(\sum y)}{\sqrt{n\sum x^2 - (\sum x)^2} \sqrt{n\sum y^2 - (\sum y)^2}}$$

где:

n - количество пар оценок,

x и y - отдельные точки выборки, индексируемые i .

Сила корреляции

0,0 - 0,3 (0 - -0,3)

Слабая положительная
(отрицательная)
корреляция

От 0,3 до 0,5
(от -0,3 до -0,5)

Умеренная положительная
(отрицательная)
корреляция

От 0,5 до 1,0
(от -0,5 до -1,0)

Сильная положительная
(отрицательная)
корреляция

Условие достоверности коэффициента корреляции Пирсона



Уровень измерения



Линейность



Нормальность



Связанные пары



Отсутствие выбросов



ВОПРОСЫ





ЗАДАНИЕ



Задание

Рассчитайте коэффициент корреляции Пирсона между длиной и шириной лепестка в наборе данных Iris.



ВОПРОСЫ





Коэффициент
ранговой корреляции
Спирмена (ρ)



Коэффициент ранговой корреляции Спирмена (ρ)

Измеряет силу и направление связи между двумя ранжированными переменными.

Формула расчета коэффициента ранговой корреляции Спирмена



$$\rho = 1 - \frac{6\sum d_i^2}{n(n^2-1)}$$

где:

d_i - разница между рангами каждой пары наблюдений.

n - количество наблюдений.

Шаги для расчета коэффициента ранговой корреляции Спирмена

1. Проранжировать данные
2. Вычислить разности
3. Возвести разности в квадрат
4. Сумма квадратных разностей
5. Применить формулу

Сила корреляции

0,0 - 0,1

От 0,1 до 0,3

От 0,3 до 0,5

От 0,5 до 0,7

От 0,7 до 1,0

Нет корреляции

Слабая
корреляция

Умеренная
корреляция

Высокая
корреляция

Очень высокая
корреляция

Использование ранговой корреляции Спирмена



Нелинейные отношения



Ординарные данные



Ненормальное распределение



Наличие выбросов



ВОПРОСЫ





ЗАДАНИЕ



Задание

Рассчитайте коэффициент корреляции Спирмена между содержанием алкоголя и качеством в наборе данных Wine Quality.



ВОПРОСЫ






Визуализация
корреляции.
Графики рассеяния



Диаграмма рассеяния

Это тип визуализации данных, который отображает взаимосвязь между двумя числовыми переменными. Каждая точка на диаграмме рассеивания представляет собой отдельную точку данных, положение которой определяется значениями двух переменных по оси x и оси y .

Интерпретация диаграммы рассеяния



Положительная корреляция



Пример

Взаимосвязь между температурой и продажами мороженого. При повышении температуры продажи мороженого также растут.

Визуализация

Точки образуют на диаграмме рассеяния наклонный вверх рисунок.

Отрицательная корреляция



Пример

Взаимосвязь между количеством часов, проведенных за просмотром телевизора, и успеваемостью. По мере увеличения количества часов, проведенных за просмотром телевизора, успеваемость снижается.

Визуализация

На диаграмме рассеяния точки образуют нисходящий наклон.

Отсутствие корреляции



Пример

Взаимосвязь между ростом человека и его любимым цветом. Между этими переменными нет связи.

Визуализация

Точки разбросаны беспорядочно, без четкой закономерности.

Ограничения визуальной интерпретации

-  Оверплоттинг
-  Субъективность
-  Ограниченность двумя переменными
-  Нелинейные взаимосвязи
-  Вводящие в заблуждение корреляции



ВОПРОСЫ






Тепловые карты в корреляционном анализе



Тепловые карты

Это графическое представление данных, в котором отдельные значения представлены цветами. Каждая ячейка тепловой карты показывает коэффициент корреляции между двумя переменными, а интенсивность цвета указывает на силу корреляции.

Создание корреляционной тепловой карты



Интерпретация корреляционных тепловых карт



Цветовое кодирование



Диагональная линия



Симметрия

Положительная корреляция



Описание

Переменные, которые увеличиваются вместе, показывают сильную положительную корреляцию, представленную темно-красными ячейками.

Пример

В наборе данных об атрибутах автомобиля размер двигателя и мощность лошадиных сил могут показать сильную положительную корреляцию.

Отрицательная корреляция



Описание

Переменные, которые движутся в противоположных направлениях, демонстрируют сильную отрицательную корреляцию, представленную темно-синими ячейками.

Пример

В наборе данных экономических показателей уровень безработицы и рост ВВП могут показать сильную отрицательную корреляцию.

Отсутствие корреляции



Описание

Переменные, которые не показывают никакой предсказуемой взаимосвязи, имеют коэффициенты корреляции, близкие к нулю, и представлены белыми или светло-голубыми ячейками.

Ограничения визуальной интерпретации

- Переуплотнение
- Субъективность
- Нелинейные взаимосвязи
- Вводящие в заблуждение корреляции

Практические приложения



Эксплораторный анализ данных (EDA)

Выбор признаков

Выявление выбросов



ВОПРОСЫ





**“Корреляция не
подразумевает
причинно-следственной
связи”**

Корреляция не подразумевает причинно-следственной связи



Эта фраза означает невозможность обоснованно вывести причинно-следственную связь между двумя событиями или переменными только на основании наблюдаемой ассоциации или корреляции между ними.

Почему корреляция не равна причинности

- Сбивающие переменные
- Проблема направленности
- Совпадение



Примеры:

- Продажи мороженого и смертность от утопления.
- Количество магистров и кассовые сборы.
- Физические упражнения и рак кожи.

Ключевые подходы установления причинно-следственной связи



Контролируемые эксперименты



Продольные исследования



Статистический контроль



Рандомизация



ВОПРОСЫ





ПРАКТИЧЕСКАЯ РАБОТА



Задание



Выполните тест хи-квадрат, чтобы определить, существует ли значимая связь между размером опухоли и злокачественностью в наборе данных «Рак молочной железы».



ВОПРОСЫ



Домашнее задание

1. С помощью библиотеки `scipy.stats` выполните независимый t-тест на наборе данных `tips` из `seaborn`. Сравните средний общий счет между курящими и некурящими.
2. С помощью библиотеки `statsmodels` выполните одновыборочный z-тест для набора данных по бриллиантам из `seaborn`. Проверьте, значительно ли отличается средняя цена бриллиантов от \$4000.
3. Используйте библиотеку `scipy.stats` для расчета коэффициента корреляции Пирсона между `total_bill` и `tip` в наборе данных `tips`.

Заключение

