


Python
for DA

Исследовательский анализ данных (EDA). Основной этап



Преподаватель

Портрет

Имя Фамилия

Текущая должность

Количество лет опыта

Какой у Вас опыт - ключевые кейсы

Самые яркие проекты

Дополнительная информация по вашему усмотрению

Корпоративный e-mail

Социальные сети (по желанию)

Важно

- 

Камера должна быть включена на протяжении всего занятия
- 

В течение занятия вопросы задавать в чате или когда преподаватель спрашивает, есть ли у Вас вопросы
- 

Вести себя уважительно и этично по отношению к остальным участникам занятия
- 

Организационные вопросы по обучению решаются с кураторами, а не на тематических занятиях
- 

Во время занятия будут интерактивные задания, будьте готовы включить камеру или демонстрацию экрана по просьбе преподавателя

Повторение

-  Цели исследовательского анализа данных
-  Инструменты EDA
-  Основные этапы EDA
-  Подключение модулей и загрузка и первоначальная проверка данных
-  Преобразование данных

План занятия

- Цели основного этапа EDA
- Одномерный анализ
- Двумерный анализ
- Многомерный анализ
- Заполнение пропущенных значений



ОСНОВНОЙ БЛОК





Цели основного этапа EDA

Цели этапа изучения данных



Проверка выбросов, закономерностей и тенденций в данных



Нахождение значимых закономерностей в данных



Получение углубленной информации о наборах данных для решения наших бизнес-задач



Определение принципа заполнения пропущенных значений в наборе данных.

Вывод описательных статистик

```
data.describe()
```

```
data.describe(include='all').T
```

	count	mean	std	min	25%	50%	75%	max
Year	7253.0	2013.365366	3.254421	1996.0000	2011.00	2014.00	2016.00	2.019000e+03
Kilometers_Driven	7253.0	58699.063146	84427.720583	171.0000	34000.00	53416.00	73000.00	6.500000e+06
Mileage	7251.0	18.224336	4.779547	0.0000	15.26	18.19	21.10	4.470882e+01
Engine	7207.0	1616.573470	595.285137	72.0000	1198.00	1493.00	1968.00	5.998000e+03
Power	7078.0	112.765214	53.493553	34.2000	75.00	94.00	138.10	6.160000e+02
Seats	7200.0	5.279722	0.811660	0.0000	5.00	5.00	5.00	1.000000e+01
New_Price	1003.0	21.339409	23.531486	2.7472	7.88	11.48	25.52	3.680000e+02
Price	6019.0	9.479468	11.187917	0.4400	3.50	5.64	9.95	1.600000e+02
Car_Age	7253.0	10.634634	3.254421	5.0000	8.00	10.00	13.00	2.800000e+01

Задание

Какие выводы можно сделать из описательных статистик?



ВОПРОСЫ





Одномерный анализ



Одномерный анализ

этот анализ проводится методами визуализации. Категориальные переменные можно визуализировать с помощью столбчатых и круговых диаграмм. Числовые переменные можно визуализировать с помощью гистограмм, диаграмм "ящик с усами", диаграмм плотности и др.

Распределение данных в каждом столбце

```
cat_cols=data.select_dtypes(include=['object']).columns.tolist()
num_cols = data.select_dtypes(include=np.number).columns.tolist()
print("Categorical Variables:")
print(cat_cols)
print("Numerical Variables:")
print(num_cols)
```

Визуализация числовых переменных

```
for col in num_cols:
    print(col)
    plt.figure(figsize = (15, 4))
    plt.subplot(1, 2, 1)
    data[col].hist(grid=False)
    plt.ylabel('count')
    plt.subplot(1, 2, 2)
    sns.boxplot(x=data[col])
    plt.show()
```

Визуализация категориальных переменных

```
fig, axes = plt.subplots(3, 2, figsize = (18, 18))
for i in range(len(cat_cols)):
    sns.countplot(ax = axes[i//2, i%2], x = cat_cols[i], data = data, color =
'blue')
axes[0][0].tick_params(labelrotation=45)
axes[2][0].tick_params(labelrotation=90)
axes[2][1].tick_params(labelrotation=90)
plt.show()
```




Логарифмическое преобразование

статистический метод, применяемый для предобработки данных, который помогает улучшить их аналитическую обрабатываемость. Преобразование заключается в применении логарифма к каждому значению переменной.

Логарифмическое преобразование

```
for colname in ['Kilometers_Driven', 'Price']:  
    data[colname + '_log'] = np.log1p(data[colname])
```



ВОПРОСЫ





Двумерный анализ



Двумерный анализ

Двумерный анализ помогает понять, как независимые переменные связаны друг с другом, а также как независимые переменные влияют на зависимые. Для числовых столбцов двумерный анализ выполняется с помощью парных графиков и диаграмм рассеяния. Для категориальных переменных используются столбчатые диаграммы разных типов.

Построение парного графика

```
plt.figure(figsize=(13,17))  
sns.pairplot(data)  
plt.show()
```

Сокращение столбцов

```
plt.figure(figsize=(13,17))  
sns.pairplot(data[['Kilometers_Driven_log', 'Mileage', 'Engine', 'Power',  
                  'Seats', 'Price_log', 'Car_Age']])  
plt.show()
```

Задание

Задание

Какие выводы можно сделать из парных графиков?

Построение столбчатых диаграмм

```
fig, axarr = plt.subplots(3, 2, figsize=(8, 12))
for i in range(len(cat_cols)):
    data.groupby(cat_cols[i])['Price_log'].mean().\
    head(20).plot.bar(ax=axarr[i//2][i%2])
plt.subplots_adjust(hspace=0.8)
plt.show()
```

Построение столбчатых диаграмм

```
fig, axarr = plt.subplots(1, 2)
data.groupby('Seats')['Price_log'].mean().plot.bar(ax=axarr[0])
data.groupby('Car_Age')['Price_log'].mean().plot.bar(ax=axarr[1])
plt.show()
```

Задание

Какие выводы можно сделать из столбчатых диаграмм?



ВОПРОСЫ





Многомерный анализ



Многомерный анализ

исследует более двух переменных для определения взаимосвязей между ними и анализа закономерностей. Чаще всего для этих целей используется тепловая карта, показывающая корреляцию между переменными.

Построение тепловой карты

```
plt.figure()  
sns.heatmap(data[['Kilometers_Driven_log', 'Kilometers_Driven', 'Mileage',  
                  'Engine', 'Power', 'Seats', 'Price_log', 'Price', 'Car_Age']].corr(), annot =  
True)  
plt.show()
```



ВОПРОСЫ





**Заполнение
пропущенных
значений**

Способы заполнения пропущенных значений

-  Заполнение средним
-  Заполнение медианным
-  Заполнение наиболее встречающимся
-  Заполнение нулевым значениям
-  Использование сложных интерполяционных алгоритмов

Убрать нулевые значения

```
data.loc[data["Mileage"]==0.0, 'Mileage']=np.nan  
data.Mileage.isnull().sum()
```

Заполнение средним арифметическим

```
data['Mileage'] = data['Mileage'].fillna(value=np.mean(data['Mileage']))
```

Заполнение пропущенных значений

```
median_values = data.groupby(['Model', 'Brand'])['Seats'].transform('median')  
data.loc[data['Seats'].isnull(), 'Seats'] = data['Seats'].fillna(median_values)
```

Подведение итогов



Не существует определенных или идеальных правил для заполнения пропущенных значений в наборе данных. Каждый метод может работать лучше для одних наборов данных, но может работать хуже для других. Только практика и эксперименты позволяют понять, что работает лучше.

Выводы по проведенному анализу



В продаже мало двухместных автомобилей, а цена на такие автомобили высокая.



Цена автомобиля снижается с увеличением его возраста.



Клиенты предпочитают покупать автомобиль у первого владельца, а не у второго или третьего.



Цена электромобилей высокая, а предложений мало.



Стоимость автомобилей с АКПП выше, чем с ручной коробкой, но в продаже таких моделей меньше



ВОПРОСЫ





ПРАКТИЧЕСКАЯ РАБОТА



Задание



Заполните пропуски в столбцах Engine и Power средними значениями для данных моделей.

Проверьте, остались ли еще в датасете пропущенные значения. Почему? Что с ними можно сделать?

Что вы думаете о пропусках в столбце Price? Есть ли удачная стратегия их заполнения?



ВОПРОСЫ





СОХРАНЕНИЕ РЕЗУЛЬТАТОВ



Pickling

```
#запись датафрейма в файл
data.to_pickle("cars.pkl")
```

Unpickling

```
#чтение датафрейма из файла
new_df=pd.read_pickle("cars.pkl")
new_df.info()
```

Домашнее задание

1. Повторите первичный анализ датасета [used_cars_data](#) после всех преобразований, сделанных на уроке. Определите, типы каких столбцов теперь можно изменить. Сделайте это.
2. Повторите одномерный анализ прологорифмированных столбцов и столбцов, в которых были заполнены пропущенные значения.
3. Выведите информацию о самых крайних выбросах всех столбцов. Проанализируйте, есть ли среди них ошибки ввода. Ликвидируйте их любым способом, учитывающим специфику данных

Заключение

