

Python
for DA

Summary Session 9



Преподаватель

Портрет

Имя Фамилия

Текущая должность

Количество лет опыта

Какой у Вас опыт - ключевые кейсы

Самые яркие проекты

Дополнительная информация по вашему усмотрению

Корпоративный e-mail

Социальные сети (по желанию)

Важно

-  Камера должна быть включена на протяжении всего занятия
-  В течение занятия вопросы задавать в чате или когда преподаватель спрашивает, есть ли у Вас вопросы
-  Вести себя уважительно и этично по отношению к остальным участникам занятия
-  Организационные вопросы по обучению решаются с кураторами, а не на тематических занятиях
-  Во время занятия будут интерактивные задания, будьте готовы включить камеру или демонстрацию экрана по просьбе преподавателя



ПОВТОРЕНИЕ ИЗУЧЕННОГО



Экспресс-опрос

?

Что такое вероятностное сэмпирование?



Вероятностное сэмплирование

фундаментальный метод статистики, при котором каждый член генеральной совокупности имеет известный ненулевой шанс быть отобранным. Этот метод гарантирует, что выборка является репрезентативной по отношению к генеральной совокупности, что позволяет исследователям делать достоверные выводы обо всей генеральной совокупности

Простая случайная выборка

Простая случайная выборка - это самая основная форма вероятностной выборки. При этом методе каждый член генеральной совокупности имеет равные шансы быть отобранным



Определите совокупность: Перечислите всех членов генеральной совокупности.



Присвоить номера: Присвойте уникальный номер каждому члену генеральной совокупности.



Случайный выбор: Используйте генератор случайных чисел или другой метод рандомизации для отбора выборки.

Пример



Представьте, что у вас есть школа с 1 000 учеников, и вы хотите опросить 100 из них. Вы можете присвоить каждому ученику номер от 1 до 1 000 и использовать генератор случайных чисел для выбора 100 номеров. Студенты, соответствующие этим номерам, и будут вашей выборкой.

Сравнение выборки



Плюсы

- Простота и легкость реализации.
- Минимизирует предвзятость, поскольку каждый участник имеет равные шансы на выборку.

Минусы

- Требуется полный список генеральной совокупности.
- Может быть непрактичным для очень больших генеральных совокупностей.

Стратифицированная случайная выборка

Стратифицированная случайная выборка предполагает разделение генеральной совокупности на подгруппы (страты) на основе общих характеристик (например, возраст, пол, уровень дохода), а затем случайную выборку из каждой страты.



Определите генеральную совокупность и страты: Определите характеристики, по которым будет проводиться стратификация, и соответствующим образом разделите генеральную совокупность.



Случайный отбор внутри страт: Для отбора выборки используйте простую случайную выборку в пределах каждой страты.

Пример



Предположим, вы хотите изучить средний балл студентов колледжа на разных специальностях. Вы можете разделить студентов на страты в зависимости от их специальности (например, наука, искусство, инженерное дело), а затем случайным образом отобрать студентов из каждой специальности.

Сравнение выборки



Плюсы

- Обеспечивает представительство всех подгрупп.
- Уменьшает ошибки выборки за счет контроля вариативности внутри страт.

Минусы

- Более сложный и трудоемкий метод, чем простая случайная выборка.
- Требуется подробная информация о генеральной совокупности для создания страт.

Экспресс-опрос

?

Что такое кластерная выборка?

Кластерная выборка

Кластерная выборка предполагает разделение совокупности на кластеры, обычно основанные на географических или организационных границах, а затем случайный отбор всех кластеров.



Определите кластеры: Разделите совокупность на кластеры.



Случайный выбор кластеров: Случайным образом выберите несколько кластеров.



Включите в выборку всех членов выбранных кластеров.

Пример



Если вы хотите исследовать домохозяйства в городе, вы можете разделить город на районы (кластеры) и случайным образом выбрать несколько районов. Затем вы опросите все домохозяйства в этих выбранных районах.

Сравнение выборки



Плюсы

- Экономичность и практичность для больших групп генеральной совокупности.
- Полезно, когда нет возможности получить полный список генеральной совокупности.

Минусы

- Большая ошибка выборки по сравнению с другими методами, если кластеры неоднородны.
- Результаты могут быть менее точными, если кластеры значительно отличаются друг от друга.

Систематическая выборка

Систематическая выборка предполагает отбор каждого n -го члена генеральной совокупности после случайного начала.



Определите совокупность: Перечислите всех членов генеральной совокупности.



Случайный старт: Случайным образом выберите начальную точку между 1 и k . Случайный старт: Случайным образом выберите начальную точку между 1 и k .



Случайный старт: Случайным образом выберите начальную точку между 1 и k .



Выберите каждого n -го члена: Из начальной точки выберите каждый n -й член.

Пример



Если у вас есть список из 1 000 сотрудников и вы хотите отобрать выборку из 100 человек, задайте интервал (k) равным 10. Если ваше случайное начало равно 3, вы выберете 3-го, 13-го, 23-го и так далее.

Сравнение выборки



Плюсы

- Простота и легкость реализации.
- Обеспечивает распределение по всей генеральной совокупности.

Минусы

- Может внести погрешность, если в списке генеральной совокупности есть скрытая закономерность.
- Менее случайна, чем простая случайная выборка.



Центральная предельная теорема (ЦПТ)

это фундаментальный принцип в области статистики, служащий краеугольным камнем для inferential statistics, которая предполагает составление прогнозов или выводов о совокупности на основе выборки данных.

Центральная предельная теорема утверждает



Если взять достаточно большие случайные выборки из генеральной совокупности, то распределение выборочных средних будет приближаться к нормальному распределению (колоколообразной кривой), независимо от формы распределения исходной генеральной совокупности



Основа для статистических методов

Многие статистические методы, включая проверку гипотез и построение доверительных интервалов, предполагают, что данные следуют нормальному распределению. ЦПТ обеспечивает теоретическую основу для этого предположения, даже если данные, лежащие в основе



Предсказуемость и стабильность

Гарантируя, что выборочное распределение среднего приближается к нормальному распределению, ЦПТ обеспечивает предсказуемость и стабильность. Это позволяет статистикам делать точные выводы о генеральной совокупности на основе выборочных данных, повышая надежность статистических анализов.



Универсальность в различных дисциплинах

Применимость ЦПТ к различным типам распределений данных делает его универсальным инструментом в различных областях, включая экономику, биологию, производство и другие. Он позволяет исследователям и аналитикам применять статистические методы к своим данным, независимо от их исходного распределения.



Перекошенные распределения

Для совокупностей с асимметричным распределением ЦПТ позволяет использовать для статистического анализа методы, основанные на нормальном распределении, поскольку при достаточно большом объеме выборки распределение средних становится приблизительно нормальным.



Равномерные распределения

Даже для равномерных распределений, когда данные распределены равномерно, ЦПТ гарантирует, что распределение выборочных средних будет стремиться к нормальности, что облегчает применение стандартных статистических тестов.



Дискретные и непрерывные данные

ЦПТ применим как к дискретным (счетным), так и к непрерывным (измеряемым) типам данных. Это означает, что независимо от того, имеете ли вы дело со счетными данными (например, количество дефектных изделий) или измерительными данными (например, вес или высота), ЦПТ позволяет использовать статистические методы, основанные на нормальном распределении.

Основные следствия из ЦПТ

Нормальное распределение
выборочных средних

Влияние на размер выборки
и точность выводов



Нормальное распределение выборочных средних

гарантирует, что распределение выборочных средних будет приближаться к нормальному распределению, независимо от исходного распределения генеральной совокупности.

Пример



Рассмотрим фабрику по производству лампочек. Срок службы этих лампочек может быть распределен не совсем нормально; возможно, большинство из них служат около года, но некоторые - значительно дольше. Если фабрика проверит срок службы случайных образцов лампочек и вычислит среднее значение срока службы для каждого образца, то благодаря ЦПТ распределение этих средних значений будет приближаться к нормальному распределению. Это позволяет фабрике делать надежные прогнозы относительно общего качества продукции.

Экспресс-опрос

?

Какой размер выборки предпочтителен?



Размер выборки

ЦПТ более эффективен, когда размер выборки велик. Хотя понятие "большой" может быть субъективным, общепринятое эмпирическое правило гласит, что размер выборки 30 или более является достаточным для того, чтобы ЦПТ работал. Это означает, что при выборке 30 или более распределение выборочных средних приближается к нормальному распределению, что делает наши статистические анализы более надежными.



Точность выводов

Точность выводов, сделанных на основе выборочных данных, повышается по мере увеличения размера выборки. Большие выборки дают больше информации о генеральной совокупности и уменьшают погрешность наших оценок. Это означает, что мы можем быть более уверены в своих выводах о генеральной совокупности, основанных на данных выборки. Например, если исследователь изучает влияние нового метода обучения на успеваемость студентов, использование больших выборок для исследования позволит получить более точные и надежные результаты об эффективности метода обучения.



Практическое соображение

Хотя большие выборки, как правило, лучше, они также требуют больше ресурсов для сбора и анализа. Исследователи должны соизмерять стремление к точным выводам с практическими ограничениями своих исследований, такими как время, бюджет и доступность данных.



Выборочные распределения

Ключевое понятие в статистике, особенно в контексте Центральной предельной теоремы (ЦПТ). Они позволяют понять поведение выборочных статистик (например, среднего значения) и сделать выводы о совокупности, из которой взяты выборки.

Экспресс-опрос

?

Что такое `random.sample(seq, n)`?



`random.sample(seq, n)`

Генерирует n уникальных образцов из последовательности без замены.



`random.choices(seq, n)`

Генерирует n образцов из последовательности с заменой.



`random.randint(a, b)`

Генерирует случайное целое число от a до b (включительно).



`numpy.random.normal(loc, scale, size)`

Генерирует случайные выборки из нормального распределения с заданными средним значением (`loc`), стандартным отклонением (`scale`) и размером выборки (`size`).

Моделирование выборочных распределений



Практическое упражнение

В этом упражнении мы будем моделировать выборочные распределения, генерируя случайные выборки из генеральной совокупности и вычисляя выборочные средние. Затем мы построим график распределения этих выборочных средних, чтобы проследить влияние размера выборки на форму распределения.

Шаг 1: Импорт необходимых библиотек

```
import numpy as np
import matplotlib.pyplot as plt
import scipy.stats as stats
```

Шаг 2: Генерируем случайные выборки

```
# Параметры генеральной совокупности
mu = 50
sigma = 10

# Функция для генерации случайных выборок и вычисления выборочных средних
def generate_sample_means(sample_size, num_samples):
    sample_means = []
    for _ in range(num_samples):
        sample = np.random.normal(mu, sigma, sample_size)
        sample_means.append(np.mean(sample))
    return sample_means
```

Шаг 3: Моделирование распределений

```
# Параметры для моделирования
sample_sizes = [10, 30, 50, 100]
num_samples = 1000

# Построение графиков выборочных распределений
plt.figure(figsize=(12, 8))

for i, sample_size in enumerate(sample_sizes):
    sample_means = generate_sample_means(sample_size, num_samples)
    plt.subplot(2, 2, i+1)
    plt.hist(sample_means, bins=30, density=True, alpha=0.6, color='g')
    plt.title(f'Размер выборки = {sample_size}')
    plt.xlabel('Среднее значение выборки')
    plt.ylabel('Частота')
    # Постройте график нормального распределения для сравнения
    xmin, xmax = plt.xlim()
    x = np.linspace(xmin, xmax, 100)
    p = stats.norm.pdf(x, mu, sigma/np.sqrt(sample_size))
    plt.plot(x, p, 'k', linewidth=2)

plt.tight_layout()
plt.show()
```



Малый размер выборки ($n=10$)

Распределение выборочных средних может выглядеть не совсем нормальным и может быть весьма разбросанным.



Умеренный размер выборки ($n=30$)

Распределение начинает больше походить на нормальное распределение.



Большие размеры выборки ($n=50$, $n=100$)

Распределение выборочных средних становится более плотно сгруппированным вокруг среднего значения генеральной совокупности и приближается к нормальному распределению.

Шаг 1: Поймите теорему о центральном пределе



ЦПТ говорит нам, что при достаточно большом объеме выборки (обычно $n \geq 30$), выборочное распределение среднего значения выборки будет приблизительно нормально распределено со средним значением μ (среднее значение генеральной совокупности) и стандартным отклонением

$$\frac{\sigma}{\sqrt{n}}$$

(стандартная ошибка), где σ - стандартное отклонение генеральной совокупности и n - объем выборки.

Шаг 2: Определение параметров



Чтобы применить ЦПТ, необходимо знать или оценить следующие параметры:

- Среднее значение генеральной совокупности (μ)
- Стандартное отклонение генеральной совокупности (σ)
- Размер выборки (n)
- Диапазон, в котором вы хотите найти вероятность для среднего значения выборки.

Шаг 3: Вычислите стандартную ошибку



Стандартная ошибка среднего (SEM) рассчитывается следующим образом $\frac{\sigma}{\sqrt{n}}$

Это измеряет дисперсию выборочных средних вокруг среднего генеральной совокупности.

Шаг 4: Стандартизация диапазона



Преобразуйте интересующий вас диапазон для выборочного среднего в z-score по формуле:

$$Z = \frac{\bar{x} - \mu}{SEM}$$

где $\bar{x}$ - это значение в диапазоне, для которого вы рассчитываете z-score. Сделайте это как для нижней, так и для верхней границы диапазона.

Шаг 5: Используйте стандартное нормальное распределение



Рассчитав z-score, используйте стандартное нормальное распределение, чтобы найти вероятности, соответствующие этим z-score. Это можно сделать с помощью таблиц стандартного нормального распределения или статистического программного обеспечения.

Шаг 6: Вычислите вероятность



Вероятность того, что выборочное среднее попадает в указанный диапазон, равна разности между вероятностями, соответствующими z-score верхней и нижней границ.

Если $P(Z < z_{\text{верхняя}})$ - это вероятность верхней границы, а $P(Z < z_{\text{нижняя}})$ - это вероятность для нижней границы, тогда вероятность того, что выборочное среднее попадает в диапазон, равна:

$$P(z_{\text{нижняя}} < Z < z_{\text{верхняя}}) = P(Z < z_{\text{верхняя}}) - P(Z < z_{\text{нижняя}}).$$



ВОПРОСЫ



Экспресс-опрос

?

Что такое доверительные интервалы (ДИ)?



Доверительные интервалы (ДИ)

Доверительные интервалы (ДИ) - это фундаментальное понятие в статистике, представляющее собой диапазон, в котором, как мы ожидаем, будет находиться параметр генеральной совокупности (например, среднее значение или доля) на основе данных выборки.



Доверительный интервал

это диапазон значений, рассчитанный на основе данных выборки, который с большой вероятностью содержит значение неизвестного параметра генеральной совокупности. Интервал имеет соответствующий уровень доверия, который определяет степень уверенности в том, что в интервал входит параметр.

Цель доверительного интервала

Оценка

Он предоставляет диапазон, который, вероятно, содержит параметр генеральной совокупности. В отличие от точечной оценки (например, среднего значения выборки), которая предполагает конкретное значение, доверительный интервал предоставляет диапазон, предлагая более тонкий взгляд на оценку.

Измерение неопределенности

Количественно определяет неопределенность вокруг оценки. Ширина интервала отражает степень неопределенности: более широкий интервал говорит о большей неопределенности, а более узкий - о меньшей.



Уровень доверия и ширина доверительного интервала

неразрывно связаны между собой. уровень доверия, обычно выражаемый в процентах (например, 90%, 95% или 99%), показывает, насколько мы можем быть уверены в том, что интервал содержит параметр генеральной совокупности



Более высокий уровень доверия

Повышение уровня доверия означает, что мы хотим получить больше уверенности в том, что наш интервал содержит истинный параметр. Однако за это приходится платить: чтобы повысить уровень доверия, мы должны расширить наш интервал. 99%-ный доверительный интервал будет шире 95%-ного, что отражает большую неопределенность в отношении точного значения параметра, но больше уверенности в том, что интервал включает его.



Снижение уровня доверия

Уменьшение уровня доверия приводит к сужению интервала. Это говорит о меньшей неопределенности в отношении значения параметра, но и о меньшей уверенности в том, что интервал содержит параметр. Доверительный интервал 90% будет более узким, чем доверительный интервал 95%, что указывает на компромисс между точностью и достоверностью.

Расчет доверительных интервалов



формула для доверительного интервала вокруг среднего значения, когда известно стандартное отклонение генеральной совокупности, выглядит следующим образом:

$$\bar{x} \pm Z \times \frac{\sigma}{\sqrt{n}}$$

где $\bar{x}$ - среднее значение по выборке, Z - Z-score, соответствующий выбранному уровню доверия (например, 1,96 для 95%), σ - стандартное отклонение генеральной совокупности, и n - размер выборки.

Доверительный интервал для доли генеральной совокупности



рассчитывается по формуле:

$$p \pm Z \times \sqrt{\frac{p(1-p)}{n}}$$

где p - выборочная доля, Z - Z-score, соответствующий желаемому уровню доверия, n - объем выборки. В этой формуле предполагается, что объем выборки достаточно велик, чтобы биномиальное распределение было аппроксимировано нормальным распределением, обычно $np \geq 5$ и $n(1-p) \geq 5$.



95%-ный доверительный интервал

представляет собой диапазон значений, в пределах которого мы можем быть на 95% уверены в том, что истинный параметр генеральной совокупности (например, среднее значение или доля) находится на основе данных выборки. Эта интерпретация основана на подходе к доверительным интервалам с учетом долгосрочной частоты. Если бы мы повторяли исследование много раз, каждый раз рассчитывая новый 95%-ный ДИ на основе новой выборки, мы бы ожидали, что около 95% этих интервалов будут содержать истинный параметр генеральной совокупности.

Заблуждение 1

Заблуждение

ДИ содержит 95% данных

Пояснение

95%-ный ДИ - это не про собранные данные, а про то, где находится истинный параметр генеральной совокупности. Он не означает, что 95% данных выборки попадают в этот интервал.



Заблуждение 2



Заблуждение

Вероятность того, что истинный параметр лежит в пределах интервала, составляет 95 %.

Пояснение

После того как по выборке рассчитан ДИ, истинный параметр генеральной совокупности либо находится, либо нет в пределах этого интервала. Вероятность 95%" относится к долгосрочной частоте ДИ, содержащих параметр, при многократном повторении исследования, а не к вероятности того, что один интервал содержит параметр.

Заблуждение 3



Заблуждение

Более узкий интервал означает, что параметр с большей вероятностью будет в нем находиться

Пояснение

Ширина ДИ отражает точность оценки, а не вероятность того, что она содержит истинный параметр. Более узкий ДИ указывает на меньшую вариабельность и более точную оценку параметра, но не меняет уровень доверия.

Заблуждение 4



Заблуждение

Перекрывающиеся ДИ указывают на отсутствие существенной разницы

Пояснение

Перекрывающиеся ДИ между двумя группами не обязательно означают отсутствие значимых различий между группами. Для определения значимости различий необходимы статистические тесты.

Как избежать неверных интерпретаций



Ориентируйтесь на долгосрочную частоту: Поймите, что уровень доверия относится к надежности метода на протяжении многих повторений исследования, а не к уверенности в том, что параметр находится в одном интервале.



Точность против вероятности: Поймите, что ширина ДИ указывает на точность оценки, а не на вероятность содержания истинного параметра.



Статистическая значимость: Используйте соответствующие статистические тесты для оценки значимости различий между группами, а не полагайтесь только на перекрытие ДИ.

Биология



Биологи используют доверительные интервалы для оценки характеристик видов растений и животных, таких как средний рост, вес или диаметр. Например, биолог может рассчитать 95%-ный доверительный интервал для оценки среднего веса лягушек в Австралии на основе выборки, чтобы получить диапазон, в который, скорее всего, попадет истинный средний вес.

Клинические испытания



В медицине доверительные интервалы имеют решающее значение для оценки эффективности лечения. Врач может использовать 95%-ный доверительный интервал для определения среднего изменения артериального давления у пациентов, принимающих новое лекарство, что поможет понять эффективность препарата и направить дальнейшие исследования или клиническое применение.

Реклама и маркетинг



Доверительные интервалы помогают отделам маркетинга оценивать эффективность рекламных кампаний. Сравнивая продажи, полученные в результате различных кампаний, с помощью доверительных интервалов, маркетологи могут определить, значительно ли кампания увеличивает доход, и тем самым определить будущие рекламные стратегии.

Производство



Инженеры используют доверительные интервалы в процессах контроля качества для оценки изменений в производстве бракованной продукции. Например, если считается, что новый производственный процесс снижает количество дефектов, доверительный интервал может помочь определить, являются ли наблюдаемые изменения в количестве дефектов статистически значимыми, что позволит усовершенствовать процесс.



Неправильная интерпретация

Распространенное заблуждение заключается в том, что 95%-ный доверительный интервал означает, что существует 95%-ная вероятность того, что интервал содержит истинный параметр. Однако правильная интерпретация заключается в том, что если эксперимент повторить много раз, то 95% рассчитанных КИ будут содержать истинный параметр. Это различие крайне важно для точной интерпретации.



Предположение о нормальности

Во многих расчетах КИ предполагается, что данные распределены нормально или что объем выборки достаточно велик, чтобы можно было применить теорему о центральном пределе. Это предположение может быть справедливо не для всех наборов данных, что может привести к неточным интервалам.



Фиксированный уровень доверия

Выбор доверительного уровня (например, 95 %) является несколько произвольным и может не отражать фактическую неопределенность оценки. Различные доверительные уровни дают интервалы разной ширины, что влияет на точность оценки.



Не учитывают систематические ошибки

Доверительные интервалы учитывают случайную ошибку выборки, но не учитывают возможные систематические ошибки или смещения в процессе сбора данных. Такие ошибки могут привести к неверным выводам, независимо от рассчитанного КИ



Зависимость от размера выборки

Ширина доверительного интервала находится в обратной зависимости от квадратного корня из размера выборки, то есть меньшие выборки дают более широкие интервалы. Это может привести к менее точным оценкам, особенно в исследованиях с ограниченным объемом данных.

Шаг 1: Импорт необходимых библиотек

```
import numpy as np  
import scipy.stats as st  
import matplotlib.pyplot as plt
```

Шаг 2: Определите выборку

```
# Генерируем выборку  
np.random.seed(0) # Для воспроизводимости  
data = np.random.normal(loc=100, scale=15, size=50) # loc=mean, scale=std,  
size=размер выборки
```

Шаг 3: Рассчитайте доверительный интервал

```
# Рассчитайте среднее значение и стандартную ошибку среднего
mean = np.mean(data)
sem = st.sem(data) # Стандартная ошибка среднего

# Определите доверительный интервал
confidence = 0.95

# Вычислить доверительный интервал
ci = st.t.interval(alpha=confidence, df=len(data)-1, loc=mean, scale=sem)

print(f "95% доверительный интервал (с использованием t-распределения): {ci}")
```

Шаг 4: Вычислите доверительный интервал

```
# Для больших наборов данных мы можем использовать нормальное распределение
ci_large = st.norm.interval(alpha=confidence, loc=mean, scale=sem)

print(f "95% доверительный интервал (с использованием нормального
распределения): {ci_large}")
```

Шаг 5: Визуализация доверительных интервалов

```
# Построение графика данных выборки
plt.figure(figsize=(10, 6))
plt.hist(data, bins=15, alpha=0.7, label='Sample Data')

# Построение графика среднего значения
plt.axvline(mean, color='red', linestyle='dashed', linewidth=2, label='Mean')

# Выделение доверительного интервала
plt.axvspan(ci[0], ci[1], color='yellow', alpha=0.3, label='95% CI (t-
распределение)')
plt.axvspan(ci_large[0], ci_large[1], color='green', alpha=0.3, label='95% CI
(нормальное распределение)')

plt.xlabel('Данные')
plt.ylabel('Частота')
plt.title('Выборка с доверительными интервалами')
plt.legend()
plt.show()
```



Проверка гипотез

фундаментальная концепция статистики и науки о данных, играющая важнейшую роль в методологии исследований в различных областях, таких как бизнес, здравоохранение и наука.



Нулевая гипотеза (H_0)

Нулевая гипотеза обычно представляет собой гипотезу о равенстве параметров генеральной выборки. Она представляет собой утверждение об отсутствии эффекта, связи или различий между выборкой и генеральной совокупностью. Она принимается за истинную до тех пор, пока не будет получено достаточно доказательств, чтобы ее отвергнуть.



Альтернативная гипотеза (H_1)

Альтернативная гипотеза по сути является обратной по отношению к нулевой гипотезе. Она представляет собой утверждение, указывающее на наличие эффекта, взаимосвязи или различий между выборкой и генеральной совокупностью. Альтернативная гипотеза - это то, что исследователи стремятся подтвердить с помощью анализа данных.

Пример 1



Преподаватель предполагает, что 60 % студентов его колледжа - выходцы из семей ниже среднего класса. В этом случае нулевой гипотезой (H_0)

Пример 1



Преподаватель предполагает, что 60 % студентов его колледжа - выходцы из семей ниже среднего класса. В этом случае нулевой гипотезой (H_0) может быть то, что реальный процент студентов из семей ниже среднего класса составляет 60 %, а альтернативной гипотезой (H_1) - то, что этот процент не составляет 60 %.

Пример 2



Врач считает, что программа 3D (диета, доза и дисциплина) на 90 % эффективна для пациентов с диабетом. Нулевая гипотеза (H_0) может утверждать, что эффективность программы 3D составляет 90 %, а альтернативная гипотеза (H_1) - что эффективность отличается от 90 %.



Ошибка первого типа (ложноположительная)

Ошибка первого типа возникает, когда нулевая гипотеза (H_0) ошибочно отвергается, когда на самом деле она истинна. Этот тип ошибки также известен как ложноположительный. Вероятность совершения ошибки типа I обозначается α , который также называют уровнем значимости теста

Пример 1



В клинических испытаниях ошибка I типа может возникнуть, если новое лекарство будет признано эффективным в лечении какого-либо заболевания, а на самом деле это не так. Последствия ошибки первого типа могут быть значительными, что может привести к ненужному лечению, напрасной трате ресурсов или неправильным научным выводам.



Ошибка второго типа (ложноотрицательная)

И наоборот, ошибка II типа возникает, когда нулевая гипотеза не отвергается, а должна отвергаться, то есть тест не обнаруживает эффекта или различия, которые на самом деле существуют. Такая ошибка известна как ложноотрицательная. Вероятность совершения ошибки типа II обозначается как β , а мощность теста, то есть способность обнаружить эффект, если он есть, равна $1-\beta$

Пример 2



Ошибка второго типа в медицинском скрининг-тесте может не выявить заболевание у пациента, у которого оно действительно есть, что может привести к отсутствию необходимого лечения и ухудшению состояния здоровья.



ВОПРОСЫ



Экспресс-опрос

?

Что такое Р-значение?



P-значение

Это статистическая метрика, используемая для оценки доказательств против нулевой гипотезы путем сравнения их с наблюдаемыми данными. Представляет собой вероятность получения таких же или более экстремальных результатов, чем наблюдаемые, в предположении, что нулевая гипотеза верна.

Экспресс-опрос

?

Что такое уровень значимости (α)?



Уровень значимости (α)

Это порог, с которым сравнивается р-значение, чтобы решить, следует ли отвергать нулевую гипотезу.

Интерпретация р-значения

Если $p\text{-значение} \leq \alpha$

Результаты считаются статистически значимыми. Отклонение нулевой гипотезы в пользу альтернативной гипотезы.

Если $p\text{-значение} > \alpha$

Результаты не являются статистически значимыми. Нулевая гипотеза сохраняется.

Интерпретация p-значения



Ошибка

Низкое значение p-value не доказывает истинность альтернативной гипотезы.

Истина

Низкое значение p-value указывает на то, что наблюдаемые данные маловероятны в предположении, что нулевая гипотеза верна.

Интерпретация p-значения



Ошибка

Интерпретация p-значения как вероятности того, что нулевая гипотеза верна или ложна.

Истина

p-значение указывает лишь на вероятность наблюдения данных, если бы нулевая гипотеза была верна. Оно не дает прямой оценки вероятности самих гипотез.

Интерпретация p-значения



Ошибка

Рассматривать p-значение как вероятность совершить ошибку типа I (отвергнуть истинную нулевую гипотезу).

Истина


Значение p рассчитывается в предположении, что нулевая гипотеза верна, и само по себе не указывает на степень ошибки решения.

Как рассчитать p-значение



Метод расчета p-значения зависит от проводимого статистического теста

Общий подход к вычислению р-значения



Проверка гипотез с помощью р-значения

- Подход к проверке гипотез с помощью р-значения использует рассчитанную вероятность для определения того, есть ли доказательства для отклонения нулевой гипотезы.
- Определение зависит от тестовой статистики, которая обобщает информацию из выборки, относящуюся к проверяемой гипотезе.

Проверка гипотез с помощью р-значения



Значения p -value обычно находятся с помощью таблиц p -value или статистического программного обеспечения

Расчет p-значения

- Расчет p-значения зависит от типа проводимого теста.
- Предполагает использование интегрального исчисления от площади под кривой распределения вероятностей для всех значений статистики, которые находятся на таком же расстоянии от контрольного значения, как и наблюдаемое значение, по отношению к общей площади под кривой распределения вероятностей.



Важно:

Низкое значение p-value не обязательно является доказательством статистической значимости.

Экспресс-опрос



Что такое t-тесты?



t-тесты

Это категория статистических тестов, используемых для определения наличия или отсутствия значимых различий между средними показателями двух групп, которые могут быть связаны по определенным признакам.

Основные типы t-тестов



Одновыборочный



Двухвыборочный (независимые выборки)



Парный t-тест (зависимые выборки)

Одновыборочный t-тест



Использование

При сравнении среднего значения одной выборки с известным или предполагаемым средним значением генеральной совокупности.

Пример

Если компания по производству газировки утверждает, что ее банки содержат в среднем 12 унций газировки, можно взять несколько банок и использовать одновыборочный t-тест, чтобы проверить, отличается ли среднее количество от 12 унций.

Двухвыборочный t-тест



Использование

Сравнивает средние значения двух независимых групп, чтобы определить, есть ли статистические доказательства того, что соответствующие средние значения генеральных совокупностей значительно отличаются.

Пример

Если нужно сравнить средние результаты тестов двух разных классов учеников или средний рост мужчин и женщин.

Парный t-тест



Использование

Используется, когда выборки связаны или совпадают каким-либо образом.

Пример

Исследования "до и после" для определения эффекта вмешательства или лечения на одних и тех же испытуемых, а также сравнение совпадающих пар, например братьев и сестер.

Импорт необходимых библиотек

```
import numpy as np  
from scipy import stats
```

Одновыборочный Т-тест

Определение данных выборки и предполагаемого среднего значения генеральной совокупности:

```
# Данные выборки
```

```
data = np.array([98, 102, 95, 105, 99, 101, 97, 103, 100, 98])
```

```
# Гипотетическое среднее значение генеральной совокупности
```

```
popmean = 100
```

Одновыборочный T-тест

Выполнение одновыборочного t-теста:

```
t_statistic, p_value = stats.ttest_1samp(data, popmean)
```

Одновыборочный T-тест

Интерпретация результатов:

```
print(f"T-статистика: {t_statistic}")  
print(f"P-value: {p_value}")
```

Двухвыборочный Т-тест

Определение двух независимых выборок:

```
# Две независимые выборки  
group1 = np.random.normal(loc=10, scale=2, size=100)  
group2 = np.random.normal(loc=12, scale=2, size=100)
```

Двухвыборочный T-тест

Выполнение двухвыборочного t-теста:

```
t_statistic, p_value = stats.ttest_ind(group1, group2)
```

Двухвыборочный T-тест

Интерпретация результатов:

```
print(f"T-статистика: {t_statistic}")  
print(f"P-value: {p_value}")
```

Парный T-тест

Определение парных выборок:

```
# Парные выборки  
before = np.random.normal(loc=10, scale=2, size=30)  
after = before + np.random.normal(loc=0.5, scale=0.5, size=30)
```

Парный T-тест

Выполнение парного t-теста:

```
t_statistic, p_value = stats.ttest_rel(before, after)
```

Парный T-тест

Интерпретация результатов:

```
print(f"T-статистика: {t_statistic}")  
print(f"P-value: {p_value}")
```

Экспресс-опрос



Что такое Z-тест?



Z-тест

Это статистический метод, используемый для проверки гипотез, в частности при сравнении средних между двумя большими выборками или при сравнении среднего по выборке с определенным значением при условии, что дисперсия генеральной совокупности известна.

Основные характеристики Z-теста

-  Знание дисперсии генеральной совокупности
-  Большой размер выборки
-  Нормальное распределение
-  Типы Z-тестов

Типы Z-тестов

Одновыборочные Z-тесты

Сравнение выборочного среднего со средним значением известной генеральной совокупности

Двухвыборочные Z-тесты

Сравнение средних между двумя независимыми выборками

Парные Z-тесты

Сравнение средних из одной группы в разное время или при разных условиях

Общая формула Z-теста



$$Z = \frac{\bar{x} - \mu}{\sigma / \sqrt{n}}$$

где: $\bar{x}$ - среднее значение по выборке,
 μ - среднее значение генеральной совокупности (или гипотетическое среднее значение),
 σ - стандартное отклонение генеральной совокупности, и
 n - размер выборки.

Примеры



Одновыборочный Z-тест

Фабрика заявляет, что диаметр ее мячей составляет 5 см. Специалист по качеству проверяет 50 мячей и обнаруживает, что средний диаметр отличается от 5 см. Учитывая, что стандартное отклонение в генеральной совокупности равно 0.4, одновыборочный Z-тест позволяет определить, является ли разница статистически значимой.

Двухвыборочный Z-тест

Сравнение средних диаметров мячей, произведенных на двух разных фабриках, где известно стандартное отклонение диаметров, чтобы проверить, есть ли между ними существенная разница.

Одновыборочный Z-тест в Python



Исследователь хочет изучить влияние наставничества на показатели интеллекта. Стандартизированный тест IQ имеет среднее значение 100 и стандартное отклонение 16. 50 студентов, участвующих в исследовании, набрали в среднем 102 балла по тесту IQ. Исследователь хочет знать, является ли этот рост статистически значимым.

Одновыборочный Z-тест в Python

```
import scipy.stats as stats
from math import sqrt

# Заданные значения
x_bar = 102 # среднее значение выборки
n = 50 # количество студентов
sigma = 16 # стандартное отклонение генеральной совокупности
mu = 100 # среднее значение генеральной совокупности

# Вычисление Z-балла
z = (x_bar - mu) / (sigma / sqrt(n))

# Нахождение p-значения
p_value = stats.norm.sf(abs(z)) * 2 # тест с двумя хвостами

print(f"Z-score: {z}")
print(f"P-value: {p_value}")
```

Двухвыборочный Z-тест в Python



Фабрика в городах А и В производит мячи диаметром 5 см. Известно, что стандартное отклонение диаметра составляет 0,1. Специалист по качеству отбирает по 50 мячей с каждой фабрики, чтобы проверить, существенно ли отличаются диаметры мячей на двух фабриках.

Двухвыборочный Z-тест в Python

```
from statsmodels.stats.weightstats import ztest
import numpy as np

# Моделирование выборочных данных
np.random.seed(0)
factory_A = np.random.normal(loc=5, scale=0.1, size=50)
factory_B = np.random.normal(loc=5.1, scale=0.1, size=50)

# Выполнение двухвыборочного Z-теста
z_stat, p_value = ztest(factory_A, factory_B)

print(f"Z-статистика: {z_stat}")
print(f"P-value: {p_value}")
```



ztest из модуля statsmodels.stats.weightstats

Это функция, которая используется для проведения z-теста для среднего на основе нормального распределения, применимого для одной или двух выборок. Может быть использована для проверки гипотез о среднем или разнице в средних между двумя независимыми выборками.

Функция ztest



Функция `ztest` возвращает два значения: тестовую статистику (`tstat`) и `p`-значение (`pvalue`) `z`-теста, которые используются для определения статистической значимости наблюдаемого различия или эффекта.



ВОПРОСЫ



Экспресс-опрос

?

Что такое тест Хи-квадрат?



Тест Хи-квадрат

Это статистический метод, широко используемый при проверке гипотез, в частности при анализе категориальных данных. Предназначен для определения наличия значимой связи между двумя категориальными переменными.

Типы тестов Хи-квадрат

Тест Хи-квадрат на
добросовестность соответствия

Используется, когда есть одна категориальная переменная с двумя или более уровнями. Проверяет, соответствуют ли наблюдаемые частоты для одной категориальной переменной ожидаемым частотам для этих уровней.

Тест независимости (или
ассоциации) Хи-квадрат

Применяется, когда есть две категориальные переменные, и нужно оценить, есть ли между ними связь. Сравнивает наблюдаемые частоты в категориях одной переменной с категориями второй переменной с ожидаемыми частотами, рассчитанными в предположении, что переменные независимы.

Ключевые понятия и допущения

-  Наблюдаемые и ожидаемые частоты
-  Степени свободы
-  Р-значение
-  Допущения

Экспресс-опрос

?

Что такое scipy.stats?



scipy.stats

Это модуль, который предоставляет удобную функцию `chi2_contingency` для проведения теста Хи-квадрат в Python.

Экспресс-опрос

?

Что такое chi2_contingency?



`chi2_contingency`

Это функция, которая используется для выполнения теста независимости Хи-квадрат на таблице случайностей.

Импорт необходимых библиотек

```
import pandas as pd  
from scipy.stats import chi2_contingency
```

Экспресс-опрос

?

Что такое таблица случайностей?



Таблица случайностей

Это матрица, которая отображает распределение частот переменных.

Создание или загрузка таблицы КОНТИНГЕНТНОСТИ

```
# Пример таблицы случайностей
data = {'Preference': ['Like', 'Dislike', 'Neutral'],
        'Product_A': [20, 15, 25],
        'Product_B': [30, 10, 20]}

df = pd.DataFrame(data)
df.set_index('Preference', inplace=True)
print(df)
```

Выполнение теста хи-квадрат

```
# Выполнить тест Хи-квадрат
chi2, p, dof, expected = chi2_contingency(df)

print(f"Статистика хи-квадрат: {chi2}")
print(f"P-value: {p}")
print(f"Степени свободы: {dof}")
print("Ожидаемые частоты:")
print(expected)
```

Интерпретация результатов

Статистика хи-
квадрат

Измеряет
расхождение
между
наблюдаемыми и
ожидаемыми
частотами

P-значение

Указывает на
вероятность
наблюдения
данных, если
нулевая гипотеза
верна

Степени свободы
(Dof)

Рассчитывается как
(количество строк -
1) * (количество
столбцов - 1)

Ожидаемые
частоты (Expected
Frequencies)

Частоты,
ожидаемые при
нулевой гипотезе о
независимости

Пример с реальным набором данных

```
import seaborn as sns

# Загружаем набор данных "Титаник"
titanic = sns.load_dataset('titanic')

# Создайте таблицу случайностей
contingency_table = pd.crosstab(titanic['class'], titanic['survived'])
print(contingency_table)

# Выполните тест Хи-квадрат
chi2, p, dof, expected = chi2_contingency(contingency_table)

print(f"Статистика хи-квадрат: {chi2}")
print(f"P-value: {p}")
print(f"Степени свободы: {dof}")
print("Ожидаемые частоты:")
print(expected)
```

Экспресс-опрос



Что такое корреляция?



Корреляция

Это статистическая мера, которая выражает степень линейной зависимости двух переменных, то есть их совместное изменение с постоянной скоростью. Количественно определяет силу и направление связи между двумя переменными с помощью коэффициента корреляции, который обычно обозначается как r .

Важность изучения взаимосвязей между переменными с помощью корреляционного анализа

- Измерение взаимосвязи
- Экономические и поведенческие выводы
- Прогнозирование и принятие решений
- Основа для дальнейших исследований

Типы переменных в корреляционном анализе



Интервальные переменные

Это переменные, в которых разница между значениями значима, но нет истинной нулевой точки.

Коэффициентные переменные

Эти переменные обладают всеми свойствами интервальных переменных, но также имеют значимую нулевую точку, которая указывает на отсутствие измеряемой величины.

Коэффициент корреляции

$$r=+1$$

Означает идеальную
положительную
корреляцию, то есть обе
переменные растут
вместе

$$r=-1$$

Означает идеальную
отрицательную
корреляцию, то есть одна
переменная
увеличивается при
уменьшении другой

$$r=0$$

Указывает на отсутствие
корреляции, то есть
между переменными нет
предсказуемой связи

Экспресс-опрос

?

Что измеряет коэффициент корреляции Пирсона (r)?



Коэффициент корреляции Пирсона (r)

Измеряет линейную связь между двумя
непрерывными переменными.

Формула расчета коэффициента корреляции Пирсона



$$r = \frac{n\sum xy - (\sum x)(\sum y)}{\sqrt{n\sum x^2 - (\sum x)^2} \sqrt{n\sum y^2 - (\sum y)^2}}$$

где:

n - количество пар оценок,

x и y - отдельные точки выборки, индексируемые i .

Сила корреляции

0,0 - 0,3 (0 - -0,3)

Слабая положительная
(отрицательная)
корреляция

От 0,3 до 0,5
(от -0,3 до -0,5)

Умеренная положительная
(отрицательная)
корреляция

От 0,5 до 1,0
(от -0,5 до -1,0)

Сильная положительная
(отрицательная)
корреляция

Условие достоверности коэффициента корреляции Пирсона



Уровень измерения



Линейность



Нормальность



Связанные пары



Отсутствие выбросов

Экспресс-опрос

?

Что измеряет коэффициент ранговой корреляции Спирмена (ρ)?



Коэффициент ранговой корреляции Спирмена (ρ)

Измеряет силу и направление связи между двумя ранжированными переменными.

Формула расчета коэффициента ранговой корреляции Спирмена



$$\rho = 1 - \frac{6\sum d_i^2}{n(n^2-1)}$$

где:

d_i - разница между рангами каждой пары наблюдений.

n - количество наблюдений.

Шаги для расчета коэффициента ранговой корреляции Спирмена

1. Проранжировать данные
2. Вычислить разности
3. Возвести разности в квадрат
4. Сумма квадратных разностей
5. Применить формулу

Сила корреляции

0,0 - 0,1

От 0,1 до 0,3

От 0,3 до 0,5

От 0,5 до 0,7

От 0,7 до 1,0

Нет корреляции

Слабая
корреляция

Умеренная
корреляция

Высокая
корреляция

Очень высокая
корреляция

Использование ранговой корреляции Спирмена



Нелинейные отношения



Ординарные данные



Ненормальное распределение



Наличие выбросов

Экспресс-опрос

?


Что такое диаграмма рассеяния?



Диаграмма рассеяния

Это тип визуализации данных, который отображает взаимосвязь между двумя числовыми переменными. Каждая точка на диаграмме рассеивания представляет собой отдельную точку данных, положение которой определяется значениями двух переменных по оси x и оси y .

Интерпретация диаграммы рассеяния



Положительная корреляция



Пример

Взаимосвязь между температурой и продажами мороженого. При повышении температуры продажи мороженого также растут.

Визуализация

Точки образуют на диаграмме рассеяния наклонный вверх рисунок.

Отрицательная корреляция



Пример

Взаимосвязь между количеством часов, проведенных за просмотром телевизора, и успеваемостью. По мере увеличения количества часов, проведенных за просмотром телевизора, успеваемость снижается.

Визуализация

На диаграмме рассеяния точки образуют нисходящий наклон.

Отсутствие корреляции



Пример

Взаимосвязь между ростом человека и его любимым цветом. Между этими переменными нет связи.

Визуализация

Точки разбросаны беспорядочно, без четкой закономерности.

Ограничения визуальной интерпретации



Оверплоттинг



Субъективность



Ограниченность двумя переменными



Нелинейные взаимосвязи



Вводящие в заблуждение корреляции

Экспресс-опрос




Что такое тепловые карты?



Тепловые карты

Это графическое представление данных, в котором отдельные значения представлены цветами. Каждая ячейка тепловой карты показывает коэффициент корреляции между двумя переменными, а интенсивность цвета указывает на силу корреляции.

Создание корреляционной тепловой карты



Интерпретация корреляционных тепловых карт



Цветовое кодирование



Диагональная линия



Симметрия

Положительная корреляция



Описание

Переменные, которые увеличиваются вместе, показывают сильную положительную корреляцию, представленную темно-красными ячейками.

Пример

В наборе данных об атрибутах автомобиля размер двигателя и мощность лошадиных сил могут показать сильную положительную корреляцию.

Отрицательная корреляция



Описание

Переменные, которые движутся в противоположных направлениях, демонстрируют сильную отрицательную корреляцию, представленную темно-синими ячейками.

Пример

В наборе данных экономических показателей уровень безработицы и рост ВВП могут показать сильную отрицательную корреляцию.

Отсутствие корреляции



Описание

Переменные, которые не показывают никакой предсказуемой взаимосвязи, имеют коэффициенты корреляции, близкие к нулю, и представлены белыми или светло-голубыми ячейками.

Ограничения визуальной интерпретации

- Переуплотнение
- Субъективность
- Нелинейные взаимосвязи
- Вводящие в заблуждение корреляции

Практические приложения



Эксплораторный анализ данных (EDA)

Выбор признаков

Выявление выбросов

Корреляция не подразумевает причинно-следственной связи



Эта фраза означает невозможность обоснованно вывести причинно-следственную связь между двумя событиями или переменными только на основании наблюдаемой ассоциации или корреляции между ними.

Почему корреляция не равна причинности

- Сбивающие переменные
- Проблема направленности
- Совпадение



Примеры:

- Продажи мороженого и смертность от утопления.
- Количество магистров и кассовые сборы.
- Физические упражнения и рак кожи.

Ключевые подходы установления причинно-следственной связи



Контролируемые эксперименты



Продольные исследования



Статистический контроль



Рандомизация



ВОПРОСЫ





ЗАДАНИЕ



Задание

Завершить работу над задачами с практикумов 17 и 18.



Задание 1



Продemonстрируйте влияние размера выборки на форму распределения средних, используя экспоненциальное распределение.

Задание 2



Рассмотрим фабрику, производящую лампочки со средним сроком службы 1000 часов и стандартным отклонением 200 часов. Если взята выборка из 50 лампочек, используйте CLT, чтобы найти вероятность того, что среднее время жизни в выборке находится в диапазоне от 950 до 1050 часов.

Задание 3



Рассчитайте и визуализируйте 95% доверительный интервал для среднего значения популяции, используя малые размеры выборки ($n < 30$) из известной популяции.

Инструкции:

- Создайте нормально распределенную совокупность из 5 000 точек данных со средним значением 50 и стандартным отклонением 10.
- Произведите случайную выборку 25 точек данных из этой совокупности.
- Рассчитайте 95 %-ный доверительный интервал для среднего значения популяции по этой выборке, используя t-распределение.
- Нанесите на график данные выборки, среднее значение популяции и границы доверительного интервала.

Задание 4

Проиллюстрируйте, как меняется ширина доверительных интервалов при разных объемах выборки.

Инструкции:

- Используя ту же совокупность, что и в задании 2, постройте три выборки разного размера ($n=15$, $n=30$, $n=60$).
- Рассчитайте 95%-ный доверительный интервал для среднего значения популяции по каждой выборке.
- Сравните ширину трех доверительных интервалов.
- Нанесите результаты на график, показав, как сужается доверительный интервал при увеличении размера выборки.

Задание 5



Продemonстрируйте, как изменение доверительного уровня влияет на ширину доверительных интервалов для среднего значения популяции.

Инструкции:

- Создайте совокупность из 1000 нормально распределенных точек данных со средним значением 100 и стандартным отклонением 20.
- Сделайте выборку из 50 точек данных из этой популяции.
- Рассчитайте и постройте доверительные интервалы для среднего значения популяции при трех различных уровнях доверия: 90 %, 95 % и 99 %.
- Используйте Matplotlib или Seaborn для визуализации среднего значения выборки, среднего значения популяции и трех наборов границ доверительных интервалов на одном графике.
- Проанализируйте, как меняется ширина доверительного интервала в зависимости от уровня доверия, и обсудите компромиссы.

Задание 1



С помощью библиотеки `scipy.stats` выполните парный t-тест на наборе данных `iris` из `seaborn`. Сравните длину и ширину лепестков одного и того же вида.

Задание 2



Выполните тест хи-квадрат, чтобы определить, существует ли значимая связь между доступом в интернет и итоговой оценкой в [наборе данных «Успеваемость студентов»](#) (student-mat.csv).

Задание 3



Рассчитайте коэффициент корреляции Пирсона между ИМТ и артериальным давлением в наборе данных «Диабет».

Задание 4



Рассчитайте коэффициент корреляции Спирмена между высотой над уровнем моря и типом почвы в наборе данных «Типы лесного покрова».

Задание 5



Используйте библиотеку `seaborn`, чтобы создать тепловую карту корреляционной матрицы для набора `iris`.

Задание 6



Используйте библиотеку `seaborn`, чтобы создать парный график набора данных `iris` с аннотацией коэффициентов корреляции Пирсона.



ВОПРОСЫ





РАЗБОР ДОМАШНЕГО ЗАДАНИЯ



Домашнее задание

1. Рассчитайте 95% доверительный интервал для доли генеральной совокупности.

Инструкции:

- Смоделируйте опрос населения, в котором 1000 человек отвечают на бинарный вопрос (да/нет). Предположим, что 600 человек ответили "Да".
- Из этой популяции сделайте выборку из 100 ответов.
- Рассчитайте долю ответов "Да" в выборке.
- Вычислите 95%-ный доверительный интервал для популяционной доли ответов "Да".
- Обсудите, как доверительный интервал дает информацию о доле населения.

2. Продемонстрируйте влияние размера выборки на форму распределения средних, используя равномерное распределение.

Домашнее задание

1. С помощью библиотеки `scipy.stats` выполните независимый t-тест на наборе данных `tips` из `seaborn`. Сравните средний общий счет между курящими и некурящими.
2. С помощью библиотеки `statsmodels` выполните одновыборочный z-тест для набора данных по бриллиантам из `seaborn`. Проверьте, значительно ли отличается средняя цена бриллиантов от \$4000.
3. Используйте библиотеку `scipy.stats` для расчета коэффициента корреляции Пирсона между `total_bill` и `tip` в наборе данных `tips`.



ВОПРОСЫ



Заключение

