


Python

Парсинг веб-страниц



Преподаватель

Портрет

Имя Фамилия

Текущая должность

Количество лет опыта

Какой у Вас опыт - ключевые кейсы

Самые яркие проекты

Дополнительная информация по вашему усмотрению

Корпоративный e-mail

Социальные сети (по желанию)

Важно

- 

Камера должна быть включена на протяжении всего занятия
- 

В течение занятия вопросы задавать в чате или когда преподаватель спрашивает, есть ли у Вас вопросы
- 

Вести себя уважительно и этично по отношению к остальным участникам занятия
- 

Организационные вопросы по обучению решаются с кураторами, а не на тематических занятиях
- 

Во время занятия будут интерактивные задания, будьте готовы включить камеру или демонстрацию экрана по просьбе преподавателя

Повторение



Протокол HTTP



Модуль requests



Работа с API



Пример API: random-data-api.com



Пример API: weatherapi.com

План занятия

- Введение в HTML
- Парсинг веб-страниц с помощью BeautifulSoup
- Обработка таблиц



ОСНОВНОЙ БЛОК





Введение в HTML

Запрос-ответ



Пояснения

- Можно обращаться к веб-сайтам из скрипта python
- Чаще всего полученный ответ – это HTML-документ

Пример

```
import requests

response = requests.get("https://example.com")
print(response.text)
```




HTML (HyperText Markup Language)

Это язык разметки, с помощью которого создаются и структурируются веб-страницы. Он указывает браузеру, что отображать (заголовки, текст, изображения, таблицы и т.д.) и как это организовано на странице

Инструменты для работы сайта

HTML

Разметка страницы - шапка,
заголовки, абзацы и т.п.

CSS

оформление – цвета, шрифты,
отступы

JavaScript

интерактивность – нажатия,
анимации и т.п.

HTML-теги



Пояснения


- HTML-документ состоит из **тегов**, которые обрамляют каждый элемент страницы и говорят, как этот элемент должен выглядеть
- Большинство тегов имеют **открывающую и закрывающую форму**

Пример

```
<i>Это курсив</i>
```

Просмотр в Jupyter Notebook

В Jupyter Notebook можно использовать HTML-теги и отображать результат их применения в ячейках типа Markdown



HTML-теги



Пояснения

- Существуют самозакрывающиеся теги

Пример

```

```

Структура HTML-документа



Каждый HTML-документ начинается с `<!DOCTYPE html>`, затем идут основные блоки

Структура HTML-документа



Пример

```
<!DOCTYPE html>
<html>
  <head>
    <meta charset="UTF-8">
    <title>Заголовок страницы</title>
  </head>
  <body>
    <!-- Вся видимая часть страницы -->
  </body>
</html>
```

Пояснения

- `<html>` — корневой элемент HTML-документа
- `<head>` — невидимая часть документа, содержит метаданные, стили, скрипты и заголовок страницы
- `<title>` — задаёт заголовок страницы
- `<meta>` — содержит метаданные
- `<body>` — основное содержимое страницы

Основные теги HTML. Текст



`<h1>` – `<h6>` – заголовки, где `<h1>` – самый крупный



`<p>` – абзац (параграф)



`<strong>`, `<b>` – жирный текст



`<em>`, `<i>` – курсив



`<br>` – перенос строки



`<hr>` – горизонтальная линия

Основные теги HTML. Списки



`<ul>` — маркированный список (unordered list)



`<ol>` — нумерованный список (ordered list)



`<li>` — элемент списка (list item)

Основные теги HTML. Ссылки и изображения



`<a href="ссылка">` — гиперссылка



`` — изображение

Пример

```
<!DOCTYPE html>
<html>
<head>
  <meta charset="UTF-8">
  <title>Моя первая страница</title>
</head>
<body>
  <h1>Добро пожаловать!</h1>
```

<p>Это пример простой HTML-страницы. Здесь вы увидите разные теги.</p>

```
<h2>Список языков:</h2>
<ul>
  <li>HTML</li>
  <li>CSS</li>
  <li>JavaScript</li>
</ul>
```

1

```
<h2>Изображение:</h2>

```

```
<h2>Ссылка:</h2>
<p><a href="https://example.com">Перейти на
внешний сайт</a></p>
```

```
</body>
</html>
```

2

Основные теги HTML. Таблицы



`<table>` — таблица



`<tr>` — строка таблицы



`<th>` — заголовочная ячейка (bold + по центру)



`<td>` — обычная ячейка

Пример

```
<table>
  <tr>
    <th>Имя</th>
    <th>Возраст</th>
  </tr>
  <tr>
    <td>Анна</td>
    <td>22</td>
  </tr>
  <tr>
    <td>Олег</td>
    <td>30</td>
  </tr>
</table>
```



ВОПРОСЫ





ЗАДАНИЯ





Выберите верный вариант ответа

1. Какой тег отвечает за видимую часть содержимого страницы?
 - a. `<html>`
 - b. `<head>`
 - c. `<script>`
 - d. `<body>`



Выберите верный вариант ответа

1. Какой тег отвечает за видимую часть содержимого страницы?
 - a. `<html>`
 - b. `<head>`
 - c. `<script>`
 - d. `<body>`



Выберите верный вариант ответа

2. Какие теги используются для создания таблицы?

- a. `<list>`, `<item>`, `<data>`
- b. `<table>`, `<tr>`, `<td>`
- c. `<ul>`, `<li>`, `<ol>`
- d. `<div>`, `<span>`, `<section>`



Выберите верный вариант ответа

2. Какие теги используются для создания таблицы?

- a. `<list>`, `<item>`, `<data>`
- b. `<table>`, `<tr>`, `<td>`
- c. `<ul>`, `<li>`, `<ol>`
- d. `<div>`, `<span>`, `<section>`



Выберите верный вариант ответа

3. Какой тег используется для создания гиперссылки?

- a. `<href>`
- b. `<link>`
- c. `<a>`
- d. `<url>`



Выберите верный вариант ответа

3. Какой тег используется для создания гиперссылки?


- a. `<href>`
- b. `<link>`
- c. `<a>`
- d. `<url>`



Выберите верный вариант ответа

4. Какой тег используется для создания маркированного списка?

- a. `<ul>`
- b. `<ol>`
- c. `<li>`
- d. `<list>`



Выберите верный вариант ответа

4. Какой тег используется для создания маркированного списка?

- a. `<ul>`
- b. `<ol>`
- c. `<li>`
- d. `<list>`



ВОПРОСЫ





Парсинг веб-страниц с помощью BeautifulSoup



Парсинг

Это процесс автоматического извлечения данных с веб-страниц. Например, можно спарсить заголовки новостей, курсы валют, расписание фильмов, цены в интернет-магазине и т.д.

Применение парсинга



Анализ данных



Мониторинг цен и новостей



Сбор контента из публичных источников



BeautifulSoup

Это библиотека Python для удобного извлечения данных из HTML и XML. Она превращает HTML в дерево тегов, по которому можно легко искать нужные элементы. Часто используется вместе с библиотекой `requests`, которая помогает получать HTML-код веб-страницы.

BeautifulSoup



Установка

```
pip install beautifulsoup4
```

Пример

```
import requests
from bs4 import BeautifulSoup

url = 'https://example.com'
response = requests.get(url)

if response.status_code == 200:
    soup = BeautifulSoup(response.text, 'html.parser')
    title = soup.title.text
    print('Заголовок страницы:', title)
else:
    print('Ошибка при запросе:', response.status_code)
```

Основные методы поиска



`find(tag, attrs)` — находит **первый** тег с указанными условиями



`find_all(tag, attrs)` — находит **все** подходящие теги



`.text` или `.get_text()` — извлекает текст из тега



`.get('атрибут')` — извлекает значение атрибута, например href.

Пример 1

```
print(soup.find('h1'))  
print(soup.find('h1').text)
```

```
# Первый <h1>
```

```
# Текст первого <h1>
```

Пример 2

```
print(soup.find('a'))
print(soup.find('a').text)
print(soup.find('a').get('href'))
print(soup.find('a')['href'])
```

```
# Первый <a>
# Текст первого <a>
# Ссылка из первого <a>
# Альтернативный способ
```


Пример 3

```
list_p = soup.find_all('p')           # Все <p>
print(list_p)

for tag in list_p:
    print(tag.text)
```



ВОПРОСЫ





ЗАДАНИЯ





Подумайте, что будет выведено в результате выполнения следующего скрипта

```
import requests
from bs4 import BeautifulSoup

html =
requests.get("https://realpython.com").text
soup = BeautifulSoup(html, "html.parser")

links = soup.find_all("a")
for i in links:
    href = i.attrs.get("href")
    if href[:4]=="http":
        print(href)
```



Обработка таблиц

Обработка таблиц



Пояснение

Парсить таблицы можно
с помощью
BeautifulSoup

Пример

```
table = soup.find('table')
rows = table.find_all('tr')

for row in rows:
    cols = row.find_all('td')
    data = [col.text.strip() for col in cols]
    print(data)
```

Пример 1

```
url = "https://the-internet.herokuapp.com/tables"
response = requests.get(url)

if response.status_code == 200:
    soup = BeautifulSoup(response.text, "html.parser")

    # Находим первую таблицу
    table = soup.find("table", id="table1")

    # Извлекаем заголовки
    headers = [th.text.strip() for th in table.find_all("th")]
    print("Заголовки:", headers)

    # Извлекаем строки данных
    rows = table.find_all("tr")[1:] # Пропускаем заголовок
    for row in rows:
        cols = [td.text.strip() for td in row.find_all("td")]
        print(cols)
else:
    print("Ошибка запроса:", response.status_code)
```

Работа со страницей

<https://the-internet.herokuapp.com/tables>

Пример 2

```

table = soup.find("table", id="table2")

headers = [th.text.strip() for th in table.find_all("th")]

# Парсинг в словари
data = []
rows = table.find_all("tr")[1:] # Пропускаем строку заголовков
for row in rows:
    cols = [td.text.strip() for td in row.find_all("td")]
    row_dict = dict(zip(headers, cols))
    data.append(row_dict)

# Вывод результата
for entry in data:
    print(entry)

```

Табличные данные удобнее иметь в форме списка словарей



ВОПРОСЫ





ЗАДАНИЯ





Выберите верный вариант ответа

1. Что делает библиотека BeautifulSoup?
 - a. Упрощает работу с таблицами Excel
 - b. Автоматизирует вход на сайты
 - c. Позволяет удобно разбирать HTML-документы
 - d. Создаёт HTML-код из Python



Выберите верный вариант ответа

1. Что делает библиотека BeautifulSoup?
 - a. Упрощает работу с таблицами Excel
 - b. Автоматизирует вход на сайты
 - c. Позволяет удобно разбирать HTML-документы
 - d. Создаёт HTML-код из Python



Выберите верный вариант ответа

2. Что делает метод `.find_all("a")`?

- a. Ищет первую ссылку на странице
- b. Находит все теги `<a>` на странице
- c. Ищет ссылки только во вложенных тегах
- d. Возвращает текст всех ссылок



Выберите верный вариант ответа

2. Что делает метод `.find_all("a")`?

- a. Ищет первую ссылку на странице
- b. Находит все теги `<a>` на странице
- c. Ищет ссылки только во вложенных тегах
- d. Возвращает текст всех ссылок



Выберите верный вариант ответа

3. Что делает метод `.find_all("tr")` при парсинге HTML-таблицы?

- a. Ищет все ячейки таблицы
- b. Ищет только заголовки таблицы
- c. Ищет все строки таблицы
- d. Возвращает первую строку таблицы



Выберите верный вариант ответа

3. Что делает метод `.find_all("tr")` при парсинге HTML-таблицы?

- a. Ищет все ячейки таблицы
- b. Ищет только заголовки таблицы
- c. Ищет все строки таблицы
- d. Возвращает первую строку таблицы



Выберите верный вариант ответа

4. Какая конструкция вернёт список всех `<td>` внутри строки таблицы?

- a. `row.get_all("td")`
- b. `row.find_all("td")`
- c. `row.td()`
- d. `row.select("td")[0]`



Выберите верный вариант ответа

4. Какая конструкция вернёт список всех <td> внутри строки таблицы?

- a. `row.get_all("td")`
- b. `row.find_all("td")`**
- c. `row.td()`
- d. `row.select("td")[0]`



ВОПРОСЫ






ПРАКТИЧЕСКАЯ РАБОТА



1. Парсинг заголовков



Получите список всех заголовков (от <h1> до <h6>) со страницы <https://contextures.com/xlsampledatab01.html>.

Пример вывода:

h1: Excel Sample Data for Practice

h2: 1) Get Sample Data for Practice

h2: 2) About the Sample Data

2. Парсинг таблицы



Извлеките в список словарей таблицу из пункта 3.1 на странице <https://contextures.com/xlsampledta01.html>.
Вычислите среднюю стоимость товаров и суммарную выручку.



ДОМАШНЕЕ ЗАДАНИЕ



Домашнее задание

1. Поиск стран

Напишите программу, которая:

- Парсит таблицу с сайта <https://www.iban.com/country-codes> и сохраняет ее в подходящей структуре данных;
- Запрашивает у пользователя код страны (пользователь может ввести двухбуквенный или трехбуквенный код) и выводит название страны, соответствующей этому коду.

Пример ввода:

Введите код страны (2 или 3 буквы): FRA

Пример вывода:

Код FRA соответствует стране: France

Заключение

