

Стать IT-шником может каждый



Работа с несколькими DataFrame. Группировка



Преподаватель



Ваше фото

ИМЯ ФАМИЛИЯ

Текущая должность

Количество лет опыта

Какой у Вас опыт - ключевые кейсы

Самые яркие проекты

Дополнительная информация по вашему усмотрению

Корпоративный e-mail

Социальные сети (по желанию)



ВАЖНО!

- Камера должна быть включена на протяжении всего занятия.
- Если у Вас возник вопрос в процессе занятия, пожалуйста, поднимите руку и дождитесь, пока преподаватель закончит мысль и спросит Вас, также можно задать вопрос в чате или когда преподаватель скажет, что начался блок вопросов.
- Организационные вопросы по обучению решаются с кураторами, а не на тематических занятиях.
- Вести себя уважительно и этично по отношению к остальным участникам занятия.
- Во время занятия будут интерактивные задания, будьте готовы включить микрофон или демонстрацию экрана по просьбе преподавателя.

ПЛАН ЗАНЯТИЯ

Введение

Основной блок

Задание для закрепления

Вопросы по основному блоку

Заключение



Стать IT-шником может каждый



ПОВТОРЕНИЕ ИЗУЧЕННОГО





Повторение

- Изменение таблиц
- Работа с пропусками
- Простые операции
- Чтение и запись данных
- Интервалы времени



Стать IT-шником может каждый



ВОПРОСЫ



Стать IT-шником может каждый



Введение

Функция `pd.concat`

Функции `pd.merge` и `df.join`

Группировка



Стать IT-шником может каждый



ОСНОВНОЙ БЛОК




Функция `pd.concat`





pd.concat —

это функция внутри `pandas`, которая позволяет объединять датафреймы как по горизонтали, так и по вертикали.



Соединение таблиц вдоль выбранной оси

```
pd.concat(objs, axis=0, join='outer', ignore_index=False, copy=True, ...)
```

Функция `pd.concat`

Основные аргументы	Пояснение
<code>objs</code>	Объединяемые таблицы
<code>axis : {0 или 'index', 1 или 'columns'}</code>	Ось индексов или ось колонок, иными словами соединение по вертикали или по горизонтали
<code>join : {'inner', 'outer'}</code>	Тип объединения — пересечение или объединение индексов/колонок
<code>copy</code>	Копировать данные или нет

Пример

```
df = pd.DataFrame(np.random.normal(size=(10, 4)),  
                  columns=['A', 'B', 'C', 'D'])  
other = df[:4].copy() # Полное копирование  
other['flag'] = other['D'] > 0  
other['D'] = other['D'] ** 2
```


Пример

```
pd.concat([df, other], axis=0, join='inner')
```

Пример объединения по другой оси

```
pd.concat([df, other], axis=1, join='inner')
```

Стать IT-шником может каждый



ВОПРОСЫ



Стать IT-шником может каждый



ЗАДАНИЕ ДЛЯ ЗАКРЕПЛЕНИЯ





Подумайте:

Вспомните какие есть виды join в SQL.

Назовите особенности работы разных вариантов join.




Функции `pd.merge` и `df.join`





pd.merge и df.join —

это функции, которые реализуют слияние таблиц по вертикали путем выполнения операций слияния баз данных в стиле SQL. Отличия в синтаксисе и аргументах.



Пример функций `pd.merge` и `df.join`

```
d.merge(left, right, how='inner', on=None, left_on=None, right_on=None, left_index=False,
right_index=False, suffixes=('_x', '_y'), ...)
```

Функции `pd.merge` и `df.join`

Основные аргументы	Пояснение
<code>left</code> и <code>right</code>	Объединяемые таблицы
<code>how</code>	Тип объединения
<code>on</code>	Имя (или имена) колонок, по которым будет производиться объединение
<code>left_on</code> и <code>right_on</code>	Аналогично <code>on</code> для случая, когда в таблицах различаются имена колонок, соответствующие ключам.
<code>left_index</code> и <code>right_index</code>	Использовать ли индексы в качестве ключей
<code>suffixes</code>	Суффиксы, которые будут добавлены к тем колонкам, имена которых повторяются

Типы объединения

left

Только по ключам
из левой таблицы
== SQL left outer join

right

Только по ключам
из правой таблицы
== SQL right outer
join

outer

По объединению
ключей == SQL full
outer join

inner

По пересечению
ключей == SQL
inner join

Пример

```
df.join(other, on=None, how='left', lsuffix="", rsuffix="", sort=False)
```

Функции `pd.merge` и `df.join`

Основные аргументы	Пояснение
<code>df</code>	Основная таблица. В качестве ключей используется индекс
<code>other</code>	Другая таблица
<code>on</code>	Колонка(-и) в <code>other</code> , соответствующая ключам, по ним происходит объединение. Если <code>None</code> , то используется индекс
<code>how</code>	Тип объединения
<code>lsuffix</code> и <code>rsuffix</code>	Суффиксы, которые будут добавлены к тем колонкам, имена которых повторяются

Пример: в обеих таблицах ключи повторяются

```
left = pd.DataFrame({'key': ['A', 'A'],  
                    'lval': [1, 2]})  
right = pd.DataFrame({'key': ['A', 'A'],  
                    'rval': [4, 5]})  
left
```

Пример: в обеих таблицах ключи повторяются

right

Пример: в обеих таблицах ключи повторяются

```
pd.merge(left, right, on='key')
```

Пример: в таблицах ключи не повторяются

```
left = pd.DataFrame({'key': ['A', 'B'],  
                    'lval': [1, 2]})
```

Пример: в таблицах ключи не повторяются

```
right = pd.DataFrame({'key': ['A', 'B'],  
                      'rval': [4, 5]})
```

Пример: в таблицах ключи не повторяются

```
pd.merge(left, right, on='key')
```


Пример: различные типы объединения

```
left = pd.DataFrame({'lkey': ['A', 'B', 'C', 'A'],  
                    'value': range(4)})  
right = pd.DataFrame({'rkey': ['A', 'B', 'D', 'B'],  
                    'value': range(4, 8)})  
right.dtypes
```


Пример: различные типы объединения

```
pd.merge(left, right,  
         left_on='lkey', right_on='rkey', how='outer')
```

Стать IT-шником может каждый



ЗАДАНИЕ ДЛЯ ЗАКРЕПЛЕНИЯ





Подумайте:

Внезапно могут измениться типы значений! Как вы думаете, почему?

```
pd.merge(left, right,  
         left_on='lkey', right_on='rkey', how='outer').dtypes
```

Подсказка:

```
pd.merge(left, right,  
         left_on='lkey', right_on='rkey', how='outer')['value_x'].values
```

Пример: различные типы объединения

```
pd.merge(left, right,  
         left_on='lkey', right_on='rkey', how='inner')
```

Пример: различные типы объединения

```
pd.merge(left, right,  
         left_on='lkey', right_on='rkey', how='left')
```

Пример: различные типы объединения

```
pd.merge(left, right, left_on='lkey', right_on='rkey', how='inner') \
    .set_index('lkey')[['value_x', 'value_y']]
```

Пример: различные типы объединения

```
left.set_index('lkey') \
    .join(right.set_index('rkey'), rsuffix='_r', how='inner')
```

Стать IT-шником может каждый



ВОПРОСЫ



Стать IT-шником может каждый



ЗАДАНИЕ ДЛЯ ЗАКРЕПЛЕНИЯ





Подумайте:

Как работает группировка данных в SQL?

Как называется группа функций SUM(), AVG(), MIN() и какие есть особенности их использования?

Стать IT-шником может каждый



Группировка



Этапы группировки данных

Разбиение данных на группы
по некоторым критериям

Применение функции
отдельно к каждой группе

Комбинирование результата
в структуру данных



Функция для выполнения группировки

```
df.groupby(by=None, axis=0, level=None, sort=True, ...)
```


Функции df.groupby

Основные аргументы	Пояснение
df	Таблица, данные которой должны быть сгруппированы
by	Задаёт принцип группировки. Чаще всего это имя столбца, по которому нужно сгруппировать. Может так же быть функцией
axis	Ось (0 = группировать строки, 1 = группировать столбцы)
level	Если ось представлена мультииндексом, то указывает на уровень мультииндекса
sort	Сортировка результата по индексу



Результат группировки —

это объект, состоящий из пар (имя группы, подтаблица).
Имя группы соответствует значению, по которому
произведена группировка.



Функции df.groupby

Операции	Пояснение
for name, group in grouped:	Цикл по группам
get_group(name)	Получить таблицу, соответствующую группе с именем name
groups	Получить все группы в виде словаря имя-подтаблица
count()	Количество значений в группах, исключая пропуски
size()	Размер групп
sum(), max(), min()	Сумма, максимум, минимум
mean(), median(), var(), std(), corr(), quantile(q)	Среднее, медиана, дисперсия, стандартное отклонение, корреляция, квантиль
describe()	Вывод описательных статистик
aggregate(func)	Применение функции (или списка функций) func к группам

Пример

```
df = pd.DataFrame({  
    'Животное' : ['Котик', 'Песик', 'Котик', 'Песик',  
                 'Котик', 'Песик', 'Котик', 'Песик'],  
    'Цвет шерсти' : ['белый', 'белый', 'коричневый', 'черный',  
                    'коричневый', 'коричневый', 'белый', 'черный'],  
    'Рост' : np.random.gamma(12, scale=3, size=8),  
    'Длина хвостика' : np.random.gamma(10, size=8)  
})  
df
```



Подумайте:

Если все котики встанут друг на друга, то какой их суммарный рост? А у песиков? А какова суммарная длина хвостиков у котиков и у песиков?



Пример

```
df.groupby('Животное').sum()
```

Пример

```
df.groupby('Животное').describe()
```

Пример

```
des = df.groupby('Животное').describe()  
des.columns
```



Подумайте:

Теперь предположим, что котики и песики встают только на представителей своего вида и своего цвета шерсти. Что тогда будет?



Пример

```
df.groupby(['Животное', 'Цвет шерсти'])  
df.groupby(['Животное', 'Цвет шерсти']).sum()
```

Пример

```
df.groupby(['Животное', 'Цвет шерсти']).sum().index
```


Стать IT-шником может каждый



ВОПРОСЫ



Стать IT-шником может каждый



ПРАКТИЧЕСКАЯ РАБОТА



Стать IT-шником может каждый



ОСТАВШИЕСЯ ВОПРОСЫ





Домашнее задание

1. Напишите программу, которая:
 - Создает DataFrame с двумя столбцами: "Дата" (в формате дд-мм-гггг) и "Значение" (целые числа).
 - Преобразует столбец "Дата" в тип datetime и устанавливает его в качестве индекса DataFrame.
 - Генерирует временной ряд, заполняя столбец "Значение" случайными числами.
 - Выводит сгенерированный временной ряд.
 - Запрашивает у пользователя начальную и конечную дату периода для фильтрации.
 - Выводит временной ряд за указанный период.



Домашнее задание

2. Напишите программу, которая:

- Создает DataFrame с тремя столбцами: "Товар", "Откуда", "Куда" (в последних двух столбцах указываются города).
- Создает второй DataFrame с двумя столбцами: "Город", "Страна".
- На основе слияния двух предыдущих DataFrame создает третий, в котором для каждого товара вместо городов доставки будут указаны страны. Лишних столбцов в этом DataFrame быть не должно, только "Товар", "Откуда", "Куда" (в последних двух столбцах указываются страны)
- Добавьте в последний DataFrame новый столбец "Внутри_страны", который принимает логические значения (True, если доставка осуществляется внутри страны).
- Вычислите, сколько в наших данных доставок внутри страны.



Домашнее задание

3. Напишите программу, которая:

- Запрашивает у пользователя количество строк данных для ввода.
- Для каждой строки запрашивает данные по трем столбцам: "Имя", "Возраст", "Регион", разделённые пробелом.
- Создает DataFrame на основе введенных данных.
- Выводит общую информацию о DataFrame, включая количество записей, средний возраст, и количество уникальных регионов.
- Выбирает и выводит на экран данные о самом молодом участнике.

Стать IT-шником может каждый



РАЗБОР ДОМАШНЕГО ЗАДАНИЯ





Домашнее задание

1. Напишите программу, которая:
 - Запрашивает у пользователя ввод чисел, разделенных пробелами.
 - Преобразует введенные данные в объект Series, используя в качестве индексов буквы алфавита начиная с 'a'.
 - Выводит созданный объект Series на экран.



Домашнее задание

2. Напишите программу, которая:

- Запрашивает у пользователя данные для создания DataFrame. Данные включают в себя имена столбцов и строки значений, вводимые через пробел.
- Создает DataFrame с использованием введенных данных.
- Выводит созданный DataFrame на экран.
- Запрашивает у пользователя имя столбца, по которому необходимо отфильтровать данные.
- Выводит значения указанного столбца.



Полезные ссылки

- [Merge, join, concatenate and compare — pandas 2.2.2 documentation](#)
- [Group by: split-apply-combine — pandas 2.2.2 documentation](#)

Стать IT-шником может каждый



ЗАКЛЮЧЕНИЕ

