

Стать IT-шником может каждый



Продвинутые возможности группировки и работы с jupyter notebook



Преподаватель



Ваше фото

ИМЯ ФАМИЛИЯ

Текущая должность

Количество лет опыта

Какой у Вас опыт - ключевые кейсы

Самые яркие проекты

Дополнительная информация по вашему усмотрению

Корпоративный e-mail

Социальные сети (по желанию)



ВАЖНО!

- Камера должна быть включена на протяжении всего занятия.
- Если у Вас возник вопрос в процессе занятия, пожалуйста, поднимите руку и дождитесь, пока преподаватель закончит мысль и спросит Вас, также можно задать вопрос в чате или когда преподаватель скажет, что начался блок вопросов.
- Организационные вопросы по обучению решаются с кураторами, а не на тематических занятиях.
- Вести себя уважительно и этично по отношению к остальным участникам занятия.
- Во время занятия будут интерактивные задания, будьте готовы включить микрофон или демонстрацию экрана по просьбе преподавателя.

ПЛАН ЗАНЯТИЯ

Введение

Основной блок

Задание для закрепления

Вопросы по основному блоку

Заключение



Стать IT-шником может каждый



ПОВТОРЕНИЕ ИЗУЧЕННОГО





Повторение

- Функция `pd.concat`
- Функции `pd.merge` и `df.join`
- Группировка



Стать IT-шником может каждый



ВОПРОСЫ



Стать IT-шником может каждый



Введение

Таблицы сопряженности (Crosstab) и сводные таблицы (Pivot table)

Основы работы с Jupyter Notebook

Магия Jupyter



Стать IT-шником может каждый



ОСНОВНОЙ БЛОК



Таблицы сопряженности и сводные таблицы





Задача:

В медицинской клинике информацию о приемах записывают в таблицу со следующими полями:

- Время приема
- Врач
- Пациент
- Поставленный диагноз
- Назначение
- Другие поля


Посчитать, сколько раз за предыдущий месяц каждый врач ставил какой-либо диагноз.

Результаты представить в виде таблицы, в которой посчитать суммы по строкам и столбцам, т.е. сколько врач сделал приемов за месяц и сколько раз конкретный диагноз поставлен всеми врачами.

Способ решения 1



Способ решения 2



Способ решения 3

Применить умную функцию из pandas, которая сделает все сама!


```
pd.crosstab(index, columns, values=None, rownames=None, colnames=None,  
aggfunc=None, margins=False, margins_name='All', dropna=True, normalize=False)
```


Полезно знать



pd.crosstab —

это функция внутри `pandas`, которая позволяет создавать эксель-подобные таблицы сопряженности.



Функция `pd.crosstab`

Основные аргументы	Пояснение
<code>index</code>	Значения для группировки по строкам
<code>columns</code>	Значения для группировки по столбцам
<code>values</code>	Агрегируемый столбец, его значения непосредственно определяют значения таблицы сопряженности
<code>aggfunc</code>	Функция, которая будет применена к каждой группе значений <code>values</code> , сгруппированным по значениям <code>index</code> и <code>columns</code>

Функция `pd.crosstab`

Основные аргументы	Пояснение
<code>rownames</code> и <code>colnames</code>	Имена строк и столбцов таблицы сопряженности
<code>margins</code>	Добавляет результирующий столбец/строку
<code>margins_name</code>	Имя результирующего столбец/строку
<code>dropna</code>	Не включать столбцы, которые состоят только из NaN
<code>normalize: boolean, {'all', 'index', 'columns'}</code>	Нормировка всей таблицы (или только по строкам/столбцам)

Способ решения 3


```
pd.crosstab(df['Врач'], df['Диагноз'], margins=True)
```

Полезно знать



pd.pivot_table —

это функция внутри `pandas`, которая позволяет создавать эксель-подобные сводные таблицы.



Функция `pd.pivot_table`

```
pd.pivot_table(data, values=None, index=None, columns=None, aggfunc='mean', fill_value=None,
               margins=False, dropna=True, margins_name='All')
```


Функция `pd.pivot_table`

Основные аргументы	Пояснение
<code>data</code>	Исходная таблица
<code>values</code>	Агрегируемый столбец, его значения непосредственно определяют значения сводной таблицы
<code>index</code>	Ключи для группировки, относятся к индексам сводной таблицы
<code>columns</code>	Ключи для группировки, относятся к столбцам сводной таблицы
<code>aggfunc</code>	Функция, которая будет применена к каждой группе значений <code>values</code> , сгруппированным по значениям <code>index</code> и <code>columns</code>

Функция `pd.pivot_table`

Основные аргументы	Пояснение
<code>fill_value</code>	Значения для замены пропусков
<code>dropna</code>	Не включать столбцы, которые состоят только из NaN
<code>margins</code>	Добавляет результирующий столбец/строку
<code>margins_name</code>	Имя результирующего столбец/строку

Способ решения 3

```
pd.pivot_table(df, index='врач', columns='диагноз', margins=True)
```

Пример

```
df = pd.DataFrame({  
    'Специальность' : ['Ветеринар', 'Ветеринар',  
                      'Психолог', 'Психолог'] * 6,  
    'Врач' : ['Андрей', 'Сергей', 'Ирина'] * 8,  
    'Диагноз' : ['Простуда', 'Простуда', 'Простуда',  
                'Волнения', 'Волнения', 'Простуда'] * 4,  
    'Доза' : np.random.randint(low=1, high=6, size=24),  
    'Продолжительность' : np.random.randint(low=1, high=6, size=24)  
})  
df
```

Пример

Сколько раз какой врач ставил каждый из диагнозов, а также суммы по строкам и столбцам

```
pd.crosstab(df['Врач'], df['Диагноз'], margins=True)
```

Пример

Какую среднюю дозу какой врач назначал по каждому из диагнозов

```
pd.crosstab(df['Врач'], df['Диагноз'], values=df['Доза'], aggfunc="mean")
```

Пример

Среднее в числовых столбцах по каждому врачу

```
pd.pivot_table(df, index=['Врач'], values=['Доза', 'Продолжительность'])
```


Пример

Сколько раз врач и в какой специальности ставил тот или иной диагноз

```
pd.pivot_table(df,  
                values='Доза',  
                index=[ 'Специальность', 'Врач' ],  
                columns=[ 'Диагноз' ],  
                aggfunc="sum")
```

Пример

Применение нескольких функций и нескольких столбцов со значениями

```
pd.pivot_table(df,  
                values=['Доза', 'Продолжительность'],  
                index=['Специальность', 'Врач'],  
                columns=['Диагноз'],  
                aggfunc=["min", "mean", "max"],  
                margins=True)
```

Стать IT-шником может каждый



ВОПРОСЫ



Стать IT-шником может каждый



Основы работы с Jupyter Notebook



Типы ячеек jupyter-ноутбука

code

Код


markdown

Текст с формулами на latex (в
одинарных или двойных \$)

raw

Неформатированный текст


Изменение типа ячейки





Command mode —

это режим команд, где можно вводить команды для быстрого редактирования блокнота в целом. Его можно активировать кнопкой Esc или щелчком мыши вне ячеек блокнота, после чего возможны варианты. Ctrl + Shift + h откроет справку.



Command mode

Команда	Пояснение
Ctrl + F	Найти и заменить
Esc + 0 + 0	Перезапустить ядро
Esc + Shift + ↑ ↓	Выделить ячейку выше/ниже текущей
Esc + Ctrl + Enter	Запустить выделенные ячейки (в естественном порядке)
Esc + D + D	Удалить все выделенные ячейки (включая текущую)
Esc + Z	Отменить удаление ячеек
Esc + C	Скопировать выделенные ячейки

Command mode

Команда	Пояснение
Esc + X	Вырезать выделенные ячейки
Esc + V	Вставить ранее скопированные ячейки
Esc + A	Вставить ячейку выше
Esc + B	Вставить ячейку ниже
Esc + Shift + M	Объединить выделенные ячейки (или текущую ячейку с нижней)
Esc + M	Заменить код на markdown
Esc + Y	Заменить markdown на код

Command mode

Команда	Пояснение
Shift + Tab	Показать описание функции, курсор должен стоять сразу после открывающей скобки
Ctrl + /	Закомментировать строку
Ctrl + Home	Перейти к началу ячейки
Ctrl + End	Перейти к концу ячейки
Ctrl + Shift + -	Разбить ячейку по текущей строке
Shift + ↑↓	Выделить ячейку выше/ниже текущей
Ctrl + Enter	Запустить выделенные ячейки
Shift + Enter	Запустить ячейку и перейти на одну ниже, что удобно, когда последовательно запускаете сразу много

Стать IT-шником может каждый



ВОПРОСЫ




Стать IT-шником может каждый



Магия Jupyter




Полезно знать



jupyter magics —

это метаязык, команды которого обычно начинаются с % или %%.



Команды jupyter magics

`%lsmagic` # Вывод ниже

Available line magics:

`%alias %alias_magic %autoawait %autocall %automagic %autosave %bookmark %cat %cd %clear %colors %conda %config %connect_info %cp %debug %dhist %dirs %doctest_mode %ed %edit %env %gui %hist %history %killbgscripts %ldir %less %lf %lk %ll %load %load_ext %loadpy %logoff %logon %logstart %logstate %logstop %ls %lsmagic %lx %macro %magic %man %matplotlib %mkdir %more %mv %notebook %page %pastebin %pdb %pdef %pdoc %pfile %pinfo %pinfo2 %pip %popd %pprint %precision %prun %psearch %psource %pushd %pwd %pycat %pylab %qtconsole %quickref %recall %rehashx %reload_ext %rep %rerun %reset %reset_selective %rm %rmdir %run %save %sc %set_env %shell %store %sx %system %tb %tensorflow_version %time %timeit %unalias %unload_ext %who %who_ls %whos %xdel %xmode`

Available cell magics:

`%%! %%HTML %%SVG %%bash %%bigquery %%capture %%debug %%file %%html %%javascript %%js %%latex %%markdown %%perl %%prun %%pypy %%python %%python2 %%python3 %%ruby %%script %%sh %%shell %%svg %%sx %%system %%time %%timeit %%writefile`


Automagic is ON, % prefix IS NOT needed for line magics.

Полезно знать



cell magics —


это команды, команды которые влияют на состояние всей ячейки, и работают только если написаны в самом её начале.





line magics —

это команды, которые могут быть написаны в любом месте и либо влияют на строку с кодом (как `%timeit`), либо выполняют какую-то системную команду (как `%ls`).




Справка

?%time



%timeit —

это команда, которая запускает команду несколько раз. По результатам вычисляется среднее и стандартное отклонение.



Пример

```
import time
import numpy as np

def sleep_if_odd():
    rvs = np.random.randint(low=0, high=int(1e9))
    randbit = rvs % 2
    if randbit % 2 == 1:
        time.sleep(1)
```


Пример

```
%timeit -n 10 sleep_if_odd()  
# 529 ms ± 116 ms per loop (mean ± std. dev. of 7 runs, 10 loops each)
```



%%writefile и %pycat —

это функции, которые позволяют сохранить ячейку с кодом в питоновский файл и вывести его содержимое с подсветкой синтаксиса.



Пример

```
%%writefile test.py  
print("Hello, World!")
```


Пример

```
%pycat test.py
```



%system и %%bash —

это функции, которые позволяют выполнять системные команды так, будто вы работаете в терминале.



Пример

%system date

Пример

!date

Пример

```
!pip install scipy
```

Стать IT-шником может каждый



ВОПРОСЫ



Стать IT-шником может каждый



ПРАКТИЧЕСКАЯ РАБОТА



Практическое задание 1

У вас есть датафрейм с информацией о покупках различных товаров разными клиентами. Кроме того, у вас есть информация о поле каждого клиента и категории товаров. Необходимо создать сводную таблицу, чтобы проанализировать, какие категории товаров покупаются чаще всего мужчинами и женщинами разных возрастных групп.

Практическое задание 2

У вас есть датафрейм с результатами опроса, в котором каждый респондент указал свой пол и предпочтения по категориям товаров. Необходимо создать таблицу сопряженности и добавить в нее процентные значения по строкам или столбцам.

Стать IT-шником может каждый



ОСТАВШИЕСЯ ВОПРОСЫ



Полезные ссылки

- [Reshaping and pivot tables — pandas 2.2.2 documentation](#)
- [pandas.crosstab — pandas 2.2.2 documentation](#)

Стать IT-шником может каждый



ЗАКЛЮЧЕНИЕ

