

Python
for DA

Знакомство с Polars



Преподаватель

Портрет

Имя Фамилия

Текущая должность

Количество лет опыта

Какой у Вас опыт - ключевые кейсы

Самые яркие проекты

Дополнительная информация по вашему усмотрению

Корпоративный e-mail

Социальные сети (по желанию)

Важно

- 

Камера должна быть включена на протяжении всего занятия
- 

В течение занятия вопросы задавать в чате или когда преподаватель спрашивает, есть ли у Вас вопросы
- 

Вести себя уважительно и этично по отношению к остальным участникам занятия
- 

Организационные вопросы по обучению решаются с кураторами, а не на тематических занятиях
- 

Во время занятия будут интерактивные задания, будьте готовы включить камеру или демонстрацию экрана по просьбе преподавателя

Повторение



GeoPandas



GeoDataFrame



Использование geodatasets



Характеристики геометрий



Построение карт

План занятия

- Обзор библиотеки Polars и ее ключевые особенности
- Мотивация использования Polars
- Установка библиотеки polars
- DataFrame в Polars
- Загрузка данных в Polars DataFrame
- Создание DataFrame в Polars
- Контексты и выражения Polars
- Выбор и фильтрация данных в Polars
- Трансформация данных



ОСНОВНОЙ БЛОК





Обзор библиотеки Polars



Polars

Это современная библиотека DataFrame, предназначенная для эффективного манипулирования данными и их анализа. В основе - структура данных DataFrame, аналогичную Pandas DataFrame, но с оптимизацией по скорости, использованию памяти и масштабируемости.

Ключевые особенности Polars



DataFrame



Эффективный механизм запросов



Функциональный API



Интеграция с Arrow

Мотивация использования Polars

-  Ограничения производительности
-  Нагрузка на память
-  Проблемы масштабируемости

Polars решает эти проблемы за счет использования характеристик производительности Rust, включая безопасность памяти, модель параллелизма и эффективную обработку параллелизма



ВОПРОСЫ





Установка библиотеки polars

Установка необходимых библиотек

```
pip install polars
```

```
pip install pyarrow
```

```
import polars as pl
```



ВОПРОСЫ





DataFrame в Polars



Табличная структура

DataFrame в Polars состоит из строк и столбцов, где каждый столбец представляет собой серию данных одного типа, а каждая строка - наблюдение или запись.



Маркированные столбцы

Столбцы в DataFrame маркированы, что позволяет легко получить доступ к данным с помощью меток столбцов.



Колоночное хранение данных

Внутренние данные в DataFrame хранятся в формате столбцов, что обеспечивает эффективный доступ к данным, манипулирование ими и вычисления.



Неизменяемые данные

DataFrame в Polars неизменяемы, то есть операции обычно создают новые экземпляры DataFrame, а не изменяют существующие.



Сравнение с Pandas DataFrame

Производительность



Polars

Создан с учетом производительности, используя эффективность Rust для обеспечения более высокой скорости выполнения и лучшего использования памяти, особенно для больших наборов данных

Pandas

Реализован на Python и может страдать от ограничений производительности, особенно при работе с большими наборами данных.

Эффективность использования памяти



Polars

Разработан для эффективного использования памяти, что делает его подходящим для работы с большими наборами данных с минимальными затратами памяти.

Pandas

Может потреблять больше памяти, особенно при выполнении операций, связанных с копированием или изменением формы данных.

Функциональный API



Polars

Предлагает функциональный API программирования, позволяющий пользователям выражать операции манипулирования данными с помощью краткого и выразительного синтаксиса

Pandas

API Polars может предложить более чистый и предсказуемый подход для решения определенных задач.

Интеграция с Arrow



Polars

Интегрируется с Apache Arrow, обеспечивая эффективный обмен данными с другими Arrow-совместимыми библиотеками и инструментами.

Pandas

Не имеет встроенной интеграции с Arrow, хотя совместимость может быть достигнута с помощью функций преобразования.

Параллельная обработка



Polars

Оптимизирован для параллельной обработки и может использовать многоядерные процессоры для повышения производительности.

Pandas

В некоторой степени поддерживает многопоточность.



ВОПРОСЫ





Загрузка данных в Polars DataFrame

Из CSV

`pl.read_csv(path: str) -> pl.DataFrame`: Считывает данные из CSV-файла в Polars DataFrame.

Параметры:

- `path (str)`: Путь к CSV-файлу.

```
import polars as pl
df = pl.read_csv('data.csv')
```

Из Pandas DataFrame

`pl.from_pandas(df: pd.DataFrame) -> pl.DataFrame`: Преобразует Pandas DataFrame в Polars DataFrame.

Параметры:

- `df (pd.DataFrame)`: Объект Pandas DataFrame.

```
import polars as pl
import pandas as pd
pandas_df = pd.read_csv('data.csv')
df = pl.from_pandas(pandas_df)
```

Из JSON

`pl.read_json(path: str) -> pl.DataFrame`: Считывает данные из JSON-файла в Polars DataFrame.

Параметры: `path (str)`:

- Путь к файлу JSON.

```
import polars as pl
df = pl.read_json('data.json')
```



ВОПРОСЫ





Создание DataFrame в Polars

Из словаря

```
pl.DataFrame(data: Dict[str, List[Any]]) -> pl.DataFrame
```

Пример

```
import polars as pl
data = {
    'A': [1, 2, 3],
    'B': ['foo', 'bar', 'baz'],
    'C': [True, False, True]
}
df = pl.DataFrame(data)
```

Из списка кортежей

```
pl.DataFrame(data: List[Tuple[Any]]) -> pl.DataFrame
```

Пример

```
import polars as pl
data = [
    (1, 'foo', True),
    (2, 'bar', False),
    (3, 'baz', True)
]
df = pl.DataFrame(data, orient="row", schema=['A', 'B', 'C'])
```



ВОПРОСЫ





Пример создания DataFrame

Фреймы Polars

```
import numpy as np
import polars as pl
import numpy as np

strings_data = ["apple", "banana", "cherry", "watermelon", "elderberry"]
integers_data = np.random.randint(1, 100, size=5)
floats_data = np.random.rand(5)

df = pl.DataFrame({
    "fruit": strings_data,
    "quantity": integers_data,
    "price": floats_data
})

print(df.head(3))
print(df.dtypes)
print(df.schema)
print(df.describe())
```



`print(df.schema)`

Выводит схему DataFrame `df`, которая включает информацию о типах данных и именах каждого столбца.



`df.describe()`

Показывает сводную статистику для каждого столбца в DataFrame.

Характеристики



count - количество наблюдений или строк в наборе данных.



null_count - количество отсутствующих значений в столбце.



mean - среднее арифметическое значение столбца.



std - стандартное отклонение столбца.



min - минимальное значение столбца.



max - максимальное значение столбца.



median - медианное значение, или пятидесятый процентиль, столбца.



25% - двадцать пятый процентиль, или первый квартиль, столбца.



75 % - семьдесят пятый процентиль, или третий квартиль, столбца.



ВОПРОСЫ





Контексты и выражения Polars



Контексты и выражения

Это основные компоненты уникального синтаксиса преобразования данных в Polars. Выражения относятся к вычислениям или преобразованиям, которые выполняются над столбцами данных, и позволяют применять различные операции над данными для получения новых результатов.

В Polars есть три основных контекста



Выбор



Фильтрация



Группировка/агрегация



ВОПРОСЫ





Выбор и фильтрация данных в Polars

Индексирование

```
df[0,:]
```

```
df[:,['fruit', 'price']]
```

Фильтрация строк

```
df.filter(pl.col("price") > 0.5).head()
```

Метод select

```
df.select(['fruit', 'price'])
```

Метод with_columns

```
df.with_columns([
    (pl.col("price") * pl.col("quantity")).alias("total")
])
```



ВОПРОСЫ





Трансформация данных



`with_columns`

Это основное выражение для трансформации данных, которое позволяет создать новый столбец для анализа.

Пример

```
df.with_columns([  
    (pl.col("price") * pl.col("quantity")).alias("total")  
])
```




`.with_columns()`

Это метод, который добавляет новые столбцы в DataFrame. Он ожидает список кортежей, где каждый кортеж содержит выражение столбца и необязательный псевдоним.



`pl.col("price") * pl.col("quantity")`

Это выражение, которое вычисляет произведение значений в столбцах «цена» и «количество». `pl.col()` - это функция от Polars, которая позволяет вам ссылаться на определенный столбец в DataFrame.



.alias("total")

Задаёт псевдоним для нового столбца. В данном случае новому столбцу присвоен псевдоним «total».



ВОПРОСЫ





ПРАКТИЧЕСКАЯ РАБОТА



Задание 1

1. Что делает следующий код?

```
df.filter(
    pl.col('brand').is_in(['apple', 'samsung', 'motorola'])
).head()
```

2. Что делает следующий код?

```
df.with_columns([
    (pl.col("price") * 100).alias("price_x_100")
])
```

Задание 2

1. Загрузите набор данных титаника.
2. Выберите только столбцы класс, пол, возраст.
3. Выберите пассажиров, путешествовавших в первом классе и заплативших более 100 фунтов за билет.
4. Добавьте столбец "стоимость билета в долларах".
5. Выберите выживших пассажиров женского пола моложе 18 лет.
6. Добавьте столбец "количество родственников на борту".
7. Выберите пассажиров, выживших с братьями или сестрами, или супругами.



ВОПРОСЫ



Заключение

