


Python
for DA

Основы статистики. Центральная предельная теорема



Преподаватель

Портрет

Имя Фамилия

Текущая должность

Количество лет опыта

Какой у Вас опыт - ключевые кейсы

Самые яркие проекты

Дополнительная информация по вашему усмотрению

Корпоративный e-mail

Социальные сети (по желанию)

Важно

- 

Камера должна быть включена на протяжении всего занятия
- 

В течение занятия вопросы задавать в чате или когда преподаватель спрашивает, есть ли у Вас вопросы
- 

Вести себя уважительно и этично по отношению к остальным участникам занятия
- 

Организационные вопросы по обучению решаются с кураторами, а не на тематических занятиях
- 

Во время занятия будут интерактивные задания, будьте готовы включить камеру или демонстрацию экрана по просьбе преподавателя

Повторение



Z-score: Определение и расчет



Применение Z-score в анализе данных



Стандартное нормальное распределение: Свойства и значение



Поиск вероятностей с помощью Z-score

План занятия

- Вероятностное сэмплирование
- Центральная предельная теорема (ЦПТ)
- Следствия центральной предельной теоремы (ЦПТ)
- Создание выборочных распределений с помощью Python
- Использование ЦПТ для нахождения вероятности



ОСНОВНОЙ БЛОК





Вероятностное сэмплирование





Вероятностное сэмплирование

Это фундаментальный метод статистики, при котором каждый член генеральной совокупности имеет известный ненулевой шанс быть отобранным. Он гарантирует, что выборка является репрезентативной по отношению к генеральной совокупности, что позволяет исследователям делать достоверные выводы обо всей генеральной совокупности.



Простая случайная выборка

Это самая основная форма вероятностной выборки. При этом методе каждый член генеральной совокупности имеет равные шансы быть отобранным.

Простая случайная выборка



Перечислите всех членов генеральной совокупности.



Присвойте уникальный номер каждому члену генеральной совокупности.



Используйте генератор случайных чисел или другой метод рандомизации для отбора выборки.

Пример



Есть школа с 1 000 учеников, и нужно опросить 100 из них. Можно присвоить каждому ученику номер от 1 до 1 000 и использовать генератор случайных чисел для выбора 100 номеров. Студенты, соответствующие этим номерам, и будут выборкой.

Сравнение выборки



Плюсы

- Простота и легкость реализации.
- Минимизирует предвзятость, поскольку каждый участник имеет равные шансы на выборку.

Минусы

- Требуется полный список генеральной совокупности.
- Может быть непрактичным для очень больших генеральных совокупностей.



Стратифицированная случайная выборка

Предполагает разделение генеральной совокупности на подгруппы (страты) на основе общих характеристик (например, возраст, пол, уровень дохода), а затем случайную выборку из каждой страты.

Стратифицированная случайная выборка



Определите характеристики, по которым будет проводиться стратификация, и соответствующим образом разделите генеральную совокупность.



Для отбора выборки используйте простую случайную выборку в пределах каждой страты.

Пример



Нужно изучить средний балл студентов колледжа на разных специальностях. Можно разделить студентов на страты в зависимости от их специальности (наука, искусство, инженерное дело), а затем случайным образом отобрать студентов из каждой специальности.

Сравнение выборки



Плюсы

- Обеспечивает представительство всех подгрупп.
- Уменьшает ошибки выборки за счет контроля вариативности внутри страт.

Минусы

- Более сложный и трудоемкий метод, чем простая случайная выборка.
- Требуется подробная информация о генеральной совокупности для создания страт.



Кластерная выборка

Предполагает разделение совокупности на кластеры, обычно основанные на географических или организационных границах, а затем случайный отбор всех кластеров.

Кластерная выборка



Разделите совокупность на кластеры.



Случайным образом выберите несколько кластеров.



Включите в выборку всех членов выбранных кластеров.

Пример



Нужно исследовать домохозяйства в городе, можно разделить город на районы (кластеры) и случайным образом выбрать несколько районов. Затем опросить все домохозяйства в этих выбранных районах.

Сравнение выборки



Плюсы

- Экономичность и практичность для больших групп генеральной совокупности.
- Полезно, когда нет возможности получить полный список генеральной совокупности.

Минусы

- Большая ошибка выборки по сравнению с другими методами, если кластеры неоднородны.
- Результаты могут быть менее точными, если кластеры значительно отличаются друг от друга.



Систематическая выборка

Предполагает отбор каждого n -го члена генеральной совокупности после случайного начала.

Систематическая выборка



Перечислите всех членов генеральной совокупности.



Случайным образом выберите начальную точку между 1 и k . Случайный старт: Случайным образом выберите начальную точку между 1 и k .



Случайным образом выберите начальную точку между 1 и k .



Из начальной точки выберите каждый n -й член.

Пример



Есть список из 1 000 сотрудников и нужно отобрать выборку из 100 человек, можно задать интервал (k) равным 10. Если случайное начало равно 3, выбрать 3-го, 13-го, 23-го и так далее.

Сравнение выборки



Плюсы

- Простота и легкость реализации.
- Обеспечивает распределение по всей генеральной совокупности.

Минусы

- Может внести погрешность, если в списке генеральной совокупности есть скрытая закономерность.
- Менее случайна, чем простая случайная выборка.



ВОПРОСЫ





Центральная пределльная теорема (ЦПТ)



Центральная предельная теорема (ЦПТ)

Это фундаментальный принцип в области статистики, служащий краеугольным камнем для inferential statistics, которая предполагает составление прогнозов или выводов о совокупности на основе выборки данных.

Центральная предельная теорема



Если взять достаточно большие случайные выборки из генеральной совокупности, то распределение выборочных средних будет приближаться к нормальному распределению (колоколообразной кривой), независимо от формы распределения исходной генеральной совокупности.

Важность ЦПТ

- Основа для статистических методов
- Предсказуемость и стабильность
- Универсальность в различных дисциплинах



Перекошенные распределения

ЦПТ позволяет использовать для статистического анализа методы, основанные на нормальном распределении, поскольку при достаточно большом объеме выборки распределение средних становится приблизительно нормальным.



Равномерные распределения

Когда данные распределены равномерно, ЦПТ гарантирует, что распределение выборочных средних будет стремиться к нормальности, что облегчает применение стандартных статистических тестов.



Дискретные и непрерывные данные

ЦПТ применим как к дискретным (счетным), так и к непрерывным (измеряемым) типам данных. ЦПТ позволяет использовать статистические методы, основанные на нормальном распределении.



ВОПРОСЫ





Следствия центральной предельной теоремы

Основные следствия из ЦПТ

Нормальное распределение
выборочных средних

Влияние на размер выборки
и точность выводов



Нормальное распределение выборочных средних

Гарантирует, что распределение выборочных средних будет приближаться к нормальному распределению, независимо от исходного распределения генеральной совокупности.

Пример: фабрика по производству лампочек



Срок службы лампочек может быть распределен не совсем нормально: большинство из них служат около года, некоторые - значительно дольше. Если фабрика проверит срок службы случайных образцов лампочек и вычислит среднее значение срока службы для каждого образца, то, благодаря ЦПТ, распределение этих средних значений будет приближаться к нормальному распределению. Это позволяет фабрике делать надежные прогнозы относительно общего качества продукции.

Влияние на размер выборки и точность выводов



Размер выборки



Точность выводов



Практическое соображение



ВОПРОСЫ





Создание **выборочных** распределений с помощью Python



Выборочные распределения

Это ключевое понятие в статистике, особенно в контексте Центральной предельной теоремы. Позволяют понять поведение выборочных статистик (например, среднего значения) и сделать выводы о совокупности, из которой взяты выборки.



`random.sample(seq, n)`

Это функция, которая генерирует n уникальных образцов из последовательности без замены.



`random.choices(seq, n)`

Это функция, которая генерирует n образцов из последовательности с заменой.



`random.randint(a, b)`

Это функция, которая генерирует случайное целое число от a до b (включительно).



`numpy.random.normal` `(loc, scale, size)`

Это функция, которая генерирует случайные выборки из нормального распределения с заданными средним значением (`loc`), стандартным отклонением (`scale`) и размером выборки (`size`).

Моделирование выборочных распределений



1. Смоделировать выборочные распределения, генерируя случайные выборки из генеральной совокупности и вычисляя выборочные средние.
2. Построить график распределения этих выборочных средних, чтобы проследить влияние размера выборки на форму распределения.

Шаг 1: Импорт необходимых библиотек

```
import numpy as np
import matplotlib.pyplot as plt
import scipy.stats as stats
```

Шаг 2: Генерируем случайные выборки

```
# Параметры генеральной совокупности
mu = 50
sigma = 10

# Функция для генерации случайных выборок и вычисления выборочных средних
def generate_sample_means(sample_size, num_samples):
    sample_means = []
    for _ in range(num_samples):
        sample = np.random.normal(mu, sigma, sample_size)
        sample_means.append(np.mean(sample))
    return sample_means
```


Шаг 3: Моделирование распределений

```
# Параметры для моделирования
sample_sizes = [10, 30, 50, 100]
num_samples = 1000

# Построение графиков выборочных распределений
plt.figure(figsize=(12, 8))

for i, sample_size in enumerate(sample_sizes):
    sample_means = generate_sample_means(sample_size, num_samples)
    plt.subplot(2, 2, i+1)
    plt.hist(sample_means, bins=30, density=True, alpha=0.6, color='g')
    plt.title(f'Размер выборки = {sample_size}')
    plt.xlabel('Среднее значение выборки')
    plt.ylabel('Частота')
    # Постройте график нормального распределения для сравнения
    xmin, xmax = plt.xlim()
    x = np.linspace(xmin, xmax, 100)
    p = stats.norm.pdf(x, mu, sigma/np.sqrt(sample_size))
    plt.plot(x, p, 'k', linewidth=2)

plt.tight_layout()
plt.show()
```



Малый размер выборки ($n=10$)

Распределение выборочных средних может выглядеть не совсем нормальным и может быть весьма разбросанным.



Умеренный размер выборки ($n=30$)

Распределение начинает больше походить на нормальное распределение.



Большие размеры выборки ($n=50$, $n=100$)

Распределение выборочных средних становится более плотно сгруппированным вокруг среднего значения генеральной совокупности и приближается к нормальному распределению.



ВОПРОСЫ





Использование ЦПТ для нахождения вероятности

Шаг 1: Поймите теорему о центральном пределе



ЦПТ говорит нам, что при достаточно большом объеме выборки (обычно $n \geq 30$), выборочное распределение среднего значения выборки будет приблизительно нормально распределено со средним значением μ (среднее значение генеральной совокупности) и стандартным отклонением $\frac{\sigma}{\sqrt{n}}$

(стандартная ошибка), где σ - стандартное отклонение генеральной совокупности и n - объем выборки.

Шаг 2: Определение параметров



Чтобы применить ЦПТ, необходимо знать или оценить следующие параметры:

- Среднее значение генеральной совокупности (μ)
- Стандартное отклонение генеральной совокупности (σ)
- Размер выборки (n)
- Диапазон, в котором вы хотите найти вероятность для среднего значения выборки.

Шаг 3: Вычислите стандартную ошибку



Стандартная ошибка среднего (SEM) рассчитывается следующим образом $\frac{\sigma}{\sqrt{n}}$

Это измеряет дисперсию выборочных средних вокруг среднего генеральной совокупности.

Шаг 4: Стандартизация диапазона



Преобразуйте интересующий вас диапазон для выборочного среднего в z-score по формуле:

$$Z = \frac{\bar{x} - \mu}{SEM}$$

где $\bar{x}$ - это значение в диапазоне, для которого вы рассчитываете z-score. Сделайте это как для нижней, так и для верхней границы диапазона.

Шаг 5: Используйте стандартное нормальное распределение



Рассчитав z-score, используйте стандартное нормальное распределение, чтобы найти вероятности, соответствующие этим z-score. Это можно сделать с помощью таблиц стандартного нормального распределения или статистического программного обеспечения.

Шаг 6: Вычислите вероятность



Вероятность того, что выборочное среднее попадает в указанный диапазон, равна разности между вероятностями, соответствующими z-score верхней и нижней границ.

Если $P(Z < z_{\text{верхняя}})$ - это вероятность верхней границы, а $P(Z < z_{\text{нижняя}})$ - это вероятность для нижней границы, тогда вероятность того, что выборочное среднее попадает в диапазон, равна:

$$P(z_{\text{нижняя}} < Z < z_{\text{верхняя}}) = P(Z < z_{\text{верхняя}}) - P(Z < z_{\text{нижняя}}).$$



ВОПРОСЫ





ПРАКТИЧЕСКАЯ РАБОТА



Решение задач



Предположим, что генеральная совокупность имеет среднее значение (μ), равное 100, и стандартное отклонение (σ), равное 15. Вы берете выборку из 36 наблюдений и хотите найти вероятность того, что среднее значение выборки находится в диапазоне от 95 до 105.

Решение

```
from scipy.stats import norm
import numpy as np

mu = 100
sigma = 15
n = 36

sem = sigma / np.sqrt(n)

z_score_lower = (95 - mu) / sem
z_score_upper = (105 - mu) / sem

probability_lower = norm.cdf(z_score_lower)
probability_upper = norm.cdf(z_score_upper)

probability_between = probability_upper - probability_lower

print(f"Вероятность того, что выборочное среднее находится в диапазоне от 95 до 105, равна
примерно {probability_between:.4f}")
```




ВОПРОСЫ



Заключение

