


Python
for DA

Основы статистики. Доверительные интервалы



Преподаватель

Портрет

Имя Фамилия

Текущая должность

Количество лет опыта

Какой у Вас опыт - ключевые кейсы

Самые яркие проекты

Дополнительная информация по вашему усмотрению

Корпоративный e-mail

Социальные сети (по желанию)

Важно

- 

Камера должна быть включена на протяжении всего занятия
- 

В течение занятия вопросы задавать в чате или когда преподаватель спрашивает, есть ли у Вас вопросы
- 

Вести себя уважительно и этично по отношению к остальным участникам занятия
- 

Организационные вопросы по обучению решаются с кураторами, а не на тематических занятиях
- 

Во время занятия будут интерактивные задания, будьте готовы включить камеру или демонстрацию экрана по просьбе преподавателя

Повторение



Вероятностное сэмплирование



Центральная предельная теорема (ЦПТ): Определение и объяснение



Следствия центральной предельной теоремы (ЦПТ)



Создание выборочных распределений с помощью Python



Как использовать центральную предельную теорему для нахождения вероятности того, что выборочное среднее находится в некотором диапазоне

План занятия

- Понимание доверительных интервалов
- Интерпретация доверительных интервалов
- Применение в реальном мире
- Реализация Python для доверительных интервалов
- Понимание гипотез
- Типы ошибок при проверке гипотез



ОСНОВНОЙ БЛОК





Понимание доверительных интервалов





Доверительный интервал

Это диапазон значений, рассчитанный на основе данных выборки, который с большой вероятностью содержит значение неизвестного параметра генеральной совокупности. Интервал имеет соответствующий уровень доверия, который определяет степень уверенности в том, что в интервал входит параметр.

Цель доверительного интервала

Оценка

Измерение неопределенности



Уровень доверия и ширина доверительного интервала

неразрывно связаны между собой. уровень доверия, обычно выражаемый в процентах (например, 90%, 95% или 99%), показывает, насколько мы можем быть уверены в том, что интервал содержит параметр генеральной совокупности



Более высокий уровень доверия

Повышение уровня доверия означает, что мы хотим получить больше уверенности в том, что наш интервал содержит истинный параметр. Однако за это приходится платить: чтобы повысить уровень доверия, мы должны расширить наш интервал. 99%-ный доверительный интервал будет шире 95%-ного, что отражает большую неопределенность в отношении точного значения параметра, но больше уверенности в том, что интервал включает его.



Снижение уровня доверия

Уменьшение уровня доверия приводит к сужению интервала. Это говорит о меньшей неопределенности в отношении значения параметра, но и о меньшей уверенности в том, что интервал содержит параметр. Доверительный интервал 90% будет более узким, чем доверительный интервал 95%, что указывает на компромисс между точностью и достоверностью.

Расчет доверительных интервалов



формула для доверительного интервала вокруг среднего значения, когда известно стандартное отклонение генеральной совокупности, выглядит следующим образом:

$$\bar{x} \pm Z \times \frac{\sigma}{\sqrt{n}}$$

где $\bar{x}$ - среднее значение по выборке, Z - Z-score, соответствующий выбранному уровню доверия (например, 1,96 для 95%), σ - стандартное отклонение генеральной совокупности, и n - размер выборки.

Доверительный интервал для доли генеральной совокупности



рассчитывается по формуле:

$$p \pm Z \times \sqrt{\frac{p(1-p)}{n}}$$

где p - выборочная доля, Z - Z-score, соответствующий желаемому уровню доверия, n - объем выборки. В этой формуле предполагается, что объем выборки достаточно велик, чтобы биномиальное распределение было аппроксимировано нормальным распределением, обычно $np \geq 5$ и $n(1-p) \geq 5$.



ВОПРОСЫ





Интерпретация доверительных интервалов



95%-ный доверительный интервал

представляет собой диапазон значений, в пределах которого мы можем быть на 95% уверены в том, что истинный параметр генеральной совокупности (например, среднее значение или доля) находится на основе данных выборки. Эта интерпретация основана на подходе к доверительным интервалам с учетом долгосрочной частоты. Если бы мы повторяли исследование много раз, каждый раз рассчитывая новый 95%-ный ДИ на основе новой выборки, мы бы ожидали, что около 95% этих интервалов будут содержать истинный параметр генеральной совокупности.

Заблуждение 1



Заблуждение

ДИ содержит 95% данных

Пояснение

95%-ный ДИ - это не про собранные данные, а про то, где находится истинный параметр генеральной совокупности. Он не означает, что 95% данных выборки попадают в этот интервал.

Заблуждение 2



Заблуждение

Вероятность того, что истинный параметр лежит в пределах интервала, составляет 95 %.

Пояснение

После того как по выборке рассчитан ДИ, истинный параметр генеральной совокупности либо находится, либо нет в пределах этого интервала. Вероятность 95%" относится к долгосрочной частоте ДИ, содержащих параметр, при многократном повторении исследования, а не к вероятности того, что один интервал содержит параметр.

Заблуждение 3



Заблуждение

Более узкий интервал означает, что параметр с большей вероятностью будет в нем находиться

Пояснение

Ширина ДИ отражает точность оценки, а не вероятность того, что она содержит истинный параметр. Более узкий ДИ указывает на меньшую вариабельность и более точную оценку параметра, но не меняет уровень доверия.

Заблуждение 4



Заблуждение

Перекрывающиеся ДИ указывают на отсутствие существенной разницы

Пояснение

Перекрывающиеся ДИ между двумя группами не обязательно означают отсутствие значимых различий между группами. Для определения значимости различий необходимы статистические тесты.

Как избежать неверных интерпретаций



Ориентируйтесь на долгосрочную частоту: Поймите, что уровень доверия относится к надежности метода на протяжении многих повторений исследования, а не к уверенности в том, что параметр находится в одном интервале.



Точность против вероятности: Поймите, что ширина ДИ указывает на точность оценки, а не на вероятность содержания истинного параметра.



Статистическая значимость: Используйте соответствующие статистические тесты для оценки значимости различий между группами, а не полагайтесь только на перекрытие ДИ.



ВОПРОСЫ





Применение в реальном мире

Биология



Биологи используют доверительные интервалы для оценки характеристик видов растений и животных, таких как средний рост, вес или диаметр. Например, биолог может рассчитать 95%-ный доверительный интервал для оценки среднего веса лягушек в Австралии на основе выборки, чтобы получить диапазон, в который, скорее всего, попадет истинный средний вес.

Клинические испытания



В медицине доверительные интервалы имеют решающее значение для оценки эффективности лечения. Врач может использовать 95%-ный доверительный интервал для определения среднего изменения артериального давления у пациентов, принимающих новое лекарство, что поможет понять эффективность препарата и направить дальнейшие исследования или клиническое применение.

Реклама и маркетинг



Доверительные интервалы помогают отделам маркетинга оценивать эффективность рекламных кампаний. Сравнивая продажи, полученные в результате различных кампаний, с помощью доверительных интервалов, маркетологи могут определить, значительно ли кампания увеличивает доход, и тем самым определить будущие рекламные стратегии.

Производство



Инженеры используют доверительные интервалы в процессах контроля качества для оценки изменений в производстве бракованной продукции. Например, если считается, что новый производственный процесс снижает количество дефектов, доверительный интервал может помочь определить, являются ли наблюдаемые изменения в количестве дефектов статистически значимыми, что позволит усовершенствовать процесс.



Неправильная интерпретация

Распространенное заблуждение заключается в том, что 95%-ный доверительный интервал означает, что существует 95%-ная вероятность того, что интервал содержит истинный параметр. Однако правильная интерпретация заключается в том, что если эксперимент повторить много раз, то 95% рассчитанных КИ будут содержать истинный параметр. Это различие крайне важно для точной интерпретации.



Предположение о нормальности

Во многих расчетах КИ предполагается, что данные распределены нормально или что объем выборки достаточно велик, чтобы можно было применить теорему о центральном пределе. Это предположение может быть справедливо не для всех наборов данных, что может привести к неточным интервалам.



Фиксированный уровень доверия

Выбор доверительного уровня (например, 95 %) является несколько произвольным и может не отражать фактическую неопределенность оценки. Различные доверительные уровни дают интервалы разной ширины, что влияет на точность оценки.



Не учитывают систематические ошибки

Доверительные интервалы учитывают случайную ошибку выборки, но не учитывают возможные систематические ошибки или смещения в процессе сбора данных. Такие ошибки могут привести к неверным выводам, независимо от рассчитанного КИ



Зависимость от размера выборки

Ширина доверительного интервала находится в обратной зависимости от квадратного корня из размера выборки, то есть меньшие выборки дают более широкие интервалы. Это может привести к менее точным оценкам, особенно в исследованиях с ограниченным объемом данных.



ВОПРОСЫ





Реализация Python для доверительных интервалов

Шаг 1: Импорт необходимых библиотек

```
import numpy as np
import scipy.stats as st
import matplotlib.pyplot as plt
```

Шаг 2: Определите выборку

```
# Генерируем выборку
np.random.seed(0) # Для воспроизводимости
data = np.random.normal(loc=100, scale=15, size=50) # loc=mean, scale=std,
size=размер выборки
```

Шаг 3: Рассчитайте доверительный интервал

```
# Рассчитайте среднее значение и стандартную ошибку среднего
mean = np.mean(data)
sem = st.sem(data) # Стандартная ошибка среднего

# Определите доверительный интервал
confidence = 0.95

# Вычислить доверительный интервал
ci = st.t.interval(alpha=confidence, df=len(data)-1, loc=mean, scale=sem)

print(f "95% доверительный интервал (с использованием t-распределения): {ci}")
```

Шаг 4: Вычислите доверительный интервал

```
# Для больших наборов данных мы можем использовать нормальное распределение
ci_large = st.norm.interval(alpha=confidence, loc=mean, scale=sem)

print(f "95% доверительный интервал (с использованием нормального
распределения): {ci_large}")
```

Шаг 5: Визуализация доверительных интервалов

```
# Построение графика данных выборки
plt.figure(figsize=(10, 6))
plt.hist(data, bins=15, alpha=0.7, label='Sample Data')

# Построение графика среднего значения
plt.axvline(mean, color='red', linestyle='dashed', linewidth=2, label='Mean')

# Выделение доверительного интервала
plt.axvspan(ci[0], ci[1], color='yellow', alpha=0.3, label='95% CI (t-
распределение)')
plt.axvspan(ci_large[0], ci_large[1], color='green', alpha=0.3, label='95% CI
(нормальное распределение)')

plt.xlabel('Данные')
plt.ylabel('Частота')
plt.title('Выборка с доверительными интервалами')
plt.legend()
plt.show()
```




ВОПРОСЫ





Понимание гипотез



Проверка гипотез

фундаментальная концепция статистики и науки о данных, играющая важнейшую роль в методологии исследований в различных областях, таких как бизнес, здравоохранение и наука.



Нулевая гипотеза (H_0)

Нулевая гипотеза обычно представляет собой гипотезу о равенстве параметров генеральной выборки. Она представляет собой утверждение об отсутствии эффекта, связи или различий между выборкой и генеральной совокупностью. Она принимается за истинную до тех пор, пока не будет получено достаточно доказательств, чтобы ее отвергнуть.



Альтернативная гипотеза (H_1)

Альтернативная гипотеза по сути является обратной по отношению к нулевой гипотезе. Она представляет собой утверждение, указывающее на наличие эффекта, взаимосвязи или различий между выборкой и генеральной совокупностью. Альтернативная гипотеза - это то, что исследователи стремятся подтвердить с помощью анализа данных.

Пример 1



Преподаватель предполагает, что 60 % студентов его колледжа - выходцы из семей ниже среднего класса. В этом случае нулевой гипотезой (H_0)

Пример 1



Преподаватель предполагает, что 60 % студентов его колледжа - выходцы из семей ниже среднего класса. В этом случае нулевой гипотезой (H_0) может быть то, что реальный процент студентов из семей ниже среднего класса составляет 60 %, а альтернативной гипотезой (H_1) - то, что этот процент не составляет 60 %.

Пример 2



Врач считает, что программа 3D (диета, доза и дисциплина) на 90 % эффективна для пациентов с диабетом. Нулевая гипотеза (H_0) может утверждать, что эффективность программы 3D составляет 90 %, а альтернативная гипотеза (H_1) - что эффективность отличается от 90 %.



ВОПРОСЫ





Типы ошибок при проверке гипотез



Ошибка первого типа (ложноположительная)

Ошибка первого типа возникает, когда нулевая гипотеза (H_0) ошибочно отвергается, когда на самом деле она истинна. Этот тип ошибки также известен как ложноположительный. Вероятность совершения ошибки типа I обозначается α , который также называют уровнем значимости теста

Пример 1



В клинических испытаниях ошибка I типа может возникнуть, если новое лекарство будет признано эффективным в лечении какого-либо заболевания, а на самом деле это не так. Последствия ошибки первого типа могут быть значительными, что может привести к ненужному лечению, напрасной трате ресурсов или неправильным научным выводам.



Ошибка второго типа (ложноотрицательная)

И наоборот, ошибка II типа возникает, когда нулевая гипотеза не отвергается, а должна отвергаться, то есть тест не обнаруживает эффекта или различия, которые на самом деле существуют. Такая ошибка известна как ложноотрицательная. Вероятность совершения ошибки типа II обозначается как β , а мощность теста, то есть способность обнаружить эффект, если он есть, равна $1-\beta$

Пример 2



Ошибка второго типа в медицинском скрининг-тесте может не выявить заболевание у пациента, у которого оно действительно есть, что может привести к отсутствию необходимого лечения и ухудшению состояния здоровья.



ВОПРОСЫ





ПРАКТИЧЕСКАЯ РАБОТА



Задание

1. Учитывая выборку из 50 растений со средней высотой выборки 19.24 дюйма и известным стандартным отклонением популяции в 10 дюймов, рассчитайте 95% доверительный интервал для средней высоты популяции.
2. Учитывая выборку из 15 растений со средней высотой выборки 20.4 дюйма и стандартным отклонением выборки 5 дюймов, рассчитайте 99%-ный доверительный интервал для средней высоты популяции, используя t-распределение.
3. Учитывая данные выборки случайных целых чисел от 10 до 30 размером 50, рассчитайте и сравните доверительные интервалы 95% и 99%.

Решение 1

```
import numpy as np
import scipy.stats as st

sample_mean = 19.24
population_std = 10
sample_size = 50
confidence_level = 0.95

z_critical = st.norm.ppf((1 + confidence_level) / 2)
margin_of_error = z_critical * (population_std / np.sqrt(sample_size))

ci_lower = sample_mean - margin_of_error
ci_upper = sample_mean + margin_of_error

print(f"95% Confidence Interval: ({ci_lower:.2f}, {ci_upper:.2f})")
```

Решение 2

```
sample_mean = 20.4
sample_std = 5
sample_size = 15
confidence_level = 0.99

t_critical = st.t.ppf((1 + confidence_level) / 2, df=sample_size-1)
margin_of_error = t_critical * (sample_std / np.sqrt(sample_size))

ci_lower = sample_mean - margin_of_error
ci_upper = sample_mean + margin_of_error

print(f"99% Confidence Interval: ({ci_lower:.2f}, {ci_upper:.2f})")
```

Решение 3

```
import numpy as np
import scipy.stats as st

np.random.seed(0)
data = np.random.randint(10, 30, 50)

sample_mean = np.mean(data)
sem = st.sem(data)

ci_95 = st.norm.interval(confidence=0.95, loc=sample_mean, scale=sem)

ci_99 = st.norm.interval(confidence=0.99, loc=sample_mean, scale=sem)

print(f"95% Confidence Interval: {ci_95}")
print(f"99% Confidence Interval: {ci_99}")
```



ВОПРОСЫ



Домашнее задание

1. Рассчитайте 95% доверительный интервал для доли генеральной совокупности.

Инструкции:

- Смоделируйте опрос населения, в котором 1000 человек отвечают на бинарный вопрос (да/нет). Предположим, что 600 человек ответили "Да".
- Из этой популяции сделайте выборку из 100 ответов.
- Рассчитайте долю ответов "Да" в выборке.
- Вычислите 95%-ный доверительный интервал для популяционной доли ответов "Да".
- Обсудите, как доверительный интервал дает информацию о доле населения.

2. Продемонстрируйте влияние размера выборки на форму распределения средних, используя равномерное распределение.

Заключение

