

Python
for DA

Summary Session 8



Преподаватель

Портрет

Имя Фамилия

Текущая должность

Количество лет опыта

Какой у Вас опыт - ключевые кейсы

Самые яркие проекты

Дополнительная информация по вашему усмотрению

Корпоративный e-mail

Социальные сети (по желанию)

Важно

-  Камера должна быть включена на протяжении всего занятия
-  В течение занятия вопросы задавать в чате или когда преподаватель спрашивает, есть ли у Вас вопросы
-  Вести себя уважительно и этично по отношению к остальным участникам занятия
-  Организационные вопросы по обучению решаются с кураторами, а не на тематических занятиях
-  Во время занятия будут интерактивные задания, будьте готовы включить камеру или демонстрацию экрана по просьбе преподавателя



ПОВТОРЕНИЕ ИЗУЧЕННОГО



Экспресс-опрос



Что такое статистика?



Статистика

Это раздел математики, который занимается сбором, анализом, интерпретацией, представлением и организацией числовых данных.

Важность статистики в анализе данных

-  Обобщение данных
-  Принятие решений
-  Понимание взаимосвязей
-  Работа с неопределенностью
-  Визуализация данных
-  Применение в реальном мире

Экспресс-опрос

?

Какие типы статистики есть?

Типы статистики

Описательная статистика

Обобщение и описание характеристик
набора данных

Индуктивная статистика

Составление прогнозов или выводов о
совокупности на основе выборки
данных



Описательная статистика


Это раздел статистики, который включает в себя организацию, визуализацию и представление данных таким образом, чтобы обеспечить четкое и краткое обобщение собранной информации.

Описательная статистика



Направлена на описание характеристик изучаемого набора данных, не делая выводов или предсказаний за пределами анализируемых данных

Компоненты описательной статистики



Меры
центральной
тенденции

Меры дисперсии

Графические
представления



Индуктивная статистика

Это раздел статистики, который включает в себя прогнозы, выводы или обобщения о более широкой совокупности на основе данных, собранных на основе выборки этой совокупности.

Индуктивная статистика



Распространяет выводы, сделанные на основе выборки, на всю генеральную совокупность, из которой была взята выборка, позволяя исследователям делать выводы, проверять гипотезы и делать прогнозы

Компоненты индуктивной статистики



Проверка гипотез

Регрессионный
анализ

Доверительные
интервалы

Экспресс-опрос

?

Что такое генеральная совокупность?



Генеральная совокупность

Это вся совокупность точек данных, представляющих интерес в конкретном исследовании. Включает в себя все возможные наблюдения, которые могут быть сделаны в рамках определенной группы.

Характеристика генеральной совокупности



Включает каждый элемент изучаемой группы

Экспресс-опрос



Что такое параметр?



Параметр

Это измеряемая характеристика генеральной совокупности, такая как среднее значение или стандартное отклонение.

Примеры генеральной совокупности



Все жители страны
Все студенты университета
Все продукты, производимые компанией

Типы генеральных совокупностей

Конечная
совокупность

Бесконечная
совокупность

Существующая
генеральная
совокупность

Гипотетическая
генеральная
совокупность

Экспресс-опрос



Что такое выборка?



Выборка

Это подмножество генеральной совокупности, отобранное для анализа. Представляет собой меньшую, управляемую часть генеральной совокупности, отобранную для того, чтобы сделать выводы обо всей группе.

Характеристика выборки



Включает только часть генеральной совокупности



Статистика

Это измеряемая характеристика выборки, такая как среднее значение выборки или стандартное отклонение выборки.

Примеры выборки



Случайная выборка 1000 жителей страны
Группа из 200 студентов университета
Выборка продукции из производственной партии

Типы генеральных совокупностей

Случайная выборка

Стратифицированная
выборка

Удобная выборка

Различия между генеральной совокупностью и выборкой



Генеральная совокупность

- Вся исследуемая группа людей, предметов или наблюдений
- Все элементы, представляющие интерес
- Цель обобщения в исследовании
- Различные методы сбора данных
- Цель - понять характеристики, тенденции и закономерности всей группы

Выборка

- Подмножество людей, предметов или наблюдений, отобранных из генеральной совокупности
- Часть генеральной совокупности
- Используется, чтобы сделать выводы о более широкой генеральной совокупности
- Данные собираются с помощью методов выборки
- Цель - сделать выводы о совокупности на основе характеристик выборки

Важность статистического анализа



Эффективность



Целесообразность



Выводы

Экспресс-опрос



Что такое переменные?



Переменные

Это фундаментальные элементы, представляющие собой характеристики или свойства, которые мы измеряем или наблюдаем в ходе исследования. Необходимы для сбора, анализа и интерпретации данных



Качественные переменные

Это нечисловые данные, описывающие качества или характеристики. Делят данные на отдельные группы или категории на основе атрибутов или свойств, которые нельзя измерить численно.

Типы качественных переменных

Номинальные
переменные

Ординарные
переменные

Бинарные переменные

Качественные переменные

- Качественные переменные выражаются не числами, а описательными терминами.
- Классифицируют данные по категориям или группам.



Примеры:

- Цвет глаз
- Семейное положение
- Тип автомобиля
- Отзывы покупателей



Количественные переменные

Это данные, которые можно измерить и выразить численно. Выражают количественные характеристики и позволяют выполнять широкий спектр математических операций и статистических анализов.

Типы количественных переменных

Дискретные переменные

Непрерывные переменные

Количественные переменные

- Количественные переменные выражаются в числах.
- Они измеряют количества или суммы.



Примеры:

- Возраст
- Доход
- Расстояние
- Результаты тестов

Важность статистического анализа



Сбор данных



Статистические методы



Интерпретация



Описательная статистика

Это статистика, которая используется для обобщения и описания основных характеристик набора данных.



Мера центральной тенденции

Это ключевой аспект описательной статистики, который определяет центральную точку или типичное значение в наборе данных.

Экспресс-опрос



Что такое среднее значение?



Среднее значение

Это сумма всех значений в наборе данных, деленная на количество значений.

Среднее значение



$$\bar{x} = \frac{\sum x_i}{n}$$

$\sum x_i$ - сумма всех значений, а n - количество значений в наборе данных

Среднее значение



Пример расчета

Рассмотрим набор данных: 5, 4, 2, 3, 2, 1, 5, 4, 5

$$\bar{x} = \frac{5+4+2+3+2+1+5+4+5}{9} = \frac{31}{9} \approx 3.44$$

Команда Python

```
import numpy as np
data = [5, 4, 2, 3, 2, 1, 5, 4, 5]
mean = np.mean(data)
print(mean) # Выходные данные: 3.44
```

Экспресс-опрос



Что такое медиана?



Медиана

Это среднее значение в наборе данных, когда значения расположены в порядке возрастания или убывания.

Шаги для расчета медианы

1. Расположите данные в порядке возрастания.
2. Если количество наблюдений (n) нечетное, медиана - это среднее значение.
3. Если количество наблюдений (n) четное, медиана - это среднее значение двух средних значений.

Медиана



Пример расчета

Рассмотрим набор данных:

5, 4, 2, 3, 2, 1, 5, 4, 5

Упорядоченный набор данных:

1, 2, 2, 3, 4, 4, 5, 5, 5

Медиана: 4 (среднее значение)

Команда Python

```
median = np.median(data)
print(median) # Вывод: 4
```

Экспресс-опрос



Что такое мода?



Мода

Это значение, которое чаще всего встречается в наборе данных. Единственная мера центральной тенденции, которую можно использовать с номинальными данными (категориальными данными).

Мода



Набор данных может не иметь моды, иметь один моду или несколько мод

Мода



Пример расчета

Рассмотрим набор данных:

5, 4, 2, 3, 2, 1, 5, 4, 5

Мода: 5 (встречается наиболее часто)

Команда Python

```
from scipy import stats
mode = stats.mode(data)
print(mode.mode) # Вывод: 5
```

Выбор подходящей меры

Среднее значение

Подходит для
симметричных
распределений без
выбросов

Медиана

Подходит для
перекошенных
распределений или при
наличии выбросов

Мода

Подходит для
категориальных данных
или определения
наиболее часто
встречающегося значения
в наборе данных

Экспресс-опрос

?

Что такое меры дисперсии?



Меры дисперсии

Это статистические инструменты, используемые для описания разброса или изменчивости в наборе данных. Дают представление о том, насколько сильно точки данных отличаются от центрального значения, помогая понять распределение и согласованность данных.

Экспресс-опрос



Что такое диапазон?



Диапазон

Это простейшая мера дисперсии, которая рассчитывается как разница между максимальным и минимальным значениями в наборе данных.

Диапазон



Диапазон = Максимальное значение - Минимальное значение

Диапазон



Пример расчета

Набор данных:

5, 4, 2, 3, 2, 1, 5, 4, 5

Диапазон: $5 - 1 = 4$

Команда Python

```
data = [5, 4, 2, 3, 2, 1, 5, 4, 5]
range_value = max(data) - min(data)
print(range_value) # Вывод: 4
```

Экспресс-опрос



Что такое дисперсия?



Дисперсия

Измеряет среднее квадратичное отклонение каждой точки данных от среднего значения. Дает представление о том, насколько разбросаны точки данных.

Дисперсия



$$\sigma^2 = \frac{\sum (x_i - \bar{x})^2}{N}$$

Дисперсия



Пример расчета

Набор данных:

5, 4, 2, 3, 2, 1, 5, 4, 5

Среднее ($\bar{x}$) : ≈ 3.44

Дисперсия:

$$\frac{(5-3.44)^2 + (4-3.44)^2 + (2-3.44)^2 + \dots + (5-3.44)^2}{9} \approx 2.02$$

Команда Python

```
import numpy as np
variance = np.var(data)
print(variance) # Выходные данные: 2.02
```


Экспресс-опрос

?

Что такое стандартное отклонение?



Стандартное отклонение

Это квадратный корень из дисперсии, обеспечивающий меру дисперсии в тех же единицах, что и данные.

Стандартное отклонение



$$\sigma = \sqrt{\frac{\sum (x_i - \bar{x})^2}{N}}$$

Стандартное отклонение



Пример расчета

$$\sqrt{2.02} \approx 1.42$$

Команда Python

```
std_dev = np.std(data)  
print(std_dev) # Выходные данные: 1.42
```

Экспресс-опрос

?

Что такое межквартильный интервал?



Межквартильный интервал (IQR)

Измеряет разброс средних 50% данных, рассчитывается как разница между третьим квартилем (Q3) и первым квартилем (Q1).

Межквартильный интервал (IQR)



$$IQR = Q_3 - Q_1$$

Межквартильный интервал (IQR)



Пример расчета

Упорядоченный набор данных:

1, 2, 2, 3, 4, 4, 5, 5, 5

Q1: 2, Q3: 5

IQR: $5 - 2 = 3$.

Команда Python

```
Q1 = np.percentile(data, 25)
Q3 = np.percentile(data, 75)
IQR = Q3 - Q1
print(IQR) # Выходные данные: 3
```




ВОПРОСЫ



Экспресс-опрос

?

Что такое "ящик с усами"?



Графическая диаграмма или "ящик с усами"

Это графическое представление, используемое в описательной статистике для отображения распределения набора данных. Дает наглядное представление о центральной тенденции, изменчивости и асимметрии данных через их квартили.

Построение графической диаграммы

Минимум

Первый
квартиль (Q1)

Медиана (Q2)

Третий
квартиль (Q3)

Максимум
(Maximum)

Наименьшая
точка данных,
исключающая
провалы

Построение графической диаграммы

Минимум

Первый
квартиль (Q1)

Медиана (Q2)

Третий
квартиль (Q3)

Максимум
(Maximum)

Медиана нижней
половины набора
данных (25-й
процентиль)

Построение графической диаграммы

Минимум

Первый
квартиль (Q1)

Медиана (Q2)

Третий
квартиль (Q3)

Максимум
(Maximum)

Среднее
значение набора
данных (50-й
процентиль)

Построение графической диаграммы

Минимум

Первый
квартиль (Q1)

Медиана (Q2)

Третий
квартиль (Q3)

Максимум
(Maximum)

Медиана верхней
половины набора
данных (75-й
процентиль)

Построение графической диаграммы

Минимум

Первый
квартиль (Q1)

Медиана (Q2)

Третий
квартиль (Q3)

Максимум
(Maximum)

Наибольшая
точка данных без
учета выбросов.

Графическая диаграмма



Для определения разброса средних 50% данных используется интерквартильный размах (IQR), который представляет собой расстояние между Q1 и Q3



Выбросы

Определяются как точки данных, которые находятся ниже $Q1 - 1,5IQR$ или выше $Q3 + 1,5IQR$.

Графическая диаграмма в Matplotlib

```
import matplotlib.pyplot as plt
import numpy as np

np.random.seed(42)
data = np.random.normal(100, 20, 200)

plt.boxplot(data)
plt.title("Box Plot using Matplotlib")
plt.show()
```

Графическая диаграмма в Seaborn

```
import seaborn as sns
import matplotlib.pyplot as plt

tips = sns.load_dataset("tips")

sns.boxplot(x=tips["total_bill"])
plt.title("Box Plot using Seaborn")
plt.show()
```

Графическая диаграмма в Plotly

```
import plotly.graph_objects as go
import numpy as np

np.random.seed(42)
y0 = np.random.randn(50) - 1

fig = go.Figure()
fig.add_trace(go.Box(y=y0))
fig.show()
```

Интерпретация диаграммы "ящик с усами"

Описательная
статистика

Индуктивная
статистика

Описательная
статистика

Индуктивная
статистика

Граница представляет собой межквартильный интервал (IQR), который содержит средние 50% данных

Интерпретация диаграммы "ящик с усами"

Описательная
статистика

Индуктивная
статистика

Описательная
статистика

Индуктивная
статистика

Линия внутри коробки
указывает на медиану
(Q2) набора данных

Интерпретация диаграммы "ящик с усами"

Описательная
статистика

Индуктивная
статистика

Описательная
статистика

Индуктивная
статистика

Линии, идущие от рамки к
минимальному и
максимальному
значениям в пределах
 $1,5 \cdot IQR$ от $Q1$ и $Q3$,
соответственно

Интерпретация диаграммы "ящик с усами"

Описательная
статистика

Индуктивная
статистика

Описательная
статистика

Индуктивная
статистика

Точки за пределами усов
считаются выбросами и
наносятся на график
отдельно

Польза диаграммы "ящик с усами"



Определения центрального значения и разброса данных



Выявления перекоса и симметрии в распределении данных



Сравнения распределений по различным группам



Выделения провалов и понимания их влияния на набор данных

Экспресс-опрос

?

Что делает биномиальное распределение?



Биномиальное распределение

Моделирует количество успехов в фиксированном числе независимых испытаний бинарного эксперимента. Каждое испытание имеет два возможных исхода: успех или неудача. Вероятность успеха одинакова для каждого испытания.

Биномиальное распределение



Параметры

- n : Количество испытаний
- p : Вероятность успеха в каждом испытании

Функция вероятности

$$P(X = k) = C_n^k p^k (1 - p)^{n-k}$$

C_n^k - биномиальный коэффициент, представляющий собой количество способов выбора k успехов из n испытаний.

Пример



Рассмотрим сценарий, в котором вы подбрасываете монету 10 раз и хотите найти вероятность получения ровно 6 голов (успехов), если вероятность получения головы при каждом подбрасывании равна 0,5

Реализация примера

```
from scipy.stats import binom
import seaborn as sns
import matplotlib.pyplot as plt

# Параметры
n = 10 # количество испытаний
p = 0.5 # вероятность успеха

# Генерируем случайные величины с биномиальным распределением
data_binom = binom.rvs(n=n, p=p, size=10000)

# Построение графика распределения
ax = sns.histplot(data_binom, kde=False, color='skyblue', bins=30)
ax.set(xlabel='Биномиальное распределение', ylabel='Частота')
plt.title('Биномиальное распределение (n=10, p=0.5)')
plt.show()
```

Экспресс-опрос

?

Что делает распределение Пуассона?



Распределение Пуассона

Моделирует количество событий, происходящих в фиксированном интервале времени или пространства, с учетом среднего числа повторений события за этот интервал. Оно используется для событий, которые происходят независимо и с постоянной скоростью.

Биномиальное распределение



Параметры

λ : Среднее количество событий в интервале

Функция вероятности

$$P(X = k) = \frac{e^{-\lambda} \lambda^k}{k!}$$

где e - основание натурального логарифма,
 k - количество вхождений

Пример



Рассмотрим сценарий, в котором колл-центр получает в среднем 3 звонка в минуту.
Вы хотите найти вероятность получения ровно 5 звонков за минуту

Реализация примера

```
from scipy.stats import poisson
import seaborn as sns
import matplotlib.pyplot as plt

# Параметр
mu = 3 # среднее число вхождений (лямбда)

# Генерируем случайные переменные с пуассоновским распределением
data_poisson = poisson.rvs(mu=mu, size=10000)

# Построение графика распределения
ax = sns.histplot(data_poisson, kde=False, color='skyblue', bins=30)
ax.set(xlabel='Распределение Пуассона', ylabel='Частота')
plt.title('Распределение Пуассона (лямбда=3)')
plt.show()
```

- Используется для фиксированного числа независимых испытаний с двумя возможными исходами.
- Используется в сценариях, где есть два возможных исхода (успех или неудача) для фиксированного числа независимых испытаний, с постоянной вероятностью успеха.

Биномиальное распределение

- Используется для моделирования количества событий в фиксированном интервале.
- Используется для моделирования количества раз, когда событие происходит в фиксированном интервале времени или пространства, когда эти события происходят с известной средней скоростью и независимо от времени, прошедшего с момента последнего события.

Распределение Пуассона

Экспресс-опрос

?


Что такое непрерывные распределения?




Непрерывные распределения

Описывают вероятности возможных значений
непрерывной случайной величины.


Непрерывные распределения



Нормальное
распределение



Равномерное
распределение



Экспоненциальное
распределение

Экспресс-опрос

?

Что такое нормальное распределение?



Нормальное распределение

Или распределение Гаусса, - это непрерывное распределение вероятностей, характеризующееся колоколообразной кривой. Симметрично относительно среднего значения, причем данные вблизи среднего значения встречаются чаще, чем данные вдали от среднего значения.

Нормальное распределение



Параметры

- μ : Среднее значение распределения
- σ : Стандартное отклонение распределения

Функция вероятности

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$

Пример



Рассмотрим сценарий, в котором рост взрослых мужчин распределен нормально со средним значением 70 дюймов и стандартным отклонением 3 дюйма

Реализация примера

```
import numpy as np
import matplotlib.pyplot as plt
from scipy.stats import norm

# Параметры
mu = 70 # среднее значение
sigma = 3 # стандартное отклонение

# Генерируем нормально распределенные случайные величины
data_normal = np.random.normal(mu, sigma, 1000)

# Построение графика распределения
plt.hist(data_normal, bins=30, density=True, alpha=0.6, color='g')

# Построение графика PDF
xmin, xmax = plt.xlim()
x = np.linspace(xmin, xmax, 100)
p = norm.pdf(x, mu, sigma)
plt.plot(x, p, 'k', linewidth=2)
plt.title("Нормальное распределение (mu=70, sigma=3)")
plt.show()
```

Примеры использования нормального распределения

Рост отдельных
людей

Результаты тестов

Артериальное
давление

Вес
новорожденных
при рождении

Экспресс-опрос

?

Что такое равномерное распределение?



Равномерное распределение

Это непрерывное распределение вероятностей, в котором все интервалы одинаковой длины в пределах диапазона распределения одинаково вероятны.

Равномерное распределение



Параметры

- a : Нижняя граница
- b : Верхняя граница

Функция вероятности

$$f(x) = \frac{1}{b-a} \text{ для } a \leq x \leq b$$

Пример



Рассмотрим сценарий, в котором случайная величина равномерно распределена между 0 и 10

Реализация примера

```
from scipy.stats import uniform
import matplotlib.pyplot as plt
import numpy as np

# Параметры
a = 0 # нижняя граница
b = 10 # верхняя граница

# Генерируем равномерно распределенные случайные величины
data_uniform = uniform.rvs(loc=a, scale=b-a, size=1000)

# Построение графика распределения
plt.hist(data_uniform, bins=30, density=True, alpha=0.6, color='b')

# Построение графика PDF
x = np.linspace(a, b, 100)
p = uniform.pdf(x, loc=a, scale=b-a)
plt.plot(x, p, 'k', linewidth=2)
plt.title("Равномерное распределение (a=0, b=10)")
plt.show()
```

Примеры использования экспоненциального распределения

Время между
прибытиями
клиентов

Время между
отказами

Время между
землетрясениями

Экспресс-опрос

?

Что такое экспоненциальное распределение?



Экспоненциальное распределение

Это непрерывное распределение вероятностей, которое описывает время между событиями в пуассоновском процессе. Используется для моделирования времени до наступления события.

Экспоненциальное распределение



Параметры

λ : Параметр скорости (обратный среднему значению)

Функция вероятности

$$f(x) = \lambda e^{-\lambda x} \text{ для } x \geq 0$$

Пример



Рассмотрим сценарий, в котором среднее время между прибытиями в пункт обслуживания составляет 5 минут. Параметр скорости λ равен $1/5$

Реализация примера

```
from scipy.stats import expon
import matplotlib.pyplot as plt
import numpy as np

# параметр
lambda_ = 1/5 # Параметр скорости

# Генерируем экспоненциально распределенные случайные величины
data_exponential = expon.rvs(scale=1/lambda_, size=1000)

# Построение графика распределения
plt.hist(data_exponential, bins=30, density=True, alpha=0.6, color='r')

# Построение графика PDF
x = np.linspace(0, np.max(data_exponential), 100)
p = expon.pdf(x, scale=1/lambda_)
plt.plot(x, p, 'k', linewidth=2)
plt.title("Экспоненциальное распределение (лямбда=1/5)")
plt.show()
```

Примеры использования экспоненциального распределения

Время ожидания
лифта

Генерация
случайных чисел

Бросок игральной
кости

Экспресс-опрос



Что такое асимметрия?



Асимметрия

Это мера положения распределения вероятностей вещественной случайной величины относительно ее среднего значения. Показывает, насколько точки данных перекошены влево (отрицательная асимметрия) или вправо (положительная асимметрия) от среднего значения.

Асимметрия

Положительная
асимметрия (правая
ассиметрия)

Отрицательная асимметрия
(ассиметрия влево)

Нулевая асимметрия
(Zero Skewness)

Правый хвост (более высокие значения) длиннее или толще левого хвоста. Среднее значение больше медианы.

Асимметрия

Положительная
асимметрия (правая
ассиметрия)

Отрицательная асимметрия
(ассиметрия влево)

Нулевая асимметрия
(Zero Skewness)

Левый хвост (меньшие значения)
длиннее или толще правого хвоста.
Среднее значение меньше
медианы.

Асимметрия

Положительная
асимметрия (правая
ассиметрия)

Отрицательная асимметрия
(ассиметрия влево)

Нулевая асимметрия
(Zero Skewness)

Данные симметрично
распределены вокруг среднего
значения, что свидетельствует о
нормальном распределении.

Формула для перекоса

$$\text{Skewness} = \frac{n}{(n-1)(n-2)} \sum \left(\frac{x_i - \bar{x}}{s} \right)^3,$$

где:

- n - количество точек данных
- x_i - это каждая отдельная точка данных
- $\bar{x}$ - среднее значение данных
- s - стандартное отклонение данных

Пример

```
import pandas as pd
import numpy as np
from scipy.stats import skew

# Пример набора данных
data = np.random.normal(0, 1, 1000)

# Рассчёт асимметрии с помощью pandas
skewness_pandas = pd.Series(data).skew()
print(f "Skewness (pandas): {skewness_pandas}")

# Рассчёт асимметрии с помощью scipy
skewness_scipy = skew(data)
print(f "Skewness (scipy): {skewness_scipy}")
```

Экспресс-опрос

?

Что такое эксцесс?



Эксцесс

Это мера "хвостатости" распределения вероятностей. Показывает, сколько данных находится в хвостах и пиках распределения по сравнению с нормальным распределением.

Эксцесс

Положительный эксцесс

Отрицательный эксцесс

Нулевой эксцесс

Распределение имеет более тяжелые хвосты и более острый пик, чем нормальное распределение. Указывает на большую вероятность экстремальных значений.

Эксцесс

Положительный эксцесс

Отрицательный эксцесс

Нулевой эксцесс

Распределение имеет более светлые хвосты и более плоский пик, чем нормальное распределение.

Эксцесс

Положительный эксцесс

Отрицательный эксцесс

Нулевой эксцесс

Распределение имеет хвосты,
похожие на нормальное
распределение.

Формула для перекоса

$$\text{Kurtosis} = \frac{n(n+1)}{(n-1)(n-2)(n-3)} \sum \left(\frac{x_i - \bar{x}}{s} \right)^4 - \frac{3(n-1)^2}{(n-2)(n-3)},$$

где:

- n - количество точек данных
- x_i - это каждая отдельная точка данных
- $\bar{x}$ - среднее значение данных
- s - стандартное отклонение данных

Пример

```
from scipy.stats import kurtosis

# Вычисление эксцесса с помощью pandas
kurtosis_pandas = pd.Series(data).kurt()
print(f "Kurtosis (pandas): {kurtosis_pandas}")

# Вычисление эксцесса с помощью scipy
kurtosis_scipy = kurtosis(data)
print(f "Kurtosis (scipy): {kurtosis_scipy}")
```




ВОПРОСЫ



Экспресс-опрос

?

Что такое функция распределения (CDF) случайной величины X ?



Функция распределения (CDF) случайной величины X

Это функция, которая дает вероятность того, что X примет значение, меньшее или равное x . Это фундаментальное понятие в теории вероятностей и статистике.

Функция распределения (CDF)



Определение

$$F_X(x) = P(X \leq x),$$

где $F_X(x)$ - это функция распределения (CDF) случайной переменной X .

Свойства

- CDF не убывает
- CDF находится в диапазоне от 0 до 1

Пример



Рассмотрим нормальное распределение со средним значением 0 и стандартным отклонением 1. CDF можно использовать для нахождения вероятности того, что значение, взятое из этого распределения, меньше или равно определенному значению.

Реализация на языке Python

```
import numpy as np
import matplotlib.pyplot as plt
from scipy.stats import norm

# Параметры
mu = 0 # среднее значение
sigma = 1 # стандартное отклонение

# Генерируем значения
x = np.linspace(-3, 3, 1000)
cdf_values = norm.cdf(x, mu, sigma)

# Строим график CDF
plt.plot(x, cdf_values, label='CDF')
plt.title('Функция распределения (CDF) нормального распределения')
plt.xlabel('x')
plt.ylabel('F_X(x)')
plt.legend()
plt.show()
```

Экспресс-опрос

?

Что такое функция процентной точки (PPF)?



Функция процентной точки (PPF)

Это функция, дающая значение, ниже которого окажется заданный процент наблюдений в распределении. Она является обратной по отношению к CDF.

Функция процентной точки (PPF)



Определение

$$x = F_X^{-1}(p),$$

где $F_X^{-1}(p)$ - это PPF и p - вероятность.

Свойства

- PPF используется для нахождения критических значений при проверке гипотез
- Она полезна для генерации случайных выборок из заданного распределения

Пример



Рассмотрим нормальное распределение со средним значением 0 и стандартным отклонением 1. PPF можно использовать для нахождения значения, ниже которого окажется заданный процент наблюдений.

Реализация на языке Python

```
# Генерируем значения
percentiles = np.linspace(0, 1, 1000)
ppf_values = norm.ppf(percentiles, mu, sigma)

# Строим график PPF
plt.plot(percentiles, ppf_values, label='PPF')
plt.title('Функция процентных точек (PPF) нормального распределения')
plt.xlabel('Перцентили')
plt.ylabel('x')
plt.legend()
plt.show()
```

Экспресс-опрос

?

Что такое функция выживания (SF)?



Функция выживания (SF)

Это функция, которая дает вероятность того, что случайная переменная X больше определенного значения x . Она является дополнением CDF.

Функция выживания (SF)



Определение

$$S_X(x) = P(X > x) = 1 - F_X(x),$$

где $S_X(x)$ - это функция надёжности случайной переменной X .

Свойства

- Функция выживания не является возрастающей
- Она изменяется от 1 до 0

Пример



Рассмотрим нормальное распределение со средним значением 0 и стандартным отклонением 1. Функция выживания может быть использована для нахождения вероятности того, что значение, взятое из этого распределения, больше определенного значения.

Реализация на языке Python

```
# Генерируем значения
survival_values = 1 - cdf_values

# Строим график функции выживания
plt.plot(x, survival_values, label='Функция выживания')
plt.title('Функция выживания нормального распределения')
plt.xlabel('x')
plt.ylabel('S_X(x)')
plt.legend()
plt.show()
```


Экспресс-опрос

?

Что такое CDF в точке x ?



CDF в точке x

Это площадь под кривой PDF от отрицательной бесконечности до x .

Экспресс-опрос

?


Что такое условная вероятность?



Условная вероятность

Это фундаментальная концепция теории вероятностей, которая связана с определением вероятности события с учетом того, что другое событие уже произошло.

Условная вероятность



Формула для расчета условной вероятности



$$P(A|B) = \frac{P(A \cap B)}{P(B)},$$

где $P(A \cap B)$ - вероятность того, что произойдут и A, и B (совместная вероятность),
 $P(B)$ - это вероятность того, что произойдет B.

Пример



Задача

Представьте, что у вас есть колода из 52 карт, и вы хотите узнать вероятность вытащить туза, учитывая, что карта красная. Здесь событие A - вытащить туза, а событие B - вытащить красную карту.

Решение

$$P(A|B) = \frac{P(A \cap B)}{P(B)} = \frac{2/52}{26/52} = \frac{1}{13}$$

Экспресс-опрос

?

Что такое закон полной вероятности?



Закон полной вероятности

Это фундаментальная концепция теории вероятностей, которая помогает рассчитать вероятность события, учитывая все возможные варианты его наступления.

Разбиение пространства выборки



Можно разделить пространство выборки на несколько
взаимоисключающих и исчерпывающих событий

$$B_1, B_2, \dots, B_n$$

События

Взаимоисключающие

Никакие два события не могут
произойти в одно и то же время

Исчерпывающие

Вместе события охватывают все
пространство выборки

Закон полной вероятности

- Событие A: это событие, вероятность которого мы хотим вычислить.
- Например, пусть A - это событие выпадения четного числа.

Закон полной вероятности



Случай 1

Если A - событие в пространстве выборок S , и $B_1, B_2, \dots, B_n$ являются взаимоисключающими и исчерпывающими событиями, которые разбивают S , тогда вероятность того, что A произойдет, может быть выражена как:

$$P(A) = P(A \cap B_1) + P(A \cap B_2) + \dots + P(A \cap B_n)$$

Случай 2

Если известны условные вероятности A с учетом каждого B_i и вероятности каждого B_i , закон можно записать в виде:

$$P(A) = P(A|B_1)P(B_1) + P(A|B_2)P(B_2) + \dots + P(A|B_n)P(B_n)$$

Экспресс-опрос

?

Что такое теорема Байеса?



Теорема Байеса

Это расширение условной вероятности, которое позволяет нам обновлять вероятность события на основе новых данных. Предоставляет математический способ пересмотреть наши убеждения в свете новой информации.

Формула теоремы Байеса



$$P(A|B) = \frac{P(B|A)P(A)}{P(B)}$$

где $P(A|B)$ - апостериорная вероятность A с учетом B,
 $P(B|A)$ - вероятность того, что B будет соответствовать A,
 $P(A)$ - предварительная вероятность A,
 $P(B)$ - предельная вероятность B.

Пример



Задача

Допустим, у нас есть болезнь, которая поражает 1 % населения ($P(A)=0.01$) и тест с 99-процентной точностью ($P(B|A)=0.99$). Если у человека положительный тест ($P(B)$), какова вероятность того, что у него действительно есть заболевание?

Решение

$$P(B) = P(B|A)P(A) + P(B|\bar{A})P(\bar{A}) =$$

$$= 0.99 \times 0.01 + 0.01 \times 0.99 = 0.0198$$

$$P(A|B) = \frac{0.99 \times 0.01}{0.0198} = 0.5$$



ВОПРОСЫ



Экспресс-опрос



Что такое Z-score?



Z-score

Это статистическое измерение, описывающее отношение значения к среднему значению группы значений. Показывает, на сколько стандартных отклонений точка данных отличается от среднего значения набора данных.

Z-score

Положительный
Z-score

Указывает на то, что точка
данных находится выше
среднего значения

Отрицательный
Z-score

Указывает на то, что точка
данных находится ниже
среднего значения

Z-score, равный 0

Означает, что точка
данных находится точно
на среднем уровне

Важность Z-score



Сравнение



Выявление выбросов



Вероятность

Формула для расчета Z-score



$$Z = \frac{x - \mu}{\sigma},$$

где z - Z-score. x - стандартизируемая величина, μ - среднее значение генеральной совокупности, σ - стандартное отклонение.

Z-score



Пример

Предположим, у нас есть набор данных тестовых оценок со средним значением (μ), равным 70, и стандартным отклонением (σ), равным 10. Мы хотим найти Z-score для тестового балла (x), равного 85.

Решение

1. Вычтите среднее значение из индивидуального балла:

$$85 - 70 = 15$$

2. Разделите разницу на стандартное отклонение:

$$15 / 10 = 1.5$$

Реализация на языке Python

```
import numpy as np

# Определите данные
data = [55, 60, 65, 70, 75, 80, 85]

# Вычислите среднее значение и стандартное отклонение
mean = np.mean(data)
std_dev = np.std(data)

# Вычислите Z-скор для конкретного значения
x = 85
z_score = (x - mean) / std_dev

print(f"Среднее значение: {mean}")
print(f"Стандартное отклонение: {std_dev}")
print(f"Z-score для {x}: {z_score}")
```

Стандартизация данных



Стандартизация преобразует данные в общую шкалу со средним значением 0 и стандартным отклонением 1. Это важно при сравнении точек данных из разных распределений или наборов данных с разными единицами измерения или шкалами.

Стандартизация данных



Пример

Предположим, у вас есть результаты двух разных экзаменов с разными средними и стандартными отклонениями. Преобразовав их в Z-score, вы сможете сравнить успеваемость студентов на обоих экзаменах по единой шкале.

Реализация на языке Python

```
import numpy as np

exam1_scores = [85, 90, 78, 92, 88]
exam2_scores = [75, 80, 70, 85, 78]

mean_exam1 = np.mean(exam1_scores)
std_exam1 = np.std(exam1_scores)
mean_exam2 = np.mean(exam2_scores)
std_exam2 = np.std(exam2_scores)

z_scores_exam1 = [(x - mean_exam1) / std_exam1 for x in exam1_scores]
z_scores_exam2 = [(x - mean_exam2) / std_exam2 for x in exam2_scores]

print("Z-баллы для экзамена 1:", z_scores_exam1)
print("Z-баллы для экзамена 2:", z_scores_exam2)
```

Экспресс-опрос



Что такое выброс?



Выброс

Это точка данных, которая значительно отклоняется от других наблюдений. Как правило, точки данных с Z-score больше 3 или меньше -3 считаются выброшенными.

Определение выбросов



Пример

В наборе данных о росте студентов вы можете использовать Z-score, чтобы определить всех студентов, чей рост значительно отклоняется от среднего.

Реализация на языке Python

```
heights = [160, 162, 165, 170, 175, 180, 185, 190, 195, 200, 320]

mean_height = np.mean(heights)
std_height = np.std(heights)

z_scores_heights = [(x - mean_height) / std_height for x in heights]

outliers = [x for x, z in zip(heights, z_scores_heights) if abs(z) > 3]

print("Выбросы:", outliers)
```


Сравнение различных наборов данных



Z-score позволяют сравнивать точки данных из разных наборов данных, стандартизируя их значения. Важно, когда наборы данных имеют разные шкалы или единицы измерения.

Сравнение различных наборов данных



Пример

Сравнение высоты учеников двух разных школ с разным средним ростом и стандартным отклонением.

Реализация на языке Python

```
school1_heights = [160, 162, 165, 170, 175]
school2_heights = [150, 155, 160, 165, 170]

# Рассчитайте среднее значение и стандартное отклонение для каждой школы
mean_school1 = np.mean(school1_heights)
std_school1 = np.std(school1_heights)
mean_school2 = np.mean(school2_heights)
std_school2 = np.std(school2_heights)

# Стандартизация высот
z_scores_school1 = [(x - mean_school1) / std_school1 for x in school1_heights]
z_scores_school2 = [(x - mean_school2) / std_school2 for x in school2_heights]

print("Z-баллы для школы 1:", z_scores_school1)
print("Z-баллы для школы 2:", z_scores_school2)
```

Оценка вероятности



Z-score используются для оценки вероятности того, что определенная точка данных находится в пределах нормального распределения. Переведя Z-score в процент или используя стандартную таблицу нормального распределения, можно определить вероятность того, что значение будет выше или ниже определенного порога.

Применение Z-score

-  Стандартизация данных
-  Выявление выбросов
-  Проверка гипотез
-  Сравнение различных наборов данных
-  Оценка вероятности

Экспресс-опрос

?

Что такое стандартное нормальное распределение?



Стандартное нормальное распределение

Это частный случай нормального (или гауссовского) распределения. Оно характеризуется средним значением (μ), равным 0, и стандартным отклонением (σ), равным 1.

Экспресс-опрос

?

Какие свойства стандартного нормального распределения вы знаете?

Свойства стандартного нормального распределения



Симметрия



Среднее значение, медиана и мода



Колоколообразная кривая



Площадь под кривой



Стандартное отклонение и дисперсия



Эмпирическое правило

Значимость стандартного нормального распределения

Стандартизация

Проверка гипотез

Доверительные
интервалы

Центральная
предельная
теорема

Экспресс-опрос




Что такое Z-таблица?



Z-таблица

Это кумулятивная вероятность для данного Z-score, которая представляет собой площадь под стандартной нормальной кривой слева от этого Z-score.

Шаги по нахождению вероятностей с помощью Z-score



Пример 1: Вероятность того, что меньше определенного Z-score



Задача

Найти вероятность того, что значение в заданном распределении имеет Z-score меньше, чем $z=0.25$.

Решение

Z-таблица показывает, что кумулятивная вероятность для $z=0.25$ равна примерно 0,5987.

Вероятность того, что значение имеет Z-score меньше 0,25, равна 0,5987 или 59,87 %.

Пример 2: Вероятность того, что значение больше определенного Z-score



Задача

Найти вероятность того, что значение в данном распределении имеет Z-score больше, чем $z = -0.5$.

Решение

Найдите -0,5 в Z-таблице. Кумулятивная вероятность равна 0,3085.

Мы хотим, чтобы вероятность была больше, чем $z = -0.5$, мы вычитаем кумулятивную вероятность из 1.

$$P(z > -0.5) = 1 - P(z < -0.5) = 1 - 0.3085 \approx 0.6915.$$

Вероятность того, что значение имеет Z-score больше, чем -0,5, равна 0,6915 или 69,15%.

Пример 3: Вероятность между двумя Z-score



Задача

Найти вероятность того, что значение в данном распределении имеет Z-score между $z=0.4$ и $z=1$.

Решение

Для $z=0.4$, кумулятивная вероятность равна 0,6554. Для $z=1$, суммарная вероятность равна 0,8413.

Вычтите меньшую кумулятивную вероятность из большей.

$$\begin{aligned} P(0.4 < z < 1) &= P(z < 1) - P(z < 0.4) = \\ &= 0.8413 - 0.6554 \approx 0.1859 \end{aligned}$$

Вероятность того, что значение имеет Z-score между 0,4 и 1, равна 0,1859 или 18,59%.

Пример на языке Python

```
from scipy.stats import norm
```

```
# Пример 1: Вероятность меньше определенного Z-score
```

```
z1 = 0.25
```

```
prob_less_than_z1 = norm.cdf(z1)
```

```
print(f"Вероятность меньше {z1}: {prob_less_than_z1}")
```

```
# Пример 2: Вероятность больше определенного Z-score
```

```
z2 = -0.5
```

```
prob_greater_than_z2 = 1 - norm.cdf(z2)
```

```
print(f"Вероятность больше {z2}: {prob_greater_than_z2}")
```

```
# Пример 3: Вероятность между двумя Z-score
```

```
z3 = 0.4
```

```
z4 = 1
```

```
prob_between_z3_z4 = norm.cdf(z4) - norm.cdf(z3)
```

```
print(f"Вероятность между {z3} и {z4}: {prob_between_z3_z4}")
```



ВОПРОСЫ





ЗАДАНИЕ



Задание

Завершить работу над задачами с практикумов 15 и 16.



Задание 1



Загрузите набор данных `tips`. Рассчитайте среднее значение, медиану, стандартное отклонение и интерквартильный размах (IQR) для каждой числовой переменной. Кроме того, создайте сводную таблицу и визуализируйте распределения с помощью гистограмм и бокс-диаграмм.

Задание 2



Завод производит лампочки, и вероятность того, что лампочка окажется бракованной, равна 0,02. Рассчитайте вероятность того, что в партии из 500 лампочек окажется ровно 10 бракованных лампочек. Кроме того, смоделируйте этот сценарий 10 000 раз и сравните эмпирическую вероятность с теоретической.

Задание 3



Центр обработки вызовов получает в среднем 5 вызовов в минуту. Рассчитайте вероятность получения ровно 8 звонков в данную минуту. Кроме того, смоделируйте количество звонков, полученных за 1 000 минут, и сравните эмпирическое распределение с теоретическим распределением Пуассона.

Задание 4



Смоделируйте время ожидания для 1 000 событий, происходящих со средней скоростью 2 события в минуту. Рассчитайте среднее время ожидания и постройте гистограмму с PDF.

Задание 5



Создайте набор данных из 5 000 значений с равномерным распределением от 10 до 20. Вычислите среднее значение, стандартное отклонение и постройте гистограмму с PDF.

Задание 1



Вычислите вероятность того, что значение, взятое из нормального распределения (среднее = 100, стандартное отклонение = 15), превышает 130.

Задание 2



Для равномерного распределения от 0 до 50 найдите 90-й процентиль.

Задание 3



Проверьте свойство экспоненциального распределения без памяти с $\lambda=0,5$. Вычислите $P(X > 10 \mid X > 5)$ и сравните его с $P(X > 5)$.

Задание 4

Опрос 200 человек показал, что 120 человек любят кофе, 80 человек - чай, а 50 человек - и кофе, и чай. Если известно, что человек любит кофе, какова вероятность того, что он также любит чай?

Задание 5



У вас есть две монеты: честная и с двумя орлами. Вы наугад выбираете одну монету и подбрасываете ее. Она выпадает головой вниз. Какова вероятность того, что вы выбрали монету с двумя орлами?

Задание 6



Создайте набор данных из 1000 значений нормального распределения со средним значением 50 и стандартным отклонением 10. Рассчитайте и постройте график CDF набора данных.

Задание 7



Два класса сдавали разные экзамены. Среднее значение экзаменационных баллов класса А составляет 75, а стандартное отклонение - 10. Средние баллы класса В составляют 80, а стандартное отклонение - 12. Ученик из класса А получил 85 баллов, а ученик из класса В - 90 баллов. Рассчитайте Z-баллы для обоих студентов и определите, кто из них показал лучшие результаты по сравнению со своим классом.

Задание 8



Набор данных содержит следующие значения: [50, 52, 53, 54, 55, 56, 57, 58, 59, 60, 100]. Рассчитайте Z-баллы для каждого значения и определите все промахи (значения с Z-баллами больше 3 или меньше -3).

Задание 9



Средний рост взрослых мужчин в городе составляет 175 см при стандартном отклонении 8 см. Рассчитайте вероятность того, что рост случайно выбранного взрослого мужчины превышает 185 см. Используйте коэффициент Z и таблицу стандартного нормального распределения.



ВОПРОСЫ





РАЗБОР ДОМАШНЕГО ЗАДАНИЯ



Домашнее задание

1. Сгенерируйте 10 000 пар значений из равномерного распределения от 0 до 1. Вычислите сумму каждой пары и постройте гистограмму сумм.
2. При определенных условиях распределение Пуассона можно использовать в качестве приближения к биномиальному распределению:
 - Число испытаний n велико.
 - Вероятность успеха p мала.
 - Произведение np (среднее значение биномиального распределения) конечное и равно λ .

Пример: если у вас есть биномиальное распределение с $n=1000$ и $p=0.003$, вы можете аппроксимировать его, используя распределение Пуассона с $\lambda=np=3$.

Задача: сгенерировать случайные величины с биномиальным распределением, сгенерировать пуассоновские распределенные случайные величины с $\lambda = np$, построить графики распределений рядом друг с другом.

Домашнее задание

1. Компания оценивает своих сотрудников по трем показателям: продажи, удовлетворенность клиентов и пунктуальность. Среднее значение и стандартное отклонение для каждого показателя следующие:

- Продажи: Среднее = 500, Стандартное отклонение = 50
- Удовлетворенность клиентов: Среднее = 80, Стандартное отклонение = 10
- Пунктуальность: Среднее = 95, Стандартное отклонение = 5

У сотрудника следующие показатели:

- Продажи: 550
- Удовлетворенность клиентов: 85
- Пунктуальность: 90

Рассчитайте Z-баллы для каждой метрики и определите, в какой метрике сотрудник показал лучшие результаты по сравнению со средним показателем по компании.

Домашнее задание

2. Среднее время выполнения задания на фабрике составляет 30 минут со стандартным отклонением 5 минут. Рассчитайте вероятность того, что выполнение случайно выбранной задачи займет от 25 до 35 минут. Используйте коэффициент Z и таблицу стандартного нормального распределения.

3. Определенное заболевание поражает 1% населения. Тест на это заболевание имеет 99 % чувствительности (истинно положительный результат) и 2 % ложноположительных результатов. Если у человека положительный тест, какова вероятность того, что у него действительно есть болезнь?



ВОПРОСЫ



Заключение

